



Vers la traduction automatique de la Langue des Signes Française (LSF)

Yanis Ouakrim

► To cite this version:

Yanis Ouakrim. Vers la traduction automatique de la Langue des Signes Française (LSF). Traitement du signal et de l'image [eess.SP]. Université Grenoble Alpes [2020-..], 2025. Français. <NNT : 2025GRALT049>. <tel-05481114v2>

HAL Id: tel-05481114

<https://theses.hal.science/tel-05481114v2>

Submitted on 28 Jan 2026

HAL is a multi-disciplinary open access archive for the deposit and dissemination of scientific research documents, whether they are published or not. The documents may come from teaching and research institutions in France or abroad, or from public or private research centers.

L'archive ouverte pluridisciplinaire **HAL**, est destinée au dépôt et à la diffusion de documents scientifiques de niveau recherche, publiés ou non, émanant des établissements d'enseignement et de recherche français ou étrangers, des laboratoires publics ou privés.



HAL Authorization

THÈSE

Pour obtenir le grade de

DOCTEUR DE L'UNIVERSITÉ GRENOBLE ALPES



École doctorale : EEATS - Électronique, Électrotechnique, Automatique, Traitement du Signal (EEATS)

Spécialité : Signal Image Parole Télécoms

Unité de recherche : Grenoble Images Parole Signal Automatique

Vers la traduction automatique de la Langue des Signes Française (LSF)

Towards Machine Translation of French Sign Language (LSF)

Présentée par :

Yanis OUAKRIM

Direction de thèse :

Denis BEAUTEMPS

Chargé de recherche HDR, CNRS Délégation Alpes

Michèle GOUIFFES

Professeure des Universités, Université Paris Saclay

Thomas HUEBER

Directeur de recherche, CNRS Délégation Alpes

Annelies BRAFFORT

Directrice de recherche, CNRS

Directeur de thèse

Co-directrice de thèse

Co-encadrant de thèse

Co-encadrante de thèse

Rapporteurs :

Séverine DUBUISSON

Maitresse de conférences, Aix Marseille Université

Mounim EL YACOUBI

Professeur, Telecom SudParis

Thèse soutenue publiquement le **24 mai 2025**, devant le jury composé de :

Alice CAPLIER,

Professeur des universités, Grenoble INP, Université Grenoble Alpes

Denis BEAUTEMPS,

Chargé de recherche, CNRS

Michèle GOUIFFÈS,

Professeur des universités, Université Paris-Saclay

Séverine DUBUISSON,

Maitresse de conférences, Aix Marseille Université

Mounim EL YACOUBI,

Professeur, Telecom SudParis

Slim OUNI,

Professeur des universités, Université de Lorraine

Présidente

Directeur de thèse

Co-directrice de thèse

Rapporteuse

Rapporteur

Examineur



Abstract

Over the last ten years, the field of automatic language processing has been transformed by advances in deep learning. However, sign languages, and French sign language in particular, have not benefited from this revolution, which has primarily benefited those with better endowed written languages. Preliminary work on the collection of annotated corpora, followed by the development of sign recognition and machine translation methods, has been carried out on German, American and British sign languages. The aim of this thesis is to provide tools for the automatic processing of LSF to facilitate the development of new methods. During the course of this thesis, carried out between Gipsa-Lab and LISN, we carried out a number of exploratory studies on the automatic processing of French sign language, a poorly endowed visuo-gestural language. The little existing machine learning work had focused on automatic alignment, segmentation or sign type recognition. A major constraint was the scarcity of data. As a first step, we have developed initial sign recognition and classification methods based on the DictaSign-LSF corpus. Using these methods, we propose a quantification of the contribution of different articulators : hands, face, body, for sign recognition in LSF. Our study highlights the importance of the hands, but also demonstrates the contribution of the face and body to sign recognition. We also examined the extraction of discriminative features for sign plunging by comparing two strategies : training a sign classifier, and training a model by contrastive learning. Through an analysis of the plunges obtained, we determine that the classification task enables better plunge.

Secondly, we have made two new LSF corpora available to researchers : Matignon-LSF and Mediapi-RGB. Matignon-LSF is based on ministerial council minutes. It is the first interpreted LSF corpus, and has the advantage of being large in size compared with existing corpora (it is the largest after Mediapi-RGB), and is completely open to public and private research. Future work will focus on aligning subtitles, hitherto aligned with audio, with LSF. Mediapi-RGB is the largest LSF corpus to date, and one of the largest translated LS corpora in the world. It comprises 89 hours of LSF broadcasts signed by deaf people. As part of the publication of these two corpora, we have described their content and extracted features using open-access models to facilitate future processing. By publishing these two corpora, we have increased the total amount of data for French sign language from 30h to 160h. This makes LSF one of the best endowed sign languages in terms of translated corpora.

Finally, we are interested in the automatic translation of LSF into French from the Mediapi-RGB corpus. We propose a first classical translation method based on transformers. Initial results suggest that the amount of data available is still insufficient. Next, we attempt to take advantage of pre-learning, first on another sign

language, American Sign Language, then on written languages using large language models. Our experiments fail to demonstrate the value of pre-learning. And finally, we demonstrate the importance of a sign classification task to guide translation.

Résumé

Ces dix dernières années, le domaine du traitement automatique des langues s'est transformé grâce aux avancées de l'apprentissage profond. Cependant, les langues des signes, et en particulier la langue des signes française, n'ont pas profité de cette révolution qui a principalement bénéficié aux langues écrites les mieux dotées. En ce qui concerne les langues des signes allemande, américaine ou britannique, des corpus ont été annotés et des travaux de recherche ont abouti à la mise au point de méthodes de reconnaissance de signes et de traduction. L'objectif de cette thèse est de proposer des contributions en termes de données et d'algorithmes pour faciliter les futurs travaux de recherche sur la langue des signes française, qui devraient à plus long terme diversifier l'offre d'outils pour la communauté sourde. Le peu de travaux d'apprentissage automatique existants s'étaient concentrés sur l'alignement automatique, la segmentation ou la reconnaissance de types de signes. Une des contraintes majeures résidait dans la rareté des données. Dans un premier temps, nous avons mis au point de premières méthodes de reconnaissance et de classification de signes à partir du corpus DictaSign-LSF. À l'aide de ces méthodes, nous proposons une quantification de l'apport de différents articulateurs : mains, visage, corps, pour la reconnaissance de signes en LSF. Notre étude souligne l'importance des mains, mais démontre aussi la contribution du visage et du corps à la reconnaissance des signes. Nous nous sommes aussi intéressés à l'extraction de caractéristiques discriminantes pour le plongement de signes en comparant deux stratégies : l'entraînement d'un classifieur de signes, et l'entraînement d'un modèle par apprentissage contrastif. À travers une analyse des plongements obtenus, nous déterminons que la tâche de classification permet un meilleur plongement. Dans un deuxième temps, nous avons mis à disposition des chercheurs deux nouveaux corpus de LSF : Matignon-LSF et Mediapi-RGB. Matignon-LSF est issu des comptes-rendus des conseils des ministres. C'est le premier corpus de LSF interprétée, il présente l'avantage d'être de grande taille en comparaison avec les corpus existants (c'est le plus grand après Mediapi-RGB), et est complètement ouvert à la recherche publique et privée. De futurs travaux s'intéresseront à aligner les sous-titres, jusqu'alors alignés avec l'audio, avec la LSF. Mediapi-RGB est le plus gros corpus de LSF à ce jour et un des plus gros corpus traduit de LS à travers le monde. Il s'agit de 89h d'émissions en LSF signées par des sourds. Dans le cadre de la publication de ces deux corpus, nous avons décrit leur contenu et nous avons extrait des caractéristiques à l'aide de modèles en accès libre pour faciliter les traitements futurs.

En publiant ces deux corpus, nous avons porté la quantité totale de données pour la langue des signes française de 30h à 160h, faisant ainsi de la LSF l'une des langues des signes les mieux dotées en corpus traduits.

Enfin, dans un troisième temps, nous nous intéressons à la traduction automatique de la LSF vers le français à partir du corpus Mediapi-RGB. Nous proposons une première méthode de traduction classique à base de *transformers*. Les premiers résultats suggèrent que la quantité de données disponibles reste insuffisante. Ensuite, nous tentons de tirer parti d'un pré-apprentissage, d'abord sur une autre langue des signes, la langue des signes américaine, puis sur des langues écrites à travers de grands modèles de langue. Nos expériences ne permettent pas de démontrer l'intérêt du pré-apprentissage. Et pour finir, nous montrons l'intérêt d'une tâche de classification des signes pour guider la traduction de la LSF.

Remerciements

En premier lieu, je tiens à remercier chaleureusement mon directeur et ma co-directrice de thèse, Denis Beautemps et Michèle Gouiffès pour leur accompagnement tout au long de la thèse, leur disponibilité, leur bienveillance et leur grand intérêt scientifique pour le sujet. Je souhaite également remercier Annelies Braffort pour le temps passé à échanger sur la LSF, la surdité, les corpus de langue des signes, tout cet univers que je ne connaissais pas avant de commencer cette thèse. Merci aussi à Thomas Hueber qui a participé à l'encadrement pour la traduction automatique et la reconnaissance de signes avec un grand intérêt.

Je remercie également toutes les chercheuses avec qui j'ai pu collaborer : Hannah Bull, Diandra Fabre, Sanjana Sankars, Julie Halbout et Julie Lascar. Les travaux présentés dans ce manuscrit n'auraient également pas pu voir le jour sans le travail parfois invisible des personnels administratifs et techniques.

Mon doctorat aurait eu une autre saveur si je n'avais pas eu la joie des moments conviviaux passés avec mes collègues doctorants Clément, Hugo, Léa, Maxime, Jalal, Hugo, Clara, Juliette, Olivier, Baptiste, Charles et tous les autres.

J'ai également apprécié le temps passé en dehors du labo à profiter de la montagne ou de la ville avec vous ; Valentine, Adrien A., Adrien L., Alexis I., Alexis F., Samuel, Hortense, Ryan, Marguerite, Étienne, Thibault, Thomas, Claire-Marie, Aude, Rémi, etc. Les moments passés ensemble ont permis la déconnexion nécessaire pour fournir ce travail.

Merci également à Justine, Suzanne, Maxime, Mirana pour les interludes musicaux et le temps passé au conservatoire et parfois en dehors.

Mon installation à Grenoble aurait pu être un moment difficile si je n'avais pas pu compter sur mes amis de longue date avec qui les échanges réguliers m'ont permis de ne jamais me sentir seul : Matt, Jules, Raphaël, Jean et tout particulièrement Martin pour l'abondance de nos échanges et les bons moments passés ensemble.

Je remercie chaleureusement mes parents et mes frères et sœurs pour leur oreille attentive et leur grand soutien, et en particulier ma mère qui a également relu mon manuscrit.

Abstract	3
Résumé	5
Introduction	19
Préambule	25
État de l'art	32
1.1 Introduction	32
1.2 Reconnaissance de signes isolés	33
1.2.1 Méthodes de reconnaissance d'actions basées sur les trames RGB	33
1.2.2 Méthodes de reconnaissance d'actions à partir de la pose humaine	34
1.2.3 Reconnaissance de signes isolés	36
1.3 Reconnaissance de signes en LS continue	37
1.3.1 Reconnaissance automatique de la parole	38
1.3.2 Reconnaissance de signes en contexte continu	38
1.4 Traduction	38
1.4.1 Un aperçu de la traduction des langues écrites	39
1.4.2 Traduction langue des signes vers langue écrite	43
1.4.3 Traduction langue écrite vers langue des signes	44
1.5 Segmentation temporelle des énoncés en Langue des Signes	45
1.6 Alignement	46
1.7 Autres tâches	47
1.8 Conclusion	47
Nouveaux corpus pour le traitement automatique de la LSF	49
2.1 Introduction	50
2.2 Typologie des corpus de LS	50
2.2.1 Sources	50
2.2.2 Annotation	52
2.3 Corpus existants	54
2.3.1 À l'international	55
2.3.2 En LSF	57
2.3.3 Conclusion	60
2.4 Matignon-LSF	60
2.4.1 Collecte des données	61
2.4.2 Description du corpus	62
2.4.3 Limitations	64
2.4.4 Perspectives	64
2.4.5 Conclusion	65
2.5 Mediapi-RGB	65
2.5.1 Description du corpus	66
2.5.2 Limitations	69
2.5.3 Perspectives	69

2.5.4	Conclusion	70
2.6	Synthèse	70
Représenter le signe en machine, modéliser le mouvement		71
3.1	Reconnaissance de signes lexicaux dans un énoncé continu	72
3.1.1	Extraction de caractéristiques	73
3.1.2	Architecture du modèle de reconnaissance	73
3.1.3	Expériences	74
3.1.4	Résultats	75
3.1.5	Conclusion	77
3.2	Stratégies d'entraînement d'extracteurs de caractéristiques à l'échelle du signe	78
3.2.1	Représentations existantes	78
3.2.2	Préparation des données	79
3.2.3	Encodage des signes	80
3.2.4	Expériences	81
3.3	Conclusion	85
Traduction automatique de la LSF		90
4.1	Introduction	90
4.2	Travaux existants	91
4.3	Modèle <i>transformer</i> encodeur-décodeur	92
4.3.1	Architecture du modèle de traduction initial	92
4.3.2	Encodage des vidéos de langue des signes	95
4.3.3	Transfert interlangue	96
4.4	Intégrer un pré-entraînement sur le texte	96
4.5	Utiliser des pseudo-gloses pour faciliter la tâche de traduction	99
4.6	Expériences	100
4.6.1	Métriques d'évaluation	100
4.6.2	Entraînement du premier modèle de traduction Transformer	102
4.6.3	Évaluation des différents encodeurs vidéos	106
4.6.4	Transfert inter-langue	107
4.6.5	Pré-entraînement sur le texte	109
4.6.6	Entraînement conjoint classification et traduction	111
4.7	Conclusion et perspectives	113
Conclusion		117
Bibliographie		122

Table des figures

1	Acuité auditive perçue et niveau de diplôme (en pourcentage). Source [Sit12]	26
2	Acuité auditive et situation financière perçues (en pourcentage). Source [Sit12]	26
3	L'abbé de l'Épée instruisant ses élèves en présence de Louis XVI , Gonzague Provat, 1875, Huile sur toile. Collection INJS, Paris.	27
4	Les grandes familles de langues des signes . Figure issue de [PGL20]	29
5	La modalité visuo-gestuelle des langues des signes . L'émetteur transmet un message en langue des signes à un récepteur qui regarde l'espace de signation. Illustration issue de [Gui06]	30
6	Transfert personnel . Le transfert personnel consiste à incarner une entité : personne, objet ou animal pour décrire une situation, raconter un événement. Illustration issue de [VGLar]. Ici, le signeur incarne une fleur sur laquelle se pose une abeille (à gauche), courbée par la pluie (au centre), cueillie (à droite)	31
1.1	Vision Transformer , figure issue de [DBK ⁺ 20]. L'image d'entrée est divisée en patchs de 16×16 pixels. Chacun d'entre eux est plongé de façon linéaire puis concaténé à un encodage positionnel puis la séquence obtenue est fournie en entrée d'un encodeur <i>transformer</i>	34
1.2	Exemple d'extraction de pose à l'aide d'OpenPose [CHS ⁺ 19] sur une vidéo de langue des signes allemande (DGS) du corpus Phonenix-RT2014 [KFN15]. Image issue de [SCB21].	35
1.3	Principe de la convolution sur graphe, figure issue de [KW16]. Le graphe en entrée contient C canaux et le graphe de sortie contient F caractéristiques. La structure du graphe est partagée entre les couches, Y_i correspond aux labels des nœuds.	36
1.4	Deuxième machine à traduire de Georges Artsrouni [Dau65]. Il s'agit en réalité d'une sorte de dictionnaire, la saisie d'un mot en français se fait à partir des 23 touches de machine à écrire, et le résultat en anglais est affiché à l'aide de voyants lumineux.	39
1.5	Architecture Encodeur / Décodeur pour la traduction automatique.	40
1.6	Carte d'attention obtenue dans le cadre de la traduction anglais vers français . Les points clairs indiquent un haut niveau d'attention.	41
1.7	Modules Transformer encodeur et décodeur . Illustration issue de [VSP ⁺ 17]	41

1.8	Pipeline classique de traduction automatique d'une langue des signes vers une langue écrite. La partie encodeur prend en entrée des caractéristiques extraites à partir des vidéos de langue des signes et la partie décodeur auto-régressive prédit les futurs <i>tokens</i> en fonction des précédents.	43
1.9	Exemple de pipeline de traduction texte vers langue des signes sur le corpus de langue des signes allemande PHOENIX-RT-2014 [KFN15] issu de [SCB20a].	44
1.10	Le problème d'alignement des sous-titres avec l'interprétation en LS. La ligne S_{audio} correspond à l'alignement original, sur l'audio et la ligne S_{GT} , correspond à un alignement ajusté à la langue des signes. Figure issue de [BAV ⁺ 21]	46
1.11	Recherche d'information dans des vidéos de langue des signes américaine à partir d'une requête textuelle. Figure issue de [DAGiNV22].	47
2.1	Photo prise lors de l'enregistrement du corpus Mocap1 [5]	51
2.2	Enregistrement de gestes bimanuels à l'aide d'un gant numérique. Image issue de [Bos06]	51
2.3	Capture d'écran du <i>DicoElix</i> , dictionnaire Français / LSF	53
2.4	Capture d'écran de <i>SpreadTheSign</i> dictionnaire multilingue de Langues des Signes	53
2.5	Capture d'écran de <i>Media'Pi</i> média sourd en LSF	53
2.6	Capture d'écran de la page Facebook de l'association JMS – Grenoble, qui publie des vidéos en LSF pour un public sourd	53
2.7	Différents types de données du corpus How2Sign. Figure issue de [DPV ⁺ 21]	55
2.8	Visualisation des poses issues d'une vidéo du corpus Mediapi-Skel et du sous-titre associé	58
2.9	Capture d'écran de <i>Media'Pi</i> média sourd en LSF	60
2.10	Capture d'écran de <i>l'Œil et la main</i> , une émission de télévision diffusée sur France 5 qui traite des questions liées à la surdité	60
2.11	Capture d'écran du <i>10 minutes</i> , une émission en ligne en LSF	60
2.12	Capture d'écran du journal de 19h, sur Franceinfo, interprété en LSF	60
2.13	Capture d'écran du compte rendu du conseil des ministres du 21 Mai 2024 , avec sous-titrage et interprétation en LSF sur la plateforme YouTube	61
2.14	Capture d'écran d'une vidéo du corpus Matignon-LSF avec le sous-titre associé, la vidéo a été rognée autour de l'interprète.	62
2.15	Pipeline de collecte des données pour Matignon-LSF. À titre personnel, je me suis chargé des étapes 1,2 et 4. Et j'ai contribué à l'étape 5.	63
2.16	Durée des corpus de LSF traduits. Matignon-LSF est le deuxième plus gros corpus de LSF traduit après Mediapi-RGB (section 2.5) et le plus gros corpus de LSF interprétée.	63
2.17	Occurrences des 20 noms les plus fréquents du corpus. Le champ lexical correspond à la politique française.	63
2.18	Capture d'écran issue d'un épisode de Média'Pi avec son sous-titre en français associé	66

2.19	Occurrences des 20 noms les plus fréquents du corpus. Le champ lexical correspond à l'actualité de la période de la création de ces contenus.	67
2.20	Trames de début de deux vidéos identiques dont le découpage, basé sur les sous-titres est décalé.	69
2.21	Trames de deux vidéos identiques ayant subi des processus de compression différents.	69
2.22	Deux extraits identiques dont l'arrière-plan a été modifié.	69
2.23	Le même reportage rediffusé mais l'échelle des deux extraits est différente.	69
3.1	Illustration du type d'annotation réalisée sur une vidéo extraite du corpus DictaSign-LSF-v2.	72
3.2	Architecture du modèle proposé pour la reconnaissance de signes lexicaux dans un flux continu.	73
3.3	Illustration du traitement réalisé sur les vidéos du corpus DictaSign-LSF-v2 pour obtenir des segments de 16 trames associés aux signes.	79
3.4	Modèle de classification. Le modèle prend en entrée une séquence de poses 3D. L'encodeur réduit ces données pour obtenir un vecteur à 64 dimensions. Une tête de classification prédit un label de signe pour l'ensemble de la séquence d'entrée.	81
3.5	Modèle de réseaux siamois. Le modèle prend deux séquences de poses 3D en entrée. L'encodeur doit prédire des vecteurs de représentation similaires dans le cas où les deux séquences correspondent au même signe, et des vecteurs distincts pour des signes différents.	82
3.6	Extraits des vidéos des sept signes utilisés dans l'analyse qualitative. . . .	86
3.7	Visualisations de projections obtenues avec la tâche de classification entraînée sur les 100 classes les plus fréquentes. Chaque point correspond à une occurrence et chaque couleur correspond à un signe lexical, la légende donne les gloses associées aux signes choisis.	87
3.8	Visualisations de projections obtenues avec la tâche d'apprentissage contrastif des occurrences de 7 signes issus de l'ensemble de test des classes non vues. Chaque point correspond à une occurrence et chaque couleur correspond à un signe lexical, la légende donne les gloses associées aux signes choisis.	88
4.1	Vue d'ensemble de l'architecture transformer utilisée. Le modèle prend en entrée des caractéristiques Video Swin extraites sur les vidéos et prédit en sortie du texte en français.	93
4.2	Exemples de tâches prétextes pour l'entraînement du modèle T5. Figure issue de [RSR ⁺ 20].	96
4.3	Aperçu de la méthode de traduction proposée par les auteurs de YouTube-ASL [UTG23]. Les vidéos sont transformées en coordonnées Mediapipe normalisées puis fournies au modèle T5.1 qui doit fournir une traduction de la langue des signes en langue écrite.	97
4.4	Fonctionnement de la méthode proposée. Dans un premier temps le modèle apprend à exécuter des tâches texte vers texte. Puis, le modèle est affiné pour traduire la langue des signes française vers le français. Le <i>prompt</i> est plongé avec la couche de plongement textuel alors que les vidéos sont plongées avec des caractéristiques visuelles.	98

4.5	Illustration du modèle d'apprentissage conjoint classification-traduction. .	100
4.6	Aperçu du fonctionnement de la métrique BERT score. Figure issue de [ZKW ⁺].	102
4.7	Les 45 noms de l'ensemble de test ayant le plus haut score F1 en traduction. Le score F1 obtenu est en bleu et le nombre d'occurrences (par lemme) dans l'ensemble d'entraînement est en rouge. Pour rappel $F_1 = 2 \cdot \frac{(\text{précision} \cdot \text{rappel})}{(\text{précision} + \text{rappel})}$	105
4.8	Répartition des scores BLEURT (en fonction du score divisé par 100 en abscisse) obtenus sur l'ensemble de test.	107

Liste des tableaux

1.1	Quelques méthodes de reconnaissance d'actions humaines à partir de vidéos et le score d' <i>accuracy</i> sur le dataset Kinetics-400 [KCS ⁺ 17]	35
1.2	Top-1 <i>accuracy</i> pour différentes méthodes de reconnaissance de signes isolés sur le dataset WLASL [LROYL19]. Tableau issu de [HZZL23]	37
2.1	Corpus de Langues des signes continue traduits en langue écrite les plus importants dans le monde	56
2.2	Les corpus de LSF. Tableau issu de [Bra22]	57
2.3	Émissions en LSF ou interprétées en LSF	59
2.4	Statistiques du corpus Matignon-LSF. *Les journalistes ne sont pas inclus	62
2.5	Statistiques du corpus Mediapi-RGB	67
3.1	Étude d'ablation des articulateurs d'entrée. Main droite, main gauche, pose générale du corps et maillage du visage.	76
3.2	Performance du modèle en fonction du nombre de gloses considérées lors de l'apprentissage.	76
3.3	Exemples de séquences de gloses prédites avec la vérité terrain correspondante. Les deux premières séquences ont obtenu un WER de 50 %, la dernière un WER de 75 %.	77
3.4	<i>Accuracy</i> obtenue avec la tâche de classification sur l'ensemble de test. Ici, l'ensemble de test contient des signes qui ont été appris lors de l'entraînement.	82
3.5	Accuracy obtenue par la tâche d'apprentissage contrastif sur les ensembles de test de signes vus et non vus. Notons que la taille de l'ensemble de test correspondant aux classes <i>vues</i> dépend du nombre de classes utilisées dans l'ensemble d'apprentissage. Par conséquent, sa contribution dans les résultats de la colonne <i>Toutes</i> varie également.	83
3.6	Scores N2 obtenus sur les vidéos de 208 classes de signes non vus, pour les deux types d'encodeur, et pour les deux types d'entraînement : en utilisant les 100 classes les plus représentées, ou l'ensemble des classes.	84
4.1	Hyperparamètres du modèle de traduction <i>transformer</i> sur Mediapi-RGB.	103
4.2	Scores BLEU, BLEURT et BERT (F1) obtenus avec notre baseline de traduction sur les données d'entraînement et de test de Mediapi-RGB.	104
4.3	Exemples de traductions obtenues sur l'ensemble de test de Mediapi-RGB à l'aide du modèle <i>transformer</i> encodeur-décodeur.	106
4.4	Comparaison des résultats de traduction obtenus sur les jeux de données de langues des signes. Tableau adapté de [TGD ⁺ 23].	108
4.5	Comparaison des représentations d'entrée pour la traduction à l'aide de la baseline <i>transformers</i>	108

4.6	Scores de traduction obtenus avec ou sans pré-entraînement sur How2Sign.	109
4.7	Exemples de sous-titres issus de How2Sign [DPV⁺21] traduits de l'anglais vers le français. Les vidéos de How2Sign portent sur des tutoriels issus du corpus How2.	110
4.8	Reproduction de l'expérience de [UTG23] sur How2Sign et Mediapipe-RGB avec le modèle T5.1 [RSR ⁺ 20] sur les coordonnées Mediapipe [BGR ⁺ 20] normalisées.	110
4.9	Modèles pré-entraînés sur du texte. L'entrée textuelle est remplacée par les caractéristiques VideoSwin-BSL.	111
4.10	Exemples de prédictions avec le modèle FLAN-T5 pré-entraîné en multi-tâches texte vers texte et affiné sur la traduction automatique de la LSF vers le français	112
4.11	(a) Répartition du score BLEURT (en fonction du score divisé par 100 en abscisse) pour le cas avec tâche de classification en 500 clusters (bleu) et le cas sans (rouge) (b) Focus sur la différence des 2 répartitions en fonction du score BLEURT (divisé par 100)	113
4.12	Exemples de résultats de traduction à partir du modèle transformer (T), à partir de la classification-traduction où la traduction est guidée par la classification (CT). La vérité terrain est indiquée (VT).	115

Introduction

Domaine de niche au début du XXI^{ème} siècle, le traitement automatique des langues envahit aujourd'hui notre quotidien : recherche d'information, assistants vocaux, traduction automatique instantanée et agents conversationnels. Mais ces petites révolutions qui facilitent la vie ne sont malheureusement pas accessibles à tous : les locuteurs de langues peu dotées sont souvent écartés de ces nouveaux outils. Les personnes sourdes signantes, qui utilisent la langue des signes française (LSF) au quotidien, font partie des mis au ban : la LSF, langue peu dotée, est à ce jour exclue des avancées du traitement automatique du langage naturel. Si des travaux existants ont ouvert la voix à travers de premiers corpus de LSF et de premières méthodes de catégorisation automatique [Bel20], de segmentation ou d'alignement [Bul23], la langue des signes française reste à la traîne au regard des collectes et des travaux effectués sur d'autres langues des signes. L'objectif de ce travail de thèse est d'outiller la recherche en traitement automatique de la LSF en proposant de nouveaux corpus et de premières méthodes de reconnaissance, de classification et enfin de traduction automatique vers le français écrit.

Contexte

Cette thèse a été financée dans le cadre du projet BPI France PSpC *Serveur Gestuel* démarré en 2020 et piloté par la société Ivès¹. Le projet regroupe deux entreprises : 4Views² et Ivès, et deux laboratoires le GIPSA-Lab à Grenoble et le LISN à Orsay.

L'objectif de la société Ivès à travers ce projet est de développer l'équivalent du serveur vocal pour la langue des signes. L'utilisateur aura possibilité d'interroger un signeur virtuel, pour faciliter ses tâches au quotidien comme le suivi d'un colis, ou des démarches administratives.

Une partie des partenaires s'est concentrée sur l'animation du signeur virtuel, tandis que nous nous sommes attachés à concevoir des algorithmes d'analyse des vidéos en LS. Le développement de ces outils nécessite un long travail sur les données (collecte, annotation, mise en correspondance ou alignement entre langue signée et langue écrite) et sur les algorithmes d'analyse de vidéos, qui s'inspirent généralement de la littérature en analyse d'activités humaines plus généraliste : classification, reconnaissance d'un signe donné dans une vidéo, traduction de la langue des signes vers la langue écrite ou l'inverse.

1. Société spécialisée dans le développement d'une plateforme relais entre sourds et entendants par le biais d'interprètes

2. Société spécialisée dans la captation de vidéos 3D et la capture de mouvements.

Le travail de thèse qui a donné lieu à la rédaction de ce manuscrit s'est déroulé entre ces deux laboratoires au sein de trois équipes de recherche : l'équipe CRISSP, qui travaille principalement sur la reconnaissance et la synthèse de la parole, l'équipe AMI, qui s'intéresse aux systèmes d'interaction, et l'équipe ILES dont les travaux portent sur le traitement de la langue écrite et signée.

En plus de mes encadrants, j'ai pu collaborer avec des chercheuses non permanentes : des doctorantes, Julie Halbout et Hannah Bull [Bul23], une post-doctorante, Diandra Fabre, et une ingénieure Julie Lascar.

Du côté du LISN, cette thèse s'inscrit dans la continuité des travaux effectués par plusieurs doctorants sur la reconnaissance de structures linguistiques [Bel20], ou encore l'alignement [BAV⁺21] entre langue signée et langue écrite. Du côté du Gipsa-Lab, la thèse fait suite à de nombreux travaux dans le domaine de la surdité portant sur la langue parlée complétée (LPC) [SBH22, Liu18], un système visuo-gestuel de codage du français oral, qui s'appuie sur des gestes de la main pour compléter la lecture labiale.

Positionnement

Du fait des difficultés sociales rencontrées par les personnes sourdes à travers l'Histoire, et plus récemment de l'interdiction de l'enseignement en langues des signes dans de nombreux pays suite au congrès de Milan, les travaux de recherche sur la langue des signes française doivent porter une attention particulière au respect des personnes sourdes et idéalement à leur inclusion dans ces travaux.

Moi-même, l'auteur de ce manuscrit et des différents travaux qui y sont présentés, ne suis pas sourd. J'ai une connaissance limitée des enjeux liés à la surdité ou de la *culture sourde*. J'ai validé le niveau A1.1 en LSF au début de mon doctorat, ce qui correspond à un niveau basique permettant de connaître les rudiments (phrases simples, vocabulaire basique : couleurs, alphabet, prénom, etc.). Pendant la période qui couvre mon doctorat, j'ai eu peu d'interactions avec des personnes sourdes. J'ai pu rencontrer des chercheurs sourds signants lors des éditions de l'atelier Sign-lang@LREC qui m'ont apporté leur éclairage personnel. Mes encadrants sont entendants, ils ont tous consacré une partie de leur carrière académique à des sujets liés à la surdité (langue des signes, langue parlée complétée). Pour résumer, le travail présenté dans ce manuscrit a été mené au sein d'un milieu exclusivement entendant avec de rares interactions avec des personnes sourdes, par conséquent il peut souffrir de biais [DDMH⁺24].

Objectifs

Cette thèse suit trois objectifs principaux : l'identification de signes dans les vidéos, la mise à disposition de nouveaux corpus de données, puis la traduction de la langue des signes vers la langue écrite.

Méthode de reconnaissance de signes en contexte continu

Dans le cadre du projet *Serveur Gestuel*, l'un des objectifs était de permettre la reconnaissance de signes dans un flux continu de LSF, c'est-à-dire dans une phrase ou un énoncé de plusieurs signes. Dans ce cadre, nous avons pu tirer profit des travaux réalisés en interne et les approfondir, notamment ceux de Valentin Belissen [Bel20], portant sur la reconnaissance de types de signes dans un flux continu de LSF et des travaux de Sanjana Sankar portant sur la reconnaissance de phonèmes dans un flux continu de langue française parlée complétée.

Mise à disposition de nouveaux corpus

Les méthodes actuelles en traitement automatique des langues, y compris des langues des signes, s'appuient sur des réseaux de neurones profonds. Ces modèles nécessitent de grandes quantités de données, idéalement annotées, pour leur apprentissage. Ainsi, un deuxième objectif de cette thèse est la mise à disposition de nouveaux jeux de données pouvant contribuer à faire avancer la recherche sur la LSF. En effet, la langue des signes française fait jusqu'alors l'objet de très peu de corpus, ce qui complique fortement l'utilisation de modèles d'apprentissage profond. Il s'agira de constituer des corpus ouverts pour être utilisables par la communauté scientifique.

Proposer de premières méthodes de traduction de la langue des signes française à partir des nouveaux corpus proposés

Après la constitution de nouveaux corpus, l'un des objectifs est de proposer de premières méthodes de traduction automatique de la LSF à partir des corpus proposés. Il s'agit dans un premier temps d'implémenter une ligne de base correspondant au type d'architecture le plus utilisé pour la traduction automatique : un modèle *transformer* Encodeur / Décodeur, puis de tester des modèles plus complexes issus de l'état de l'art et d'étudier s'ils s'adaptent ou non à la LSF et au français au vu des données disponibles.

Production scientifique

Les différents travaux décrits dans ce manuscrit ont abouti à la mise à disposition de jeux de données ainsi qu'à des publications scientifiques.

Données

- **DictaSign-LSF-100** : À partir du corpus existant DictaSign-LSF de discussions en LSF, on propose un jeu de données de signes pour la classification, il s'agit du premier corpus de classification de signes en LSF.
- **Matignon-LSF** : disponible à l'adresse <https://www.ortolang.fr/market/corpora/matignon-lsf>, il correspond à 39h de LSF interprétée avec sous-titres en français. Ces données sont issues des comptes-rendus du conseil des ministre du gouvernement français.

- **Mediapi-RGB** : disponible à l'adresse <https://www.ortolang.fr/market/corpora/mediapi-rgb>. Mediapi-RGB contient 86 heures de langue des signes originale en LSF avec des sous-titres français alignés sur l'audio.

Articles

- Ouakrim, Y., Beautemps, D., Gouiffès, M., Hueber, T., Berthommier, F., & Braffort, A. (2023). *A Multistream Model for Continuous Recognition of Lexical Units in French Sign Language*.

J'ai conduit les différentes expériences présentées dans l'article, et je me suis chargé de la rédaction. Mes encadrants ont largement contribué aux idées derrière cet article, et m'ont accompagné pour la rédaction.

- Ouakrim, Y.¹, Bull¹, H., Gouiffès, M., Beautemps, D., Hueber, T., & Braffort, A. (2024, February). Mediapi-RGB : Enabling technological breakthroughs in french sign language (LSF) research through an extensive Video-Text corpus. In *19th International Joint Conference on Computer Vision, Imaging and Computer Graphics Theory and Applications (Vol. 2)*.

Prix du meilleur article de la conférence.

Ce travail est un travail conjoint avec Hannah Bull [Bul23] et mes encadrants. J'ai conduit une partie des analyses du corpus et une partie de la rédaction (introduction, état de l'art, expérience). Hannah a contribué au plus gros de la rédaction et à l'organisation du travail. J'ai conduit l'expérience de traduction présentée dans l'article et l'analyse des résultats. Mes encadrantes Annelies Braffort et Michèle Gouiffès ont établi le partenariat permettant la création du corpus. Tous mes encadrants ont contribué aux discussions et aux idées liées à l'expérience de traduction.

- Halbout, J.¹, Fabre, D.¹, Ouakrim, Y.¹, Lascar, J.¹, Braffort, A., Gouiffès, M., & Beautemps, D. (2024, May). Matignon-LSF : a Large Corpus of Interpreted French Sign Language. In *LREC-COLING 2024 11th Workshop on the Representation and Processing of Sign Languages : Evaluation of Sign Language Resources (pp. 202-208)*.

Je me suis chargé de la collecte du corpus, j'ai organisé la collaboration, et j'étais à l'initiative du travail. J'ai rédigé un tiers de l'article. Julie Halbout et Julie Lascar se sont chargées des analyses statistiques. Diandra Fabre a mené une analyse de l'alignement des sous-titres. Julie Halbout, Diandra Fabre et Annelies Braffort ont participé à la rédaction du papier. Michèle Gouiffès et Denis Beautemps ont participé aux discussions et à la relecture du papier.

- Fabre, D., Lascard, J., Ouakrim, Y., Lascar, J., Braffort, A., Hueber, T., Gouiffès, M., & Beautemps, D. (soumis, 2024, Sept.). Exploring Sign Re-

1. Contribution égale

cognition Strategies to Enhance Automatic Translation of French Sign Language.

Diandra Fabre a conduit les différentes expériences présentées dans l'article et a fait le plus gros de la rédaction. Julie Lascar s'est chargée de l'obtention des annotations semi-automatiques avec contrôle humain. J'ai été à l'initiative de l'utilisation de pseudo-labels comme alternatives aux annotations humaines, et je me suis chargé de leur génération et j'ai participé de façon mineure à la rédaction. Mon encadrant Denis Beutemps est à l'initiative de l'idée derrière cet article. Mes autres encadrants ont largement contribué à la relecture du papier.

Organisation du manuscrit

Le préambule de ce manuscrit donne des notions sur les enjeux liés à la surdité et les langues des signes en général d'un point de vue historique, social et linguistique. Le chapitre 1 dresse un état de l'art des travaux portant sur les différentes langues des signes en mettant l'accent sur les méthodes propres à la LSF. Ce chapitre comprend de nombreux ponts vers d'autres domaines de recherche, notamment : la traduction des langues écrites, la reconnaissance de la parole, et la classification de vidéos. Pour chaque corpus, le processus de collecte et de prétraitement des données est décrit.

Le chapitre 2 dresse un état des lieux des ressources de langue des signes disponibles à travers le monde, puis en particulier des ressources existantes en langue des signes française. Enfin, deux nouveaux corpus sont présentés : Matignon-LSF et Mediapi-RGB. On analyse le champ lexical des corpus, et on donne leurs limites et leurs avantages. Pour chaque corpus on développe le processus de collecte et de préparation des données en vue de faciliter la mise en œuvre de traitements automatiques.

Le chapitre 3 s'intéresse à la représentation machine des signes. Dans un premier temps, il présente une première méthode de reconnaissance de signes en flux continu de LSF. Cette méthode est ensuite utilisée pour quantifier l'apport des différents articulateurs de la LSF : les deux mains, le visage et la pose générale du corps. Dans une deuxième section, on s'intéresse aux stratégies d'apprentissage de représentations pour la langue des signes française. On compare les plongements de signes obtenus à l'aide d'un classifieur, méthode la plus utilisée dans l'état de l'art, puis à l'aide d'une tâche d'apprentissage contrastif, où un modèle doit juger de la similarité entre deux occurrences de signes identiques ou non.

Dans le chapitre 4, Mediapi-RGB, le plus grand corpus de LSF traduit en français, est utilisé pour développer une première méthode de traduction de la LSF vers le français. Les résultats obtenus sont ensuite analysés en détail. Une seconde approche explore les avantages d'un pré-entraînement sur une langue des signes proche, l'ASL. Par la suite, l'accent est mis sur l'exploitation de grandes quantités de texte à l'aide de grands modèles de langues. Enfin, des pseudo-labels de forme de signes sont intégrés pour améliorer la qualité de la traduction.

La conclusion de ce manuscrit résume les différentes contributions du travail présenté, dresse leurs limitations puis offre des perspectives pour y faire face lorsque c'est possible.

Préambule

Pour une bonne appréhension des différents concepts abordés au cours des chapitres, il est nécessaire de commencer par une brève présentation du contexte social, historique et linguistique de la surdité et des langues des signes.

Quelques mots sur la surdité

La Fédération Mondiale des Sourds estime qu'il y aurait plus de 70 millions de personnes sourdes dans le monde³. Derrière ce chiffre se cache une multitude de réalités différentes : la surdité peut être partielle ou totale et évoluer au cours de la vie. La surdité peut être vécue comme un handicap ou non. Certains Sourds⁴ se sentent appartenir à une communauté sourde d'autres non. Les surdités les plus légères apparaissent la plupart du temps avec le vieillissement alors que les surdités plus sévères sont souvent présentes dès la naissance ou la petite enfance [Sit12].

Les personnes sourdes profondes sont en moyenne moins diplômées que le reste de la population et ont plus de difficultés financières comme le montrent les figures 1 et 2 issues du baromètre de la surdité publié par l'INPES en 2012 [Sit12]. Ces difficultés peuvent être en partie expliquées par les problèmes de communication rencontrés par les personnes sourdes tout au long de la vie, que ce soit à l'école ou dans le monde du travail. De plus, une grande majorité des sourds éprouve des difficultés à la lecture et l'écriture [DH09]. Si les implants cochléaires, qui permettent aux personnes sourdes d'avoir un semblant d'audition, sont parfois vus comme une solution technique à la surdité, en France, seulement 7,2% des personnes sourdes y ont recours ; l'écrasante majorité ne souhaite pas se faire implanter ou estime ne pas en avoir besoin (88,3%). A contrario, 86,5% des personnes qui n'entendent pas communiquent en LSF [Sit12].

Pour faire face à certains problèmes de communication, il existe des centres relais téléphoniques qui permettent aux personnes sourdes de faire appel à un interprète pour les aider à communiquer avec une personne ou un service. En France, 36,2% des personnes qui communiquent en LSF y ont déjà fait appel. Au total, on estime que 500 000 personnes sourdes et malentendantes nécessiteraient un service téléphonique spécifique en France⁵. L'une des principales difficultés pour généraliser ce type de service d'accessibilité est le manque d'interprètes. En France, le métier d'in-

3. <https://wfdeaf.org>

4. Le mot *Sourd* écrit avec une majuscule fait référence aux personnes se réclamant de la communauté sourde.

5. ARCEP, *Rapport d'évaluation des besoins des personnes sourdes ou malentendantes en matière d'accessibilité des services téléphoniques*




Figure 1 – **Acuité auditive perçue et niveau de diplôme** (en pourcentage). Source [Sit12]




Figure 2 – **Acuité auditive et situation financière perçues** (en pourcentage). Source [Sit12]

terprète en LSF, comme pour toutes les langues, est un métier très qualifié (bac+5). En 2003 on comptait 300 interprètes de LSF alors qu'on estime qu'il en faudrait 1 000⁶.

Qu'est-ce qu'une langue des signes ?

Contrairement à une idée reçue, les langues des signes n'ont pas été "inventées" mais, à l'instar des langues vocales, elles ont émergé de façon naturelle pour permettre aux personnes sourdes de communiquer. Elles sont donc rattachées à des zones géographiques plus ou moins définies, tout comme les langues vocales⁷. Les langues des signes ne sont pas une autre façon de représenter les mots de la langue vocale du pays ou de la région, ce sont des langues à part entière. Ainsi, l'énoncé en langue des signes ne suit pas l'ordre des mots d'une langue vocale, il présente ses propres spécificités dont il faut tenir compte pour le traitement automatique des langues des signes.

Les langues des signes à travers l'Histoire

On trouve des traces écrites très anciennes de l'existence de langues des signes, chez Platon (500 av. J.-C.) ou encore dans l'Évangile de Luc (60 ap. J.-C.). Par

6. <https://informations.handicap.fr/a--3027.php>

7. Le terme *langue vocale* fait référence aux langues de modalités audio-phonatoire, comme le français par exemple, par opposition aux langues des signes qui suivent une modalité visuo-gestuelle.



Figure 3 – **L'abbé de l'Épée instruisant ses élèves en présence de Louis XVI**, Gonzague Provat, 1875, Huile sur toile. Collection INJS, Paris.

ailleurs, certains chercheurs émettent même l'hypothèse que la communication gestuelle serait apparue avant la communication vocale [Sto01], comme peut le suggérer le comportement de certains primates.

La surdité a longtemps été considérée comme un signe de manque d'intelligence [Ber19]. Au 16^{ème} siècle, le moine bénédictin espagnol Pedro Ponce de Léon s'intéresse à l'éducation des sourds à partir de signes et se fait connaître en organisant des démonstrations publiques avec des enfants sourds. À la suite de son travail, Juan Pablo Bonnet [Bon91], publie un premier dictionnaire de dactylologie de Langue des Signes, associant chaque lettre à un signe manuel, attribuant ces signes à Saint Bonaventure.

Au 18^{ème} siècle, l'Abbé de l'Épée, prêtre catholique français est le premier à reconnaître que ce qui était jusque-là perçu comme de simples gestes constitue en réalité le véritable vecteur d'une langue : la langue des signes. Pour la première fois, il suggère l'utilisation des signes pour l'éducation des enfants sourds avec des résultats impressionnants. Son travail inédit et remarquable se diffuse dans le monde sous le nom de "méthode française" [dL76]. Il donne naissance à l'Institut National des Jeunes Sourds qui permettra aux enfants sourds de recevoir une éducation en langue des signes. Le regroupement d'enfants sourds, souvent issus de familles entendant, a favorisé le développement de nouveaux signes et a facilité la transmission orale. Cependant, deux siècles plus tard, lors du congrès de Milan qui s'est tenu en 1880, plusieurs pays, dont la France, décident d'interdire l'enseignement en Langue des Signes. L'enseignement oraliste, qui vise à utiliser la langue française pour l'enseignement des sourds, est privilégié, ce qui n'a pas fait disparaître la LSF mais qui a freiné son développement [Enc13]. Il a fallu attendre 1991 pour que l'interdiction de l'enseignement en LSF soit levée. En 2005, la LSF est reconnue comme langue à part entière. Enfin, en 2009, le ministère de l'éducation nationale a ouvert un CAPES

pour l'enseignement de la LSF [Ré05, DD13].

Les langues des signes à travers le Monde

Les langues des signes n'ont pas de système d'écriture contrairement à beaucoup d'autres langues, ce qui complique le travail des linguistes qui travaillent sur l'histoire de ces langues [Nyl01, Can16]. Cependant, l'observation des langues des signes actuelles et des recherches sur les déplacements de sourds ou de groupes de sourds permettent d'émettre des hypothèses sur la généalogie des langues des signes.

La langue des signes à laquelle l'abbé de l'Épée s'est intéressé autour de 1751 est souvent utilisée comme balise dans ce domaine sous le nom de *noétomalalien*, terme inventé par l'écrivain sourd Henri Gaillard et combinant les mots grecs "noéto" (intelligible) et "alalie" (sans parole). Cette langue des signes, observée et décrite pour la première fois à Paris, serait l'ancêtre de l'actuelle LSF mais aussi d'autres langues des signes, comme la langue des signes américaine (ASL) [Can16, PGL20]. Cette filiation s'explique par le rôle décisif dans l'instruction des sourds et l'enseignement en langue des signes qu'a joué l'université Gallaudet en 1817. En effet le co-fondateur de cette université Laurent Clair, ancien élève de l'école fondée par l'abbé de l'Épée, enseignait en LSF. On estime qu'environ 58% des signes de l'ASL sont des cognats de signes de la LSF [Bah96].

La figure 4 donne un aperçu des différentes familles de langues des signes dans le monde.

Particularités des langues des signes

Les langues des signes sont des langues visuo-gestuelles, comme l'illustre la figure 5. Elles s'appuient à la fois sur les gestes pour l'expression et sur la vision pour la compréhension. Les signes sont réalisés dans l'*espace de signation*, c'est à dire une zone autour du signeur qui correspond à la zone atteignable par les mains [BM12].

Un signe est une unité gestuelle qui peut s'appuyer sur un ou plusieurs articulateurs du corps humain pour exprimer une idée. Ces articulateurs ne comprennent pas seulement les mains mais aussi les lèvres, le regard, les sourcils, les joues, les épaules, le buste, etc. [Mil21]

Plusieurs équipes de linguistes ont cherché à établir une catégorisation des différents types de signes qui peuvent avoir des rôles grammaticaux différents [Mil21]. En guise d'exemple, la typologie de Johnston [JB16], qui est souvent utilisée dans le cadre de l'annotation de corpus comprend 6 types de signes :

- Les **signes lexicaux** sont des unités gestuelles très conventionnelles, tant par leur aspect que par leur signification. Les signes lexicaux peuvent être listés dans un dictionnaire.
- Les **signes illustratifs** ou **signes iconiques** sont des unités gestuelles qui intègrent des éléments conventionnels et non conventionnels. Ils sont fortement dépendants du contexte et ne peuvent être listés dans un dictionnaire. Ces signes s'appuient souvent sur le positionnement dans l'espace (*spatialisation*), et peuvent inclure des variations autour de signes lexicaux.
- Les **nom-signes**, un nom signe est un signe associé à une personne, il est connu dans son environnement afin de pouvoir la désigner sans avoir à épeler




Figure 4 - **Les grandes familles de langues des signes.** Figure issue de [PGL20]




Figure 5 - **La modalité visuo-gestuelle des langues des signes.** L'émetteur transmet un message en langue des signes à un récepteur qui regarde l'espace de signation. Illustration issue de [Gui06]

son nom d'état civil. Ils s'appuient souvent sur des caractéristiques distinctives d'une personne. Par exemple, le signe du président américain Donald Trump fait référence à son toupet.

- Les **balises** sont des postures de la main qui sont conservées pendant une partie de l'énoncé, usuellement par la main dominée, elles sont utilisées comme référence spatiale.
- Les **descripteurs de formes**, sont un ensemble de configurations gestuelles pouvant être utilisées pour décrire une forme dans l'espace (par exemple, représenter un rond ou une sphère).
- Les **pointages** consistent à pointer du doigt l'entité que l'on cherche à désigner. Il peut s'agir d'une personne (moi, toi), d'un objet, voire d'un concept abstrait qui aurait été placé auparavant dans l'espace de signation.

Comme le suggèrent ces différents types de signes, un énoncé en langue des signes ne se résume pas en une séquence de signes, il peut y avoir des phénomènes simultanés comme l'utilisation de balises ou des phénomènes spatiaux par le biais des signes illustratifs. On observe également des phénomènes linguistiques comme le *transfert personnel* qui permet d'incarner une personne, un animal ou un objet lors d'une conversation (fig. 6). Ces phénomènes propres aux langues des signes sont variés et ont été décrits par des linguistes [Cux00] avec des approches différentes selon le statut accordé à l'aspect illustratif.




Figure 6 – **Transfert personnel.** Le transfert personnel consiste à incarner une entité : personne, objet ou animal pour décrire une situation, raconter un évènement. Illustration issue de [VGLar]. Ici, le signeur incarne une fleur sur laquelle se pose une abeille (à gauche), courbée par la pluie (au centre), cueillie (à droite)

État de l'art

CHAPITRE 1

1.1	Introduction	32
1.2	Reconnaissance de signes isolés	33
1.2.1	Méthodes de reconnaissance d'actions basées sur les trames RGB	33
1.2.2	Méthodes de reconnaissance d'actions à partir de la pose humaine	34
1.2.3	Reconnaissance de signes isolés	36
1.3	Reconnaissance de signes en LS continue	37
1.3.1	Reconnaissance automatique de la parole	38
1.3.2	Reconnaissance de signes en contexte continu	38
1.4	Traduction	38
1.4.1	Un aperçu de la traduction des langues écrites	39
1.4.2	Traduction langue des signes vers langue écrite	43
1.4.3	Traduction langue écrite vers langue des signes	44
1.5	Segmentation temporelle des énoncés en Langue des Signes	45
1.6	Alignement	46
1.7	Autres tâches	47
1.8	Conclusion	47

1.1. Introduction

Dans ce chapitre, nous donnons un panorama des techniques et méthodes qui ont été mises au point pour le traitement automatique des langues des signes. Nous présenterons ensuite les principales tâches de ce domaine de recherche : reconnaissance et classification de signes, traduction de la langue des signes vers le texte ou du texte vers la langue des signes. Nous mettrons en lien ces différentes tâches avec des travaux menés dans des domaines de recherche connexes comme le traitement automatique des langues écrites, la reconnaissance de la parole ou la classification d'actions humaines à partir de vidéo.

Pour chacun des grands axes présentés, nous mettrons en exergue ce qui a été fait sur la LSF en particulier.

1.2. Reconnaissance de signes isolés

Dans le domaine du traitement automatique des langues des signes, la reconnaissance de signes isolés vise à prédire une classe à partir d'une vidéo contenant un unique signe. La classe correspond à une *glose*¹ [KFN15] ou à un mot en langue écrite [LROYL19, LZXP18]. Comme évoqué dans l'introduction de ce manuscrit, cette tâche de recherche peut avoir des applications concrètes comme la recherche d'information par signe, ou la reconnaissance de signes en temps réel (avec une webcam par exemple). La reconnaissance de signes isolés peut être mise en lien avec la classification d'actions humaines, une des tâches du domaine de la vision par ordinateur dont les applications sont multiples : surveillance, recherche d'informations, santé, sport... Nous allons présenter les grandes lignes des travaux existants dans ce domaine. Les méthodes proposées visent à prédire un label d'action à partir de trames d'une vidéo, c'est une tâche de classification.

En fonction de la nature des données qu'elles prennent en entrée, elles peuvent être divisées en deux catégories : les méthodes qui s'appuient sur les trames RGB brutes ou sur le flux optique, et les méthodes s'appuyant sur la pose humaine.

1.2.1. Méthodes de reconnaissance d'actions basées sur les trames RGB

Par définition, une vidéo est une succession d'images en 2 dimensions. On peut donc parler d'objets tridimensionnels : $2D + t$, où t est le temps. Ainsi, de nombreux travaux se sont consacrés à l'utilisation de convolutions 3D pour la classification de vidéos [TBF⁺15, CZ17, QYM17]. Les auteurs de [CZ17] ont montré qu'il était possible de tirer légèrement parti d'un pré-entraînement sur de la classification d'images puis de faire un affinage sur de la classification de vidéos (+0,2% d'*accuracy*).

Un des inconvénients des réseaux convolutifs est que le champ réceptif est limité par la taille du filtre de convolution [LNC⁺22]. Pour pallier ce problème, les auteurs de [WGGH18] ont proposé de s'appuyer sur l'auto-attention au sein des vidéos pour que leur modèle apprenne des liens spatio-temporels d'une trame à l'autre en considérant l'ensemble de la vidéo. Plus récemment, l'architecture *transformers*, initialement mise au point pour la traduction automatique de textes (sec. 1.4.1), a fait son apparition dans le domaine de la vision par ordinateur sous le nom de *vision transformer*, abrégé ViT, avec des résultats sans précédent pour la classification d'images [DBK⁺20, TCD⁺21] puis de vidéos. La section 1.4.1 détaillera cette architecture.

Les auteurs de Swin Transformer [LLC⁺21] étendent le principe du ViT avec une application sur des fenêtres de plusieurs tailles, permettant la prise en compte de l'image à plusieurs échelles. De nombreux travaux ont cherché à bénéficier des avancées offertes par le ViT et le *Swin Transformer* pour la classification de vidéos [ADH⁺21, FXM⁺21, LNC⁺22] en ajoutant la prise en compte de la dimension temporelle. Ces modèles ont permis l'obtention de meilleurs résultats, en terme de taux de reconnaissance, que les méthodes s'appuyant sur les réseaux convolutifs 3D

1. Les gloses sont des identifiants de formes de signes lexicaux. Ainsi, une glose peut correspondre à plusieurs significations, par exemple, le signe pour "bonjour" et le signe pour "merci", sont identiques, ils correspondront donc à une seule et même glose.




Figure 1.1 – **Vision Transformer**, figure issue de [DBK⁺20]. L'image d'entrée est divisée en patches de 16×16 pixels. Chacun d'entre eux est plongé de façon linéaire puis concaténé à un encodage positionnel puis la séquence obtenue est fournie en entrée d'un encodeur *transformer*.

pour les différents *benchmarks* de reconnaissance d'actions ².

Enfin, comme dans d'autres domaines de l'apprentissage profond, plusieurs travaux se sont concentrés sur les stratégies d'apprentissage. Les auteurs de BEVT [WCW⁺22] ont cherché à appliquer la méthode d'entraînement BERT (voir sec. 1.4.1) aux vidéos en masquant à la fois spatialement et temporellement les vidéos puis en entraînant le modèle à reconstruire les parties masquées. Les auteurs de VideoBERT [SMV⁺19] ont appliqué le même principe, sur le masquage temporel (masquage de trames) mais sans masquage spatial (de parties de l'image). En plus de cela, ils ajoutent conjointement un entraînement BERT sur le texte des vidéos. La méthode *InternVideo* [WLL⁺22, WLL⁺24] s'appuie sur le même principe mais sépare l'apprentissage sur la vidéo et l'apprentissage sur le texte, puis associe les deux avec un apprentissage par contraste entre la représentation du texte et celle de la vidéo associée.

En plus du masquage, VideoMAE [TSWW22] s'appuie sur une tâche de reconstruction pour l'apprentissage de représentation. Les résultats obtenus montrent que ces deux tâches conjointement utilisées comme pré-apprentissage permettent d'obtenir de meilleurs résultats que les méthodes énoncées précédemment.

Le tableau 1.1 donne un aperçu des résultats obtenus par ces différents types de méthodes sur le dataset Kinetics-400 [KCS⁺17].

1.2.2. Méthodes de reconnaissance d'actions à partir de la pose humaine

La pose humaine peut être vue comme une représentation compacte des mouvements, son principal défaut est qu'elle peut induire des erreurs ou de la perte d'information de façon plus ou moins importante en fonction de la technologie utilisée pour obtenir la pose. En 2024, des modèles de deep learning tel que Mediapipe [BGR⁺20] ou OpenPose [CHS⁺19] (fig. 1.2) sont très utilisés pour obtenir la pose humaine

2. <https://paperswithcode.com/task/action-recognition-in-videos>

Méthode	Type de réseau	Stratégie d'apprentissage	Acc@1
I3D [CZ17]	3D CNN	Pré-entraînement sur ImageNet-1K	71.1
BEVT [WCW ⁺ 22]	Video Swin Transformer [LNC ⁺ 22] avec masquage spatial et temporel	Pré-entraînement sur Kinetics 1K [KCS ⁺ 17] puis pré-entraînement BERT	80.6
Video Swin Transformer [LNC ⁺ 22]	Video Swin Transformer	Pré-entraîné sur ImageNet-21K	84.9
VideoMAE [TSWW22]	ViT	Masquage et Reconstruction puis affichage	87.4
InternVideo [WLL ⁺ 22]	UniformerV2 [LWH ⁺ 23]	(ViT) BERT sur la vidéo et sur le texte, puis apprentissage contrastif texte / vidéo (CLIP)	91.1

Table 1.1 – Quelques méthodes de reconnaissance d'actions humaines à partir de vidéos et le score d'*accuracy* sur le dataset Kinetics-400 [KCS⁺17]




Figure 1.2 – Exemple d'extraction de pose à l'aide d'OpenPose [CHS⁺19] sur une vidéo de langue des signes allemande (DGS) du corpus Phonenix-RT2014 [KFN15]. Image issue de [SCB21].

mais restent sujet à des erreurs de prédiction. Les dispositifs de *motion capture* sont plus précis mais peuvent quand même pâtir d'imprécisions dues à des occlusions ou à des problèmes de calibration. Il s'agit d'un dispositif plus contraignant (salle ou dispositif de captation dédié).

D'un point de vue théorique, ces poses humaines sont des graphes particuliers. En effet, ce sont des graphes de taille fixe : les sommets correspondent aux articulations et les arrêtes correspondent aux os qui relient ces articulations entre elles. Lorsque des articulations ne sont pas visibles, alors les sommets du graphe ne sont pas supprimés mais rendus nuls ou approximés (interpolation ou modèle appris). Les arrêtes relient toujours les mêmes points, par exemple, le poignet sera toujours relié au coude et jamais au genou. Ces graphes ont été représentés de différentes façons à travers la littérature : liste de points, graphe, liste d'angles, image [DZC⁺22]...

Une façon naturelle de traiter ces graphes est l'utilisation de réseaux convolutifs sur graphes (GCN), c'est à dire des réseaux s'appuyant sur des couches de convolution sur graphe (voir fig. 1.3). Leur usage est très répandu dans le domaine de la reconnaissance d'actions à partir de la pose humaine [CJH⁺21, SZW19, CZY⁺21, SZSW20] avec de bons résultats. À titre d'exemple les auteurs de [LLLL23] obtiennent un score d'*accuracy* de 93,4% sur le dataset NTU RGB-D [SLNW16].

D'autres méthodes traitent les poses humaines à partir de réseaux convolutifs classiques. Le graphe est représenté sous la forme d'une matrice en 2 ou 3 dimensions




Figure 1.3 – Principe de la convolution sur graphe, figure issue de [KW16]. Le graphe en entrée contient C canaux et le graphe de sortie contient F caractéristiques. La structure du graphe est partagée entre les couches, Y_i correspond aux labels des nœuds.

de façon à pouvoir appliquer des filtres de convolution classiques. Par exemple, on peut représenter la pose comme une liste de points [LZXP18, DFW15, KBA⁺17]. On obtient alors une matrice de dimensions $T \times P \times C$ où l'axe T correspond aux différentes trames, l'axe P correspond aux différents points et l'axe C correspond aux coordonnées. Ces approches obtiennent de moins bons résultats que les approches à base de graphes pour la reconnaissance d'actions à partir de la pose [CSB⁺19].

1.2.3. Reconnaissance de signes isolés

Les modèles de reconnaissance de signes isolés s'appuient principalement sur les modèles utilisés en reconnaissance d'actions humaines comme I3D [CZ17, LROYL19, MGI⁺21, AVM⁺20] sur les pixels, ou ST-GCN [WZA22, MGI⁺21] sur les poses humaines. De façon similaire à ce qui a été fait en reconnaissance d'actions, certaines méthodes de reconnaissance de signes isolés ont cherché à tirer profit des deux types d'approches de façon conjointe [MGI⁺21]. Si la reconnaissance d'actions humaines et la reconnaissance de signes présentent de nombreuses similarités (humain, mouvement), il faut noter quelques différences : les mouvements utilisés en langues des signes sont cantonnés à l'espace de signation, et l'utilisation des mains et du visage est beaucoup plus fine chez les différentes langues des signes que sur les actions référencées dans les corpus de reconnaissance d'actions. Pour prendre en compte ces spécificités, certaines méthodes donnent plus d'importance à ces articulateurs [MGI⁺21, SZY24] et montrent que cela conduit à une (légère) amélioration des performances (entre 0 et 3% d'*accuracy* supplémentaire).

Toujours dans le sillon des travaux du domaine de la reconnaissance d'actions, certains travaux ont cherché à appliquer un pré-entraînement BERT [DCLT19] sur la pose des signeurs [TNW20, HZgZ⁺21, HZZL23]. Les auteurs montrent que ce pré-entraînement BERT permet une amélioration des performances. Le masquage se fait soit de façon temporelle (sur les trames ou des ensembles de trames), ou de façon spatiale (à l'échelle des points), ou le cumul de ces stratégies [HZZL23]. Le tableau 1.2 donne un aperçu des résultats obtenus par différentes méthodes de reconnaissance de signes isolés sur le dataset de langue des signes américaine WLASL [LROYL19]. On peut supposer que ce type de pré-entraînement permet aux modèles de mieux comprendre les liens qui lient les trames d'un signe ou qui lient les articulations entre-elles.

Table 1.2 – **Top-1 accuracy pour différentes méthodes de reconnaissance de signes isolés sur le dataset WLASL [LROYL19]**. Tableau issu de [HZZL23]

Method	WLASL100		WLASL300		WLASL	
	Top-1	Top-5	Top-1	Top-5	Top-1	Top-5
Pose-based						
ST-GCN [YXL18]	50.78	79.07	44.46	73.05	34.40	66.57
Pose-TGCN [LROYL19]	55.43	78.68	38.32	67.51	23.65	51.75
PSLR [TNW20]	60.15	83.98	42.18	71.71	-	-
SignBERT [HZgZ ⁺ 21]	76.36	91.09	62.72	85.18	39.40	73.35
SignBERT+ [HZZL23]	79.84	92.64	73.20	90.42	48.85	82.48
RGB-based						
I3D [LROYL19]	65.89	84.11	56.14	79.94	32.48	57.31
HMA [HZL21]	-	-	-	-	37.91	71.26
TCK [LRYL20]	77.52	91.08	68.56	89.52	-	-
BSL [AVM ⁺ 20]	-	-	-	-	46.82	79.36
SignBERT [HZgZ ⁺ 21]	82.56	94.96	74.40	91.32	54.69	87.49
SignBERT+ [HZZL23]	84.11	96.51	78.44	94.31	55.59	89.37

Reconnaissance de signes isolés en LSF

Aucune méthode de reconnaissance de signes isolés n'a été appliquée sur la LSF à ce jour.

1.3. Reconnaissance de signes en LS continue

Alors que les signes isolés sont réalisés hors contexte, de façon nette et cano- nique, sans transition avec d'autres signes, les signes dans un contexte continu, c'est à dire au sein d'un énoncé en langue des signes, sont susceptibles d'être déformés (co-articulation), signés plus rapidement, adaptés à une situation, etc. [Seg09]. De fait, sans adaptation, un modèle entraîné sur des signes isolés ne sera pas adapté à reconnaître des signes dans un contexte continu. On peut distinguer deux types de travaux sur la reconnaissance de signes en contexte continu :

- la classification de signes continus, séparés de leur contexte. Il s'agit alors des mêmes méthodes que celles utilisées dans la section précédente à ceci près qu'elles sont appliquées sur des corpus où les signes ont été extraits d'énoncés continus³.
- la reconnaissance de signes continus en contexte, il s'agit alors de reconnaître des signes dans une vidéo contenant plusieurs signes. Le modèle est alors susceptible de rencontrer des signes en dehors du vocabulaire, ou des signes non-lexicaux, qui ne pourront pas être reconnus.

3. Les signes sont alors plus courts et les modèles prennent alors des séquences d'entrée plus courtes (autour de 16 trames).

Dans cette section nous allons développer le second scénario, en commençant par nous appuyer sur le domaine de la reconnaissance de la parole qui a beaucoup inspiré les travaux de reconnaissance de signes en contexte continu.

1.3.1. Reconnaissance automatique de la parole

Dans le domaine de la reconnaissance de la parole (ASR), de nombreuses méthodes ont été développées pour passer d'un flux de parole audio à une liste de mots écrits. Ce qui est assez proche du paradigme de la reconnaissance de signes en flux continu⁴. L'ASR partage de nombreux points communs avec les réseaux séquences à séquences utilisés pour la traduction (sec. 1.4) : RNN, *transformers*.

Une autre caractéristique des réseaux utilisés pour l'ASR est l'utilisation de fonction de *Classification Temporelle Connectioniste* (CTC) [GFGS06] pour conditionner la sortie, ce qui permet d'entraîner des modèles de reconnaissance sans requérir d'annotations temporelles des phonèmes ou des mots dans la séquence.

Les méthodes d'ASR représentent généralement la parole comme des matrices de deux dimensions (spectrogramme MEL, MFCC) [HBT⁺21]. Pour pouvoir appliquer des modèles de type BERT sur de la parole en vue de pré-entraîner des modèles d'ASR, les auteurs de la méthode HuBERT [HBT⁺21] s'appuient sur des pseudos labels d'unités acoustiques obtenus à l'aide d'un simple clustering (K-Moyennes) sur ces caractéristiques. Le modèle doit réussir à prédire les labels de clusters correspondant aux trames masquées. Avec ce pré-entraînement les auteurs montrent une amélioration des résultats sans besoin de labels : -1% de taux d'erreur par mot (Word Error Rate, WER) en comparaison avec les méthodes supervisées [HBT⁺21].

1.3.2. Reconnaissance de signes en contexte continu

Les travaux portant sur la reconnaissance de signes au sein d'énoncés continus s'appuient sur des méthodes similaires à celles utilisées pour la reconnaissance de la parole [CYCT20, ZZZL20]. Le flux de langue des signes passe à travers un encodeur visuel qui extrait des caractéristiques qui sont ensuite transmises à des couches récurrentes, une fonction de coût CTC [GFGS06] permet l'apprentissage en tenant compte des potentielles insertions, substitutions et délétions.

Reconnaissance de signes en flux continu de LSF

À ce jour, il n'existe pas de méthode portant sur la reconnaissance de signes en flux continu en LSF à partir de vidéos.

1.4. Traduction

Le terme de traduction automatique des langues des signes peut englober un large éventail de modalités : d'une langue des signes vers une autre, d'une langue des

4. Si l'on met de côté les caractéristiques d'entrée, et le faible nombre de classes de sortie (phonèmes).




Figure 1.4 – **Deuxième machine à traduire de Georges Artsrouni** [Dau65]. Il s'agit en réalité d'une sorte de dictionnaire, la saisie d'un mot en français se fait à partir des 23 touches de machine à écrire, et le résultat en anglais est affiché à l'aide de voyants lumineux.

signes vers de la langue parlée, d'une langue des signes vers une langue écrite, d'une langue écrite vers une langue des signes, etc. La plupart des travaux publiés à ce jour se concentrent sur la modalité langue des signes vers texte même s'il existe quelques travaux s'intéressant à d'autres modalités.

Dans cette section nous donnerons un aperçu des travaux portant sur la traduction des langues écrites puis nous présenterons les travaux menés sur les langues des signes pour les deux modalités les plus explorées : d'une langue des signes vers une langue écrite, et d'une langue écrite vers une langue des signes.

1.4.1. Un aperçu de la traduction des langues écrites

Les premiers modèles de traduction automatique ont vu le jour dans le domaine du traitement automatique du langage naturel pour les langues écrites dès la fin des années 1930 [HL00, GA18]. Il s'agissait alors de modèles mécaniques [HL00, Dau65], la figure 1.4 montre une machine à traduire de l'inventeur Franco-Arménien Georges Artsrouni [Dau65]. Dès les années 1940, les machines de calculs, sont proposées pour la traduction automatique [HL00]. Les premières méthodes s'appuyaient sur des systèmes à base de règles [HL00], elles ont ensuite été remplacées par les méthodes à base d'exemples qui sont devenues les méthodes statistiques dans les années 1980. L'arrivée des réseaux de neurones a révolutionné la recherche dans le domaine en permettant l'obtention de résultats jusqu'alors inédits.

Formalisation du problème de traduction

Les méthodes statistiques de traduction automatique reposent sur la probabilité d'une phrase dans une langue cible y sachant une phrase dans une langue source




Figure 1.5 – Architecture Encodeur / Décodeur pour la traduction automatique.

$\mathbf{x}$, c'est à dire $P(\mathbf{y}|\mathbf{x})$. La phrase dans la langue source $\mathbf{x}$ est composée de *tokens*⁵ $x_1, x_2, \dots, x_i$ et la phrase dans la langue cible également : $y_1, y_2, \dots, y_j$. La plupart des méthodes de traduction sont auto-régressives : les *tokens* de la phrase cible sont traduits un par un en s'appuyant à la fois sur la phrase source $\mathbf{x}$ et sur les *tokens* déjà prédits de la phrase cible $y_1, y_2, \dots, y_{t-1}$. Ce qui peut être résumé par l'équation suivante :

$$P(\mathbf{y}|\mathbf{x}) = \prod_{t=1}^J P(y_t | y_1, y_2, \dots, y_{t-1}, \mathbf{x})$$

La plupart des méthodes suivent une architecture encodeur / décodeur : la partie encodeur extrait une représentation de la langue source et la partie décodeur génère du texte de langue cible, un *token* à la fois en s'appuyant sur la langue source et les précédents *tokens* prédits. La figure 1.5 illustre ce principe.

Réseaux de neurones récurrents (RNN)

En 2014, plusieurs équipes de chercheurs ont présenté les premiers réseaux récurrents [CvMG⁺14, SVL14]. Les réseaux récurrents traitent les séquences élément par élément en mémorisant une partie de l'information et en oubliant une autre partie. Ce mécanisme a montré de bons résultats pour la traduction de phrases courtes mais reste limité pour la traduction de phrases longues. Bahdanau et al. [BCB14] ont proposé une solution à ce problème en présentant le mécanisme d'attention : à chaque étape de décodage, le modèle se concentre sur certains mots en particulier de la séquence source pour générer une représentation intermédiaire pertinente lui permettant de décoder le *token* courant. La figure 1.6 issue de [BCB14] donne un exemple de carte d'attention dans le contexte de la traduction anglais vers français.

Transformers

L'architecture du *transformer*, proposée par Vaswani et al. en 2017 [VSP⁺17], repose sur une extension du mécanisme d'attention, appelée attention multi-têtes, pour remplacer les couches récurrentes traditionnellement utilisées dans les réseaux de type RNN ou LSTM. Contrairement à ces approches, où les phrases d'entrée sont traitées de manière séquentielle, le *Transformer* effectue un traitement entièrement parallèle, accélérant ainsi considérablement les calculs. Chaque token de la séquence

5. Un *token* est un segment de texte correspondant souvent à un mot mais pouvant correspondre à des unités plus petites (syllabe, caractère) ou plus grandes (locutions).




Figure 1.6 – **Carte d'attention obtenue dans le cadre de la traduction anglais vers français.** Les points clairs indiquent un haut niveau d'attention.




Figure 1.7 – **Modules Transformer encodeur et décodeur.** Illustration issue de [VSP⁺17]

d'entrée est enrichi par un encodage positionnel, permettant de conserver une notion d'ordre malgré l'absence de dépendance temporelle.

Le *transformer* fonctionne à travers deux blocs principaux : l'encodeur et le décodeur, qui échangent des informations via les mécanismes d'attention. L'encodeur traite l'ensemble de la séquence d'entrée en calculant des poids d'attention qui déterminent l'importance relative de chaque mot dans le contexte global. De son côté, le décodeur génère la séquence de sortie en prenant en compte non seulement les informations traitées par l'encodeur, mais aussi celles qu'il a déjà produites, grâce à un mécanisme d'*attention causale*. La figure 1.7 donne un aperçu des modules encodeur et décodeur du *transformer*.

Cette architecture a démontré des performances supérieures aux méthodes précédentes dans les tâches de traduction automatique, avec un entraînement plus rapide et moins coûteux en ressources de calcul. Grâce à son efficacité, le *transformer* est devenu l'architecture de référence pour la traduction automatique et d'autres tâches de traitement du langage naturel.

Grands modèles de langage

L'architecture *transformer* a également permis de grandes avancées pour les tâches monolingues (réponses à des questions, prédiction de la phrase suivante) grâce au modèle BERT [DCLT19], qui permet l'apprentissage de représentations sémantiques en cherchant à prédire des *tokens* masqués en fonction du contexte de la phrase (*tokens* qui précèdent et *tokens* qui succèdent). Les auteurs de mBART [LGG⁺20] ont cherché à tirer profit de ce type de pré-entraînement pour la traduction, en initialisant leur modèle encodeur/décodeur sur des tâches monolingues : la permutation de phrases et la prédiction de *tokens* masqués.

Modèles génératifs

En parallèle des modèles de types BERT, adaptés pour l'obtention de représentations sémantiques, des modèles dit "génératifs" ont vu le jour à l'image de GPT [RNS⁺18]. Plus adaptés à la génération de texte, ils s'appuient sur un pré-entraînement sur de très grosses bases de données, la fin d'un texte est masqué et le modèle doit apprendre à prédire la suite en tenant compte du début. Appliqué à de très grandes quantités de texte et une grande variété de tâches, les modèles de type GPT sont capables de résoudre un très grand nombre de tâches : réponses à des questions, rédaction de texte, code... Certains travaux ont montré que ce type de modèles peut servir pour des tâches de traduction, bien qu'étant moins performants que les modèles à base de *transformers* [KAB⁺23].

Back-translation ou traduction inverse

Dans la grande majorité des scénarios, l'entraînement de modèles de traduction nécessite des données bilingues. Or, parfois, les données bilingues sont de quantité réduite alors qu'il existe des données monolingues dans la langue source en plus grande quantité. Le concept de *back-translation* [SHB16, EOAG18] ou traduction inverse consiste à utiliser un premier modèle de traduction, entraîné sur un corpus bilingue pour obtenir une pseudo-traduction sur les données monolingues. Cela




Figure 1.8 – **Pipeline classique de traduction automatique d'une langue des signes vers une langue écrite.** La partie encodeur prend en entrée des caractéristiques extraites à partir des vidéos de langue des signes et la partie décodeur auto-régressive prédit les futurs *tokens* en fonction des précédents.

permet ensuite d'entraîner un deuxième modèle en utilisant en plus des données bilingues existantes, les données monolingues et leur pseudo-traduction (on parle de *données bilingues synthétiques*). L'utilisation de ces données supplémentaires permet une amélioration des résultats en traduction sur des données réelles, par exemple, les auteurs de [HKHC18] obtiennent une amélioration du score BLEU de 5,4 points, passant de 16,7 à 22,1 pour la traduction de l'Anglais vers le Français.

Transfert entre langues

Certains travaux ont montré que les scénarios d'entraînements multilingues permettaient d'améliorer les résultats de traduction entre deux langues, et ce en particulier dans le cas des langues peu dotées grâce au phénomène de transfert de connaissances entre les langues [ABHS20, DCK20, LGG⁺20]. Le transfert de connaissance fonctionnerait mieux quand les langues appartiennent à la même famille linguistique.

1.4.2. Traduction langue des signes vers langue écrite

La traduction automatique des langues des signes vers des langues écrites a émergé à la fin des années 2010 à la suite des grandes avancées qui avaient eu lieu dans le domaine de la traduction des langues écrites. Le premier corpus connu de langue des signes traduit dans une langue vocale est le corpus Phoenix2014-RTHW-Weather [KFN15] paru en 2014, un corpus de langue des signes allemande (DGS) interprétée traduite en Allemand sous forme de texte. Sa mise à disposition a permis l'émergence de premières méthodes de traduction automatique en 2018 [CHK⁺18, KWSS18]. Comme pour les langues écrites, les méthodes de traduction automatique des langues des signes s'appuient sur des réseaux séquences à séquences classiques d'abord à base de RNN [CHK⁺18] puis de *transformers* [YR20, CKHB20b].

La figure 1.8 donne un aperçu de l'architecture classique des modèles de traduction de langues des signes vers du texte. En entrée du modèle séquences à séquences, la langue des signes est représentée sous-forme de séries de caractéristiques [TGD⁺23, CHK⁺18, CKHB20b]. Ces caractéristiques sont obtenues à l'aide d'un encodeur gelé ou non. Cet encodeur est dans la vaste majorité des cas emprunté

au domaine de la vision par ordinateur. Ces modèles de vision par ordinateur, originellement utilisés pour de la classification d'images sur ImageNet [DDS⁺09] ou d'action humaines sur Kinetics [KCS⁺17], sont ensuite affinés sur de la langue des signes, pour de la classification de signes isolés ou directement dans le cadre de l'entraînement du modèle de traduction [CHK⁺18].

En sortie du modèle, on attend du texte, sous-forme de *tokens*, pouvant être des mots ou des sous-unités de mots en fonction des méthodes. La méthode proposée par les auteurs de [TGD⁺23] a la particularité d'entraîner le modèle de traduction de la langue des signes américaine vers des phrases en anglais sans majuscules, les majuscules sont prédites dans un second temps avec un modèle dédié [LIRK03].

L'annotation en gloses du corpus Phoenix2014-RTWH-Weather et le type de langue des signes utilisée⁶ dans ce même corpus ont conduit un grand nombre de travaux de recherche à s'intéresser à l'utilisation de gloses pour aider la traduction [YR20, CHK⁺18, CKHB20b]. D'après les auteurs de [CKHB20b], l'utilisation de gloses pour guider les représentations intermédiaires du modèle de traduction permet d'améliorer le score BLEU [PRWZ02] de 8%.

L'émergence de nouveaux corpus de plus grande taille, non annotés en gloses [AVM⁺21, DPV⁺21] a conduit peu à peu à l'abandon de l'utilisation de ce type d'annotation coûteux dans les modèles de traduction pour revenir à des architectures *transformer* classiques [TGD⁺23, AVM⁺21, ZCC⁺23].

Traduction automatique de la LSF vers le Français

Aucune méthode de traduction automatique n'a été appliquée sur la LSF pour le moment, ni vers le Français. Cela peut s'expliquer par l'absence de corpus traduit de taille suffisante en LSF.

1.4.3. Traduction langue écrite vers langue des signes

La traduction d'une langue écrite vers une langue des signes [SCB20b, SCHB20] est un autre domaine de recherche du traitement automatique des langues des signes. Il s'agit alors de générer un énoncé en langue des signes à partir d'un énoncé en langue

6. Il s'agit de langue des signes interprétée, plutôt formelle (télévision) donc un usage plus important de signes lexicaux, et moins d'iconicité



Figure 1.9 – **Exemple de pipeline de traduction texte vers langue des signes** sur le corpus de langue des signes allemande PHOENIX-RT-2014 [KFN15] issu de [SCB20a].

écrite. La langue des signes est produite à travers l'animation d'un avatar, la génération d'une séquence de poses humaines [SCB20b] ou la génération d'une vidéo photo-réaliste [SCHB20]. De façon similaire à ce qui s'est fait dans le domaine de la traduction, les premiers travaux s'appuyaient principalement sur des systèmes à base de règles (HamNoSys [KK14], Azee [FHC14], SiGML [EGJK04]), qui ont principalement laissé place à des systèmes bout à bout basé sur des réseaux séquence à séquence [SCB20b]. Les systèmes à base de règles ont souvent un domaine limité car ils s'appuient sur des signes pré-enregistrés ou pré-définis qui sont ensuite concaténés de façon à produire un énoncé. Les signes sont enregistrés avec un dispositif de motion capture, ou alors ils sont paramétrisés par des animateurs 3D ou des linguistes [FHC14].

Les réseaux de neurones bout-à-bout cherchant à s'affranchir de l'utilisation d'un dictionnaire de signes ne sont pour l'instant pas suffisamment précis dans la génération de mouvements ou de configuration de main [SCB20b, SCHB20] mais les modèles sont de plus en plus performants [BPV⁺24]⁷. La figure 1.9 donne un exemple de pipeline de traduction texte vers langue des signes [SCB20a]. Une alternative aux réseaux bout-à-bout est les réseaux qui se décomposent en génération de texte vers des gloses puis des gloses vers des signes en contexte [SCB22], le modèle s'appuie sur un dictionnaire pour établir les correspondances gloses-signes [SCB22].

Traduction automatique du français écrit vers la LSF

La traduction du français écrit vers la LSF a fait l'objet de plusieurs travaux : d'abord avec des approches à base de règles [Ker11, FHC14], puis à base d'exemples [BLBC⁺23, Nae20]. Il n'existe pas encore de méthode à base d'apprentissage profond, les corpus existants jusque là étant de trop petite taille.

1.5. Segmentation temporelle des énoncés en Langue des Signes

La plupart des méthodes énoncées précédemment [TGD⁺23, AVM⁺21] s'appliquent sur des phrases de langues des signes ou des signes individuels. Cependant, souvent, les enregistrements vidéo de langues des signes continue contiennent plusieurs signes et plusieurs phrases. Il est donc nécessaire de passer préalablement par une étape de segmentation temporelle, que ce soit en portions équivalentes aux phrases, ou plus finement en signes. Dans le meilleur des cas, il existe des traductions en langue écrite alignées temporellement à la langue des signes, ce qui permet de redécouper la langue des signes en s'appuyant sur les temps de début et de fin de ces traductions en langue écrite, on obtient alors des vidéos s'apparentant à des phrases en langue des signes [BBG20b, OBG⁺24]. Le même raisonnement est possible pour la segmentation en signes lorsqu'on a à disposition des annotations en signes alignées temporellement (début, fin) [BBG20a, KFN15, FPMC21]. Parfois de telles annotations n'existent pas, rendant alors compliquée toute tâche d'analyse, que ce soit la reconnaissance, la classification, la traduction.

7. La vidéo à l'adresse <https://youtu.be/u89bnprj46Q?si=i-PbjuE8p9z7Z1Jq> donne des exemples de génération de langue des signes américaine à partir de texte en Anglais




Figure 1.10 – **Le problème d'alignement des sous-titres avec l'interprétation en LS.** La ligne S_{audio} correspond à l'alignement original, sur l'audio et la ligne S_{GT} , correspond à un alignement ajusté à la langue des signes. Figure issue de [BAV⁺21]

Certains travaux ont cherché à résoudre ce problème en s'appuyant sur des corpus segmentés pour entraîner des modèles de segmentation [BGB20, MJM⁺23, BAV⁺21]. Des études linguistiques montrent en effet que la prosodie des langues des signes permet d'identifier des débuts et fins phrases [San10, OC12], par exemple en maintenant la configuration du dernier signe [San10]. Par conséquent, les auteurs de [MJM⁺23, BAV⁺21] ont mis au point des heuristiques basés notamment sur les pauses dans la signation pour détecter des segments. Ces mêmes auteurs montrent que les méthodes apprises à l'aide d'algorithmes d'apprentissage profond permettent une amélioration des résultats de l'ordre de 10% par rapport aux heuristiques, avec des scores F1 de l'ordre de 85%. On peut en déduire que les méthodes d'apprentissage profond permettent d'obtenir une segmentation automatique de qualité.

Segmentation de la LSF

Une méthode de segmentation automatique de la LSF a été proposée par [BGB20] avec de bons résultats sur le corpus Mediapi-Skel [BGB20b].

1.6. Alignement

L'alignement consiste à aligner temporellement des annotations existantes (une traduction par exemple), avec le flux vidéo de langue des signes, cela revient à assigner un temps de début et de fin à chaque annotation.

La recherche en traitement automatique des langues des signes s'est largement appuyée sur des corpus issus d'émissions de télévision interprétées en langue des signes. Les sous-titres de l'émission sont utilisés comme pseudo traductions de la langue des signes produite par les interprètes. Une des limitations de ce type de données est qu'elles nécessitent une étape d'alignement préalable : en effet, les sous-titres sont alignés avec la parole et non avec l'interprétation en langue des signes. Le délai et parfois l'ordre d'interprétation étant variables, la tâche d'alignement nécessite bien souvent une intervention manuelle de personnes bilingues. La figure 1.10 donne un aperçu de ce problème sur une vidéo issue du corpus BOBSL [AVM⁺21]. Pour pallier cette difficulté, certains travaux se sont intéressés à l'alignement automatique des sous-titres en langue vocale et de la langue des signes [BAV⁺21, MJM⁺23, BGB20]. On peut distinguer deux types de méthodes : celles qui segmentent l'énoncé en LS puis qui associent le segment à un sous-titre [MJM⁺23, BGB20], et les méthodes




Figure 1.11 – **Recherche d'information dans des vidéos de langue des signes** américaine à partir d'une requête textuelle. Figure issue de [DAGiNV22].

qui s'appuient à la fois sur les sous-titres et les trames et qui cherchent à générer des temps de début et de fin de sous-titre [BAV⁺21]. Les deux types d'approches semblent donner des résultats similaires [MJM⁺23], dans les deux cas, l'alignement semble fonctionner sur les exemples donnés par les auteurs de [BAV⁺21, MJM⁺23].

1.7. Autres tâches

Si la plupart des travaux en traitement automatique des langues des signes ont eu trait à la traduction et la reconnaissance de signes, ou des tâches connexes pour la préparation des données (segmentation, alignement), certains auteurs se sont intéressés à d'autres aspects. Par exemple, les auteurs de [DAGiNV22] se sont focalisés sur la recherche d'information dans des vidéos de langue des signes américaine à partir de requêtes textuelles. La figure 1.11 donne un aperçu de l'objectif des auteurs.

Belissen et al. [Bel20] se sont intéressés à la classification de signes en LSF selon leur type (balise, signe lexical, signe illustratif, etc.) dans un flux continu.

Comme nous l'avons vu dans la section 1.4, l'utilisation de gloses pour aider la traduction d'une langue des signes vers une langue vocale est un usage répandu. Ces annotation en gloses étant très coûteuses en temps et en expertise les auteurs de [CGB21, MBP⁺22] ont proposé des méthodes d'annotation automatique ou semi-automatique [LGBD24a] en s'appuyant sur des heuristiques et des caractéristiques issues de modèles d'apprentissage profond.

1.8. Conclusion

Dans ce chapitre nous nous sommes intéressés aux différentes tâches du traitement automatique des langues des signes, nous avons vu différents travaux existant et nous avons évoqué des parallèles avec d'autres domaines de recherche : la traduction des langues écrites, la reconnaissance de la parole et la classification d'actions humaines à partir de vidéos.

Nous avons montré que la LSF a fait l'objet d'aucun travaux de reconnaissance automatique de signes isolés ou dans un contexte continu, il n'y a pas non plus de travaux de traduction automatique de la LSF vers une langue écrite. Une des raisons qui peut expliquer ces constats est le peu de données existantes à disposition des chercheurs sur la LSF. Or, comme expliqué en introduction de ce chapitre, le traitement automatique de la LSF est un enjeu important pour permettre aux sourds signants de bénéficier des avancées technologiques récentes. Pour tenter de répondre à ce problème, nous avons au cours de cette thèse mis à disposition deux nouveaux corpus de LSF, et proposé des méthodes de reconnaissance de signes isolés et en contexte continu. Et enfin, nous avons posé les prémisses de la traduction automatique de la LSF à travers de premières méthodes.

Nouveaux corpus pour le traitement automatique de la LSF

2.1	Introduction	50
2.2	Typologie des corpus de LS	50
2.2.1	Sources	50
2.2.2	Annotation	52
2.3	Corpus existants	54
2.3.1	À l'international	55
2.3.2	En LSF	57
2.3.3	Conclusion	60
2.4	Matignon-LSF	60
2.4.1	Collecte des données	61
2.4.2	Description du corpus	62
2.4.3	Limitations	64
2.4.4	Perspectives	64
2.4.5	Conclusion	65
2.5	Mediapi-RGB	65
2.5.1	Description du corpus	66
2.5.2	Limitations	69
2.5.3	Perspectives	69
2.5.4	Conclusion	70
2.6	Synthèse	70

2.1. Introduction

La pierre angulaire de l'utilisation de méthodes d'apprentissage profond reste encore la disponibilité de données en grande quantité. Dans le domaine du traitement automatique des langues écrites, des avancées majeures ont été rendues possibles grâce aux immenses quantités de texte disponibles librement sur Internet depuis deux décennies [RSR⁺20, AORS22]. Ces avancées se font de façon déséquilibrée d'une langue à l'autre, en écho aux déséquilibres linguistiques et économiques. On parle de langue peu dotée pour évoquer les langues pour lesquelles on dispose de peu de données numériques. Une langue peut être peu dotée pour plusieurs raisons : parce qu'il y a peu de locuteurs, parce que c'est une langue orale ou encore parce que c'est une langue qui n'est pas utilisée à la télévision ou dans la presse. La quantité de données qui sépare une langue dotée d'une langue peu dotée n'est pas définie.

Dans le cas de la LSF, il existe de nombreuses sources informatisées de données, principalement issues d'émissions de télévision, mais aussi de dictionnaires en ligne, de lexiques, etc. Cependant la plupart de ces ressources ne sont pas libres de droit et ne peuvent être utilisées en l'état par les chercheurs sans accord des ayants droit. La négociation d'un accord avec une société de production est un processus long et complexe. Idéalement, les données utilisées dans un travail de recherche doivent pouvoir être accessibles à d'autres chercheurs afin que les expériences soient reproductibles et vérifiables, ce qui complique les négociations car les ayants droit souhaitent souvent garder la main sur la diffusion de leurs données. Ainsi, même si les ressources informatisées de LSF sont relativement importantes en comparaison avec d'autres langues signées ou vocales, la LSF reste souvent qualifiée de langue peu dotée car peu de ces données sont utilisables pour des travaux de recherche en traitement automatique du fait des contraintes légales.

Dans ce chapitre, nous passerons en revue les différentes sources de corpus et les éventuels biais qu'elles peuvent induire, puis nous dresserons un état des lieux des corpus existants pour la LSF et les autres langues des signes. Enfin, nous présenterons les deux corpus développés au cours de cette thèse : Mediapi-RGB [BBG20b] en collaboration avec Hannah Bull [OBG⁺24] et Matignon-LSF [HFO⁺24] en collaboration avec Julie Halbout, Julie Lascar et Diandra Fabre.

2.2. Typologie des corpus de LS

La diversité des corpus de langue des signes s'explique par la grande variété des études linguistiques ou informatiques portant sur ces langues. Dans cette section nous donnons un aperçu des grands types de corpus.

2.2.1. Sources

Une façon de classer les corpus est de s'appuyer sur leur source, c'est à dire la façon dont ils ont été collectés. On peut classer ces sources en trois catégories : les données de laboratoire, les données de la télévision, et les données issues d'Internet.



Figure 2.1 – Photo prise lors de l'enregistrement du corpus Mocap1 [5]



Figure 2.2 – Enregistrement de gestes bimanuels à l'aide d'un gant numérique. Image issue de [Bos06]

Données de laboratoire

Avant le développement de l'apprentissage automatique et son besoin de données en très grande quantité, les chercheurs en traitement automatique des langues des signes s'appuyaient très largement sur des données collectées en laboratoire [BBG20a, eBBB16]. L'enregistrement d'un corpus en laboratoire comporte de nombreuses variables. Tout d'abord quoi enregistrer? Certains corpus s'appuient sur des phrases définies qui sont répétées par plusieurs signeurs. D'autres à l'opposé cherchent à enregistrer des conversations spontanées à l'aide de stratégies d'élicitation. Les corpus peuvent avoir un thème plus ou moins large comme KETI [KKJC19], un corpus coréen qui porte sur les situations d'urgence ou DictaSign qui porte sur les transports et les voyages [BBG20a]. Ensuite, qui enregistrer? Des signeurs sourds issus de famille entendante? Des signeurs sourds ou non issus de familles sourdes? Des interprètes en langues des signes? [Bra16] Ensuite comment? Avec des caméras, du tracking optique, des gants numériques? Ce sont quelques-unes des questions qui entrent en jeu lors de la constitution des corpus de laboratoire, ce qui explique leur grande diversité.

Ces corpus ont comme point commun qu'ils sont complexes et coûteux à constituer, ce qui a pour conséquence qu'ils soient souvent de taille plus limitée¹ que des corpus issus de la télévision ou du web.

Dispositifs de captation

Il existe tout un éventail de technologies de captation pouvant être utilisées en laboratoire : gants numériques [Bra96] (fig. 2.1), caméras de profondeurs [RTM⁺23], motion capture [eBBB16] (fig. 2.2). Avec sa simplicité et son faible coût, la vidéo reste le mode de captation le plus populaire [DPV⁺21, BBG20a, DRD⁺07].

Données de télévision

Les corpus issus de données de télévision correspondent quasi-exclusivement à des émissions initialement en langue vocale qui sont interprétées en LS en direct ou

1. À l'exception de gros corpus de nature patrimoniale financés par les gouvernements [SFR⁺13, KHL⁺20]

non [KFN15, AVM⁺21, HFO⁺24]. C'est le type de données le plus répandu du fait de la quantité croissante de contenu interprété à la télévision dans de nombreux pays. Ces émissions peuvent traiter une grande variété de sujets. Souvent, le discours source, en langue vocale, est sous-titré en plus d'être interprété. Les sous-titres sont ainsi utilisés comme annotation.

Cependant ce type de données comprend plusieurs limites :

- Les sous-titres de la langue vocale et l'interprétation ne sont pas alignés dans le temps.
- Le processus d'interprétation peut passer par le résumé, la synthèse, des ajouts ou suppressions d'information pour faciliter la compréhension du public cible. Le contenu des sous-titres ne correspondra pas nécessairement de manière précise au contenu de l'interprétation en LS. D'autant plus que le sous-titrage peut lui aussi passer par des phénomènes de simplification dûs aux contraintes d'affichage [Bue22].
- La langue des signes interprétée, souvent de façon simultanée au discours vocal, peut différer de la langue des signes utilisée au quotidien par les personnes sourdes, en se rapprochant de la syntaxe de la langue vocale par exemple.
- Enfin, usuellement les interprètes traduisent dans leur langue première, ce qui n'est pas le cas des interprètes de LS, sauf ceux qui sont CODA².

Données du web

Le web est un outil formidable pour l'échange de connaissances et de nombreux sites web sont dédiés aux langues des signes, il existe des dictionnaires (fig. 2.3 et fig. 2.4), des lexiques, des vidéos pédagogiques, etc. Il existe aussi des média-sourds qui s'appuient sur les langues des signes pour diffuser des informations sur un grand nombre de sujets. Enfin, il existe du contenu en langues des signes sur les principaux réseaux sociaux : YouTube, Facebook, Instagram, etc. (fig. 2.6). Ces contenus publiés sur le web sont différents des contenus télévisés car ils correspondent le plus souvent à du contenu créé directement en langue des signes, il ne s'agit pas d'une traduction simultanée ou différée. La facilité induite par le web et par les outils numériques permet à un grand nombre de sourds, pas nécessairement professionnels du métier, de créer et publier des vidéos. Ainsi sur le web on trouve davantage de contenu créé par des sourds pour des sourds, principalement en langue des signes, qu'à la télévision. Ces données revêtent donc un intérêt particulier pour les chercheurs.

2.2.2. Annotation

Les différentes tâches du traitement automatique des langues telles que détaillées dans le chapitre 1 nécessitent des corpus annotés. Il existe une grande diversité de type d'annotation en fonction des tâches cible. Une des difficultés pour l'annotation de corpus de LS réside dans le besoin d'experts capables d'annoter des informations linguistiques de plus ou moins haut niveau en fonction des tâches : gloses, catégories de signes ou traduction.

2. CODA : *Children Of Deaf Parents*, enfants de parents sourds



Figure 2.3 – Capture d'écran du *DicoElix*, dictionnaire Français / LSFFigure 2.4 – Capture d'écran de *SpreadTheSign* dictionnaire multilingue de Langues des SignesFigure 2.5 – Capture d'écran de *Media'Pi* média sourd en LSF

Figure 2.6 – Capture d'écran de la page Facebook de l'association JMS – Grenoble, qui publie des vidéos en LSF pour un public sourd

Gloses

Les gloses sont des mots en langue vocale utilisés pour représenter les signes sous forme écrite. Voilà un exemple de liste de gloses correspondant à une phrase en LSF issue du corpus Mediapi-RGB [OBG⁺24] : PERSONNE HOMME FOOTBALL RIBERY DANS ALLEMAGNE CLUB BAYERN MUNICH LUI PENDANT DOUZE ANS SON. Une des limitations des gloses est qu'elles ne permettent pas une parfaite bijectivité : un signe peut correspondre à plusieurs mots en français en fonction du contexte et vice-versa. Dans le cadre de l'annotation de corpus, on privilégie l'utilisation d'*ID-gloses*. Ce sont des gloses qui ne dépendent pas du sens contextuel du signe mais qui sont associées à la forme, elles sont donc considérées comme des identifiants de forme et non pas des équivalents de sens. Par exemple pour le signe signifiant à la fois "bonjour" et "merci" en LSF on pourrait associer systématiquement la glose BONJOUR, même si dans un contexte donné, on traduirait le signe par merci. Un corpus annoté en ID-gloses a donc un protocole d'association mot/signe. Il n'existe pas de règle universelle pour définir un tel protocole. La principale limitation des gloses est qu'elles ne peuvent pas rendre compte de l'éventail de nuances et de variations qu'englobe la signation [Bra16]. Ainsi, pour un gros camion, un petit camion et un camion moyen un signeur peut utiliser le même signe mais avec des variations au niveau de certains articulateurs (ici, les joues, les sourcils, les mains). Plus globalement, la glosification n'est pas adaptée à l'iconicité et tout ce qu'elle englobe (spatialisation, prise de rôle, etc.).

Catégories de signes

Comme expliqué dans le chapitre 1, la classification de signes selon leur catégorie est une des tâches du traitement automatique des langues des signes. Certains corpus [BBG20a] sont annotés en types de signes ce qui peut compléter une annotation en gloses qui met de côté les pointages, signes illustratifs, balises, etc.

Traduction

Idéalement, la *traduction* correspond à une version traduite en langue écrite de l'énoncé en langue des signes. Cependant dans le cas de la plupart des corpus de langue des signes interprétée, la traduction fournie correspond à la transcription de la langue vocale source, ce qui rend le contenu moins fidèle à ce qui est réellement signé.

Dans le cas de vidéos longues il est important que la traduction soit alignée temporellement avec la vidéo de façon à pouvoir découper des segments de vidéos plus petits tout en récupérant la traduction correspondante.

En effet, dans le cadre des méthodes de traduction automatique, fournir des vidéos de 30 minutes à un réseau de neurones peut s'avérer complexe, il est plus aisé de travailler sur des segments courts. L'alignement temporel ajoute donc une complexité à l'annotation, dans le cas de l'utilisation de sous-titres de langues vocales sur des données de langue des signes interprétées, l'alignement brut n'est pas exploitable car le décalage langue des signes / langue vocale est trop important, cela nécessite une étape d'alignement.

Autres annotations

Enfin, il existe d'autres types d'annotations, utilisés surtout à des fins d'analyse linguistiques comme des systèmes graphique permettant de décrire des unités gestuelles de langues des signes [KK14, Sut10] ou encore des descriptions à l'aide de formalismes complexes comme Azee [FHC14, FT14] plutôt orientés pour l'animation d'avatar signants. Ces annotations requièrent un très haut niveau d'expertise et de grandes quantités de temps et restent cantonnées à de tout petits corpus [FT14].

Conclusion

Si les gloses apparaissaient autrefois comme le mode d'annotation naturel des corpus de LS, leur utilisation est remise en question du fait de leurs difficultés à englober la complexité des langues des signes et leur coût d'annotation à la fois en expertise et en temps qui devient un frein de plus en plus important à mesure que les corpus deviennent plus volumineux.

2.3. Corpus existants

Dans un premier temps nous ferons un tour d'horizon des corpus existants à travers le monde puis nous nous intéresserons spécifiquement aux corpus de langue des signes française.




Figure 2.7 – Différents types de données du corpus How2Sign. Figure issue de [DPV⁺21]

2.3.1. À l'international

Plusieurs langues des signes ont fait l'objet de collectes de corpus, aussi bien pour des études linguistiques que pour le traitement automatique, le tableau 2.1, dresse un état des lieux des corpus dans le monde pour les différentes langues des signes. On remarque que les langues des signes les mieux dotées sont l'ASL³, la DGS⁴ et la BSL⁵.

Phoenix-RTWH-Weather

Le corpus Phoenix-RTWH-Weather [KFN15] est un corpus issu d'une émission de météo diffusée sur la chaîne de télévision allemande Phoenix. L'émission est interprétée en langue des signes allemande. Le corpus contient 12h30 de vidéos. Il est annoté en gloses et traduit en Allemand à l'écrit. C'est le corpus le plus utilisé aujourd'hui dans le domaine du traitement automatique des langues des signes malgré son domaine limité et sa faible représentativité de la langue des signes allemande telle qu'elle est pratiquée par les personnes sourdes.

How2Sign

Avec ses 80h de langue des signes américaine (ASL), How2Sign [DPV⁺21] est un des plus grands corpus de langue des signes continue non interprétée et traduite en Anglais. Il s'agit de tutoriels qui expliquent des tâches de façon basique, par exemple "Comment jouer du ukulélé". Ces tutoriels sont issus du corpus de langue vocale How2. Ce corpus est très intéressant car les énoncés proposés traitent de sujets simples et de la vie courante. Les vidéos sont signées par des signeurs natifs d'ASL et par des interprètes ce qui permet d'avoir un peu de diversité tout en garantissant un bon niveau de langue des signes. Le corpus est aujourd'hui une référence pour l'évaluation des méthodes de traitement automatique de l'ASL.

YouTube-ASL

Comme expliqué plus haut, la législation américaine permet aux chercheurs l'utilisation de données soumises au copyright dans le cadre de leurs recherches, cela

3. Langue des signes américaine
4. Langue des signes allemande
5. Langue des signes britannique

Table 2.1 – **Corpus de Langues des signes continue traduits en langue écrite les plus importants dans le monde**

Name	Year	SL	Duration	#Videos	#Signers	Gloss	Text	Voc. Size	Type
RWTH-PHOENIX [KFN15]	2014	DGS	12.5	386	9	Yes	Yes	1,081	Interpreted
SIGNUM sentences [vAK07]	2009	DGS	33.51	21,840	25	Yes	Yes	450	Signed from text
Public DGS Corpus	2018	DGS	50	-	330	Yes	Yes	-	Natural
CUNY ASL [LH14]	2014	ASL	3.53	242	8	Yes	Yes	-	Natural
How2Sign [DPV+21]	2021	ASL	79.12	2,529	13	Yes*	Yes	16,609	Natural
YouTube ASL [CSR+21]	2023	ASL	984	-	>2 519	Yes	Part.	60K	Signed from text
RWTH-BOSTON-104 [DRD+07]	2007	ASL	-	201	3	Yes	No	168	-
BSL Corpus [SFR+13]	2011	BSL	125	-	249	Yes	Yes	5,000	Natural
BBC BOBSL [AVM+21]	2021	BSL	1,467	1,962	39	-	-	-	Interpreted
DictaSign V2 LSF [BBG20a]	2020	LSF	8.00	207	18	Yes	No	2,252	Natural
MEDIAPI-SKEL [BBG20b]	2020	LSF	27	368	>100	No	Yes	-	Natural
Mediapi- RGB [OBG+24]	2023	LSF	85.9	1 230	>10	No	Yes	-	Natural
GSL20 [ACP+20]	2020	GSL	9.59	10,290	7	Yes	No	310	Signed from glosses
Video-Based CSL [YZ17]	2018	CSL	100	3,500	50	No	Yes	178	Signed from glosses
KETI [KKJC19]	2019	KSL	27.99	14,672	14	Yes	Yes	105	Pre-defined sentences
Corpus LFSB [MGC16]	2016	LSFB	12.00	2,400	100	Yes	Part.	2,500	Natural
SWISSTXT-RAW [CSR+21]	2021	DSGS	12.15	181	100	Yes	Part.	2,500	Signed from text

Table 2.2 – **Les corpus de LSF**. Tableau issu de [Bra22]

Nom	Année	Description	Durée	VF	Annotation
LS-COLIN [SBC ⁺ 02]	2002	monologue, narration, récit, explication	1,5h	partielle	partielle
CREAGEST [BCB ⁺ 10]	2011	dialogue et acquisition	> 156h *	partielle	partielle
DEGELS [BB12]	2012	dialogue, comparable LSF et gestualité	LSF : 35', gest. : 39'	partielle	partielle
40 Brèves [FT14]	2014	monologue, traduction de brèves journalistiques	1h	oui	oui
Mocap1 [eBBB16]	2016	monologue, description de photos	2h	non	partielle
Dicta-Sign-LSF-v2 [BBG20a]	2020	dialogue, plusieurs tâches avec plus ou moins d'élicitation	8h	oui	partielle
Mediapi-Skel [BBG20b]	2020	très varié, issu d'un média bilingue	27h	oui	non
Rosetta-LSF [BLBC ⁺ 22]	2022	monologue, traduction de phrases de type journalistique	3h		oui
Corpus Catteau [Cat21]	2020	poésie en LSF, interprétation en FR et entretiens	*	oui	oui

s'appelle le "fair use". Créé dans ce cadre, YouTube-ASL [UTG23] est un corpus de plus de 1000 heures de vidéos en langue des signes américaine tirées de YouTube et publiées par des centaines d'individus différents. Ces vidéos ont été listées automatiquement à partir des métadonnées pour en faire un corpus. Les traductions proposées sont celles fournies par les auteurs des vidéos pour leur public. En comparaison avec How2Sign, YouTube-ASL est de qualité moindre car les vidéos n'ont pas été vérifiées manuellement, il se peut que les sous-titres ne correspondent pas à une réelle traduction. Du fait de ses caractéristiques, ce corpus est particulièrement adapté pour le pré-entraînement de modèles qui seront ensuite affinés sur des corpus de langue des signes de grande qualité mais de taille plus modeste comme How2Sign.

2.3.2. En LSF

La langue des signes française a fait l'objet de nombreux corpus ces 20 dernières années [Bra22], cependant ces corpus de LSF ont été constitués en laboratoire principalement à des fins linguistiques et ont deux principales limitations :

- soit ils sont de très petite taille (moins de 8h.) (Rosetta, DictaSign-LSF, 40 brèves, etc.)
- soit ils ne sont pas annotés ou seulement très partiellement (Creagest)

Le tableau 2.2 issu de [Bra22] permet une vue d'ensemble des ressources existantes en LSF.



Figure 2.8 – Visualisation des poses issues d'une vidéo du corpus Mediapi-Skel et du sous-titre associé

Creagest

Creagest [BCB⁺10] est un corpus de plus de 300h de LSF adulte et enfantine publié en 2011. Partiellement disponible en ligne (106h seulement sont téléchargeables), peu annoté et peu documenté, Creagest est difficilement utilisable dans le cadre du traitement automatique de la LSF.

Rosetta-LSF

Rosetta-LSF [BLBC⁺22], publié en 2022, est un corpus d'environ 3h de LSF enregistré via un dispositif de capture de mouvements (motion capture). Les données de mouvement ont ensuite été utilisées pour générer des vidéos à l'aide d'un avatar. Les sujets ont été enregistrés lors de la réalisation de 4 tâches :

- La traduction en LSF de 194 titres de journaux issus ou inspirés de ceux du site de France info.
- La description de 28 photographies.
- La reproduction de 24 extraits de vidéos en LSF.
- La réalisation de plus de 1200 signes isolés correspondant aux notions les plus fréquentes issues des titres de la tâche 1.

Mediapi-Skel

Plus récemment le corpus de LSF Mediapi-Skel [BBG20b] a été mis à disposition dans le but de pallier aux deux problèmes évoqués plus haut. Il s'agit d'un corpus de taille bien plus grande que les précédents et intégralement traduit en Français. Ces deux corpus sont issus du média en ligne à destination des Sourds : Media'Pi!. Malheureusement, les données de Mediapi-Skel ne sont disponibles que sous forme de poses obtenues à l'aide d'OpenPose [CHS⁺19] et de Mediapipe [BGR⁺20]. La figure 2.8 donne un exemple de poses et de sous-titre du corpus.

Sources de vidéos de LSF

D'importants corpus d'ASL, de DGS ou de BSL sont issus d'émissions de télévision. Il est donc pertinent de s'intéresser aux sources de vidéos de LSF en dehors

Table 2.3 – Émissions en LSF ou interprétées en LSF

Name	Potential duration (h)	#Signers	Subtitles	Interpreting	Publishable
Média-Pi	≈129	> 100	Yes	No	Partially
Les 10 minutes M6	≈90	3	Yes	No	Maybe
Comptes rendu conseil des ministres	30	5	Yes	Yes	Yes
Tout info, tout en signes	4.7	> 1	Yes	Hybrid	Maybe
L'Œil et la main	468	-	Yes	No	Maybe
Total	±680	>108	-	-	-

du monde de la recherche aussi bien à la télévision que sur internet. Le tableau 2.3, liste différentes sources d'émissions en LSF ou interprétées en LSF.

Média'Pi est un média en ligne dont la première langue est la LSF, les reportages sont diffusés en LSF puis sous-titrés en français par un traducteur (fig. 2.9). Les vidéos présentent de nombreux avantages d'un point de vue du traitement automatique des langues des signes : il y a presque toujours un seul signeur par vidéo, toutes les vidéos sont traduites en français et les traductions sont temporellement alignées avec la LSF. Cependant le modèle économique de Media'Pi repose sur un accès payant ce qui constitue un frein à l'établissement d'un accord pour la diffusion de vidéos même dans le cadre de la recherche. Dans le cas de Mediapi-Skel, seules les poses avaient pu être publiées [BBG20b].

Le *10 minutes* est un média similaire, il s'agit d'un journal en LSF diffusé sur le site de la chaîne de télévision M6 (fig. 2.11). M6 a accepté de mettre à disposition ses vidéos du *10 minutes* pour la recherche, mais l'établissement d'un contrat s'est avéré trop compliqué. Sans compter d'autres difficultés comme l'interruption définitive de l'émission et la disparition de la plus grande partie des données dans l'incendie d'un datacenter.

La société de production de *l'Œil et la main* a également accepté de mettre à disposition l'ensemble de ses données pour nos recherches. La création d'un corpus à partir de ces données représenterait plusieurs défis, l'extraction des sous-titres incrustés, la reconnaissance des signeurs (plusieurs personnes dans l'image), la segmentation en vidéos plus courtes, etc. (fig. 2.10).

D'autres émissions comme les questions au gouvernement sur LCP, les journaux télévisés interprétés en LSF sur plusieurs chaînes du service public (fig. 2.12) sont des sources de données envisageables mais elles nécessitent l'établissement d'accords pour l'utilisation des données pour la recherche. Un tel accord doit idéalement permettre de rendre le corpus disponible à des chercheurs extérieurs pour pouvoir garantir la reproductibilité de la recherche. Enfin, il s'agit d'interprétation en LSF avec les limites que cela implique : pas d'alignement avec les sous-titres écrits, potentielle perte d'information due aux contraintes du direct, etc.

Les contenus gouvernementaux présentent les mêmes inconvénients que les émissions interprétées à l'exception de la nécessité d'un accord d'utilisation. En effet, les



Figure 2.9 – Capture d’écran de *Media'Pi* média sourd en LSF



Figure 2.10 – Capture d’écran de *L’œil et la main*, une émission de télévision diffusée sur France 5 qui traite des questions liées à la surdité



Figure 2.11 – Capture d’écran du *10 minutes*, une émission en ligne en LSF



Figure 2.12 – Capture d’écran du journal de 19h, sur Franceinfo, interprété en LSF

vidéos publiées sur le site du gouvernement sont sous une licence ouverte.

2.3.3. Conclusion

Les corpus de langues des signes représentent un enjeu important pour la recherche en traitement automatique des langues des signes. On observe un fort déséquilibre entre les différentes langues des signes, les mieux dotées sont l’ASL, la BSL et la DGS. En plus de la quantité, le type de données a son importance ; on différenciera notamment la langue des signes spontanée de la langue des signes interprétée en direct. Enfin, l’annotation plus ou moins complète des données influe fortement sur les possibilités d’utilisations des différents corpus. Dans le cas de la LSF, les corpus existants et annotés sont de très petite taille à l’exception de Mediapi-Skel qui n’est disponible que sous-forme de squelettes et non de vidéos. Il existe donc un besoin pour des corpus bilingues de plus grandes tailles dont les vidéos sont disponibles. Les différents acteurs de la production de vidéos en LSF qu’elle soit interprétée ou non représentent un potentiel point de départ pour la création de nouveaux corpus de recherche.

2.4. Matignon-LSF

Comme expliqué dans la section précédente, il existe de grandes quantités de vidéos en LSF disponibles en ligne, principalement en langue des signes interprétée. En droit français, ces données sont soumises au droit d’auteur et les chercheurs voulant s’en servir doivent établir un accord avec les ayants droit. C’est ainsi le cas pour




Figure 2.13 – **Capture d'écran du compte rendu du conseil des ministres du 21 Mai 2024**, avec sous-titrage et interprétation en LSF sur la plateforme YouTube

les vidéos de la chaîne parlementaire, des émissions de France télévisions interprétées en LSF, etc. En 2011, le gouvernement français a mis en place la *Licence Ouverte Étalab*, il s'agit d'une licence utilisable par n'importe quelle administration pour la publication de données publiques. Cette licence est très permissive et permet l'utilisation, la modification, la copie, la diffusion de données de façon très large y compris à des fins commerciales. Le contenu du site du gouvernement français⁶ est publié sous cette licence Étalab, dont notamment les vidéos des interventions du premier ministre et du porte-parole du gouvernement qui sont pour la plupart interprétées en LSF depuis juillet 2020 (2.13). Cela représente donc une source importante de vidéos de LSF, librement disponibles, qui devrait continuer de s'enrichir au fil des années. À partir de ces vidéos, nous avons proposé un nouveau corpus de LSF intitulé *Matignon-LSF* (2.14) qui a fait l'objet d'une publication au workshop sur les ressources en Langues des Signes sign-lang@LREC-COLING 2024 [HFO⁺24]. J'ai travaillé sur la partie collecte et préparation des données (rognage, filtrage des sous-titres), l'extraction des caractéristiques (mediapipe), et la rédaction du papier (partie introduction et état de l'art, figures).

2.4.1. Collecte des données

On peut différencier deux types de contenu interprété en LSF disponible sur le site du gouvernement : les interventions du premier ministre et les comptes-rendus du conseil des ministres. Les interventions du premier ministre sont très variées et ne sont que rarement interprétées en LSF. Les comptes-rendus du conseil des ministres sont quant à eux systématiquement interprétés en LSF depuis juillet 2020. Les vidéos sont postées sur les plateformes YouTube et Dailymotion. Sur YouTube,

6. <https://gouvernement.fr>



Figure 2.14 - **Capture d'écran d'une vidéo du corpus Matignon-LSF** avec le sous-titre associé, la vidéo a été rognée autour de l'interprète.

Durée totale (h)	39
Durée moyenne des vidéos (min)	36,54
#vidéos	67
#sous-titres	51 131
#phrases	18 000
#mots de vocabulaire en français	10 000
#signeurs	15
#locuteurs	3*
Résolution vidéo (px)	494 x 494
Taux de rafraîchissement (fps)	30

Table 2.4 - **Statistiques du corpus Matignon-LSF.**
*Les journalistes ne sont pas inclus

les comptes-rendus de conseil des ministres ont été regroupés dans des playlists. Nous nous sommes donc appuyés sur ces playlists pour télécharger les vidéos de conseils des ministres à l'aide de la librairie python PyTube. La deuxième étape a consisté à trier les vidéos exploitables ou non, puis à rogner les vidéos de façon à ne garder que l'interprète en LSF. Ensuite, il a fallu télécharger les sous-titres en français associés à chacune des vidéos à l'aide de la librairie YouTubeTranscript et éliminer les vidéos sans sous-titres professionnels⁷. Enfin, à l'image de ce qui a été fait pour d'autres corpus [AVM⁺21, OBG⁺24, DPV⁺21], nous mettons à disposition des caractéristiques pré-extraites sur le corpus à l'aide des modèles entraînés pour d'autres tâches : le modèle I3D entraîné pour la classification de signes en BSL [VMA⁺21] et Mediapipe Holistic [BGR⁺20] entraîné pour l'estimation de pose.

Nous avons publié l'ensemble des scripts que nous avons développés sous la forme d'une boîte à outil pour permettre à tous les chercheurs de mettre à jour le corpus au fur et à mesure des publications de nouvelles vidéos. La figure 2.15 donne une vue d'ensemble du pipeline de collecte de données.

2.4.2. Description du corpus

Matignon-LSF est le premier corpus de LSF interprété. Avec presque 40h de LSF, il s'agit du deuxième plus grand corpus de LSF traduit, derrière Mediapi-RGB (décrit dans la section suivante) comme l'illustre la figure 2.16. Le tableau 2.4 donne des données chiffrées sur le corpus. Le vocabulaire utilisé est très centré sur le champ lexical de la politique, la figure 2.17 donne les 20 noms les plus fréquents dans les sous-titres du corpus.

7. La majorité des vidéos des conseils des ministres postées sur YouTube sont sous-titrées dans les semaines suivant leur publication. Certaines de ces vidéos n'ont pas été sous-titrées. Il existe cependant une transcription de chacun des comptes-rendus sur le site du gouvernement mais elle n'est pas sous-forme de sous-titres. Les sous-titres générés automatiquement sont écartés de façon à garantir l'homogénéité du corpus.



Figure 2.15 – **Pipeline de collecte des données pour Matignon-LSF.** À titre personnel, je me suis chargé des étapes 1,2 et 4. Et j'ai contribué à l'étape 5.




Figure 2.16 – **Durée des corpus de LSF traduits.** Matignon-LSF est le deuxième plus gros corpus de LSF traduit après Mediapi-RGB (section 2.5) et le plus gros corpus de LSF interprétée.




Figure 2.17 – **Occurrences des 20 noms les plus fréquents du corpus.** Le champ lexical correspond à la politique française.

2.4.3. Limitations

Matignon-LSF présente plusieurs limitations, tout d'abord par sa nature, il s'agit de langue des signes interprétée et non de langue des signes produite directement. De fait, la structure de la langue sera différente de celle utilisée par des personnes sourdes. Enfin les sous-titres fournis avec ce corpus sont alignés avec l'audio et non la langue des signes, ce qui pose de nombreux problèmes dans la perspective du traitement automatique. En effet, on observe un décalage de durée variable entre le discours en français et l'interprétation. Or, cela rend compliqué de traiter des extraits de LSF tout en gardant le sous-titre associé.

2.4.4. Perspectives

Le corpus Matignon-LSF présente cependant de nombreux avantages qui peuvent être exploités pour répondre à diverses tâches de vision par ordinateur et de traitement du langage naturel.

Alignement

A ce stade, les sous-titres français et la LSF de Matignon-LSF ne sont pas encore alignés. Quel que soit le type de langue (parlée, écrite ou signée), les méthodes de traduction automatique nécessitent un alignement préalable entre la langue source et la langue cible. Afin d'utiliser ce jeu de données pour des tâches de traduction, il est nécessaire de pouvoir associer un extrait de LSF aux sous-titres français correspondants. Le jeu de données Matignon-LSF contient une traduction complète pour chacune des 67 vidéos. Cependant, fournir des séquences vidéo de 35 minutes ($\approx 52\,500$ images) et leurs traductions associées à un modèle de traduction serait très coûteux en terme de mémoire et de nombre de paramètres du modèle.

Il serait donc nécessaire de diviser ces vidéos en sous extraits. Les méthodes les plus récentes s'appuient principalement sur la segmentation des phrases. Les vidéos et le texte sont donc divisés en unités semblables à des phrases, avec une association entre le texte et la LS : pour chaque phrase LS, le texte correspondant à la traduction est donné. Cependant, produire un tel alignement phrase LS/texte à partir d'un ensemble de données LS interprétées est un véritable défi : le texte est aligné sur l'audio, alors que l'interprétation en LS est effectuée avec une latence qui varie dans le temps et d'un interprète à l'autre.

Ainsi, la toute première tâche à effectuer sur cet ensemble de données devrait être d'aligner les sous-titres sur le contenu de la LSF. L'alignement manuel nécessite un temps considérable, comme l'explique [BAV⁺21] : il faut environ 10 à 15 heures à un expert parlant couramment la langue des signes pour synchroniser les sous-titres avec une heure de vidéo continue en langue des signes. Les méthodes d'alignement automatique telles que celle utilisée pour l'ensemble de données BOBSL [AVM⁺21] pourraient être une solution, mais nécessiteraient un ajustement pour la LSF.

Modélisation de la LSF

Le jeu de données Matignon-LSF peut être utilisé tel quel, sans alignement préalable, pour la modélisation de la langue des signes et peut être utilisé pour former

des modèles de langage non supervisés sur la LSF tels que SignBERT [HZZL23].

Reconnaissance de signes

Avec l'aide d'une méthode telle que le processus d'annotation automatique de [LGBD24a] en cours de développement, nous pourrions procéder à la reconnaissance et à la classification automatiques des signes. Cela fournirait des informations sur le nombre de signes lexicaux dans notre ensemble de données. La classification des signes est également une étape vers l'alignement de notre ensemble de données entre la LS et les sous-titres. Cependant, il convient de noter que les mots figurant dans les sous-titres ne correspondent pas directement aux signes individuels produits par les interprètes, et vice versa. Il peut également y avoir des divergences entre le contenu audio et le texte des sous-titres.

Une fois aligné, l'ensemble de données Matignon-LSF pourrait être utilisé pour former des modèles de traduction automatique pour une grande variété de modalités : LSF vers texte français, LSF vers parole, et vice-versa [OBG⁺24], [VDiN20].

Étude de la LSF interprétée

En tant que première base de données de LSF interprétée de cette ampleur, Matignon-LSF peut être utilisé pour étudier la spécificité de la LSF interprétée par rapport à la LSF originale observée dans d'autres corpus. Par exemple, le travail de [BBG20a] pourrait être utilisé pour quantifier la distribution des types de signes dans ce jeu de données.

2.4.5. Conclusion

Les principaux avantages de ce nouveau corpus par rapport aux corpus existants peuvent être résumés comme suit :

- Il est totalement ouvert à un usage public ou privé
- Il est destiné à s'enrichir au fur et à mesure de la publication de nouvelles vidéos par le gouvernement français.
- Il s'agit du premier corpus de LSF interprétée.

2.5. Mediapi-RGB

L'établissement d'un partenariat entre le LISN et le média en ligne *Média'Pi*, m'a permis de travailler en collaboration avec Hannah Bull [Bul23] pour mettre à disposition un nouveau corpus destiné au traitement automatique de la LSF : Mediapi-RGB. Ce travail a fait l'objet d'une publication à la conférence VISAPP 2024 [OBG⁺24]. Avec 86 heures de vidéo, il s'agit du plus grand corpus de LSF traduit. Le corpus est constitué de contenus originaux en langue des signes française produits par des journalistes sourds, et comporte des sous-titres en français écrit alignés sur la langue des signes. La version actuelle de Mediapi-RGB est disponible sur le site Ortolang⁸ et peut être utilisée à des fins de recherche universitaire. Les ensembles de test et de validation contiennent respectivement 13 et 7 heures de vidéo.

8. <https://www.ortolang.fr/workspaces/mediapi-rgb>



Figure 2.18 – Capture d'écran issue d'un épisode de Média'Pi avec son sous-titre en français associé

L'ensemble de formation contient 66 heures de vidéo qui seront diffusées progressivement jusqu'en décembre 2024. En outre, la version actuelle contient des squelettes de points clés, une segmentation temporelle des signes, des caractéristiques spatio-temporelles et des sous-titres pour toutes les vidéos des ensembles d'apprentissage, de validation et de test, ainsi qu'un vocabulaire suggéré de noms à des fins d'évaluation. Enfin, nous suggérons des applications technologiques et linguistiques potentielles pour ce nouveau corpus vidéo-texte.

J'ai contribué à la mise en forme et à la publication du corpus, nettoyage, renommage, suppression de doublons, ainsi qu'à l'analyse statistique du corpus (chiffres, figures, vocabulaire). Je me suis chargé de l'extraction des estimations de pose à l'aide de Mediapipe. Les détails sur les contributions de Hannah Bull (rédaction, segmentation en signes, extraction des features VideoSwin, Open pose, I3D, etc.) sont détaillées dans l'article [OBG⁺24].

2.5.1. Description du corpus

Les données sont issues du média en ligne *Média'Pi*⁹, la même source de données utilisée pour créer Mediapi-Skel [BBG20b]. Il s'agit d'un média en ligne généraliste et indépendant lancé en avril 2018. Les articles et les reportages proposés portent sur l'actualité nationale et internationale ainsi que sur des sujets liés à la communauté sourde en LSF et en français (voir fig. 2.18). Il fonctionne sur la base d'un abonnement.

La quantité et la qualité des contenus originaux produits par Média'Pi! est difficile à trouver en dehors des corpus produits en laboratoire, et la diversité des scénarios reflète mieux la diversité des vidéos en LS du monde réel.

La LSF produite par les journalistes sourds suit une structure naturelle. Après les enregistrements, le contenu de la LSF est traduit en français écrit et aligné sur la vidéo en LSF sous forme de sous-titres. L'alignement entre les sous-titres écrits et

9. <https://media-pi.fr/>

Table 2.5 – Statistiques du corpus Mediapi-RGB

# épisodes sous-titrés	1230
# heures	86
# trames	7.7 million
Résolution (# vids.)	2160p (28), 1080p (1182), 720p (18), 480p (2)
Fréquence (# vids.)	25 fps
Durée moyenne des épisodes.	4.2 minutes
# signeurs	>10
# sous-titres	50 084
Durée moyenne de sous-titre	4.9 secondes




Figure 2.19 – **Occurrences des 20 noms les plus fréquents du corpus.** Le champ lexical correspond à l'actualité de la période de la création de ces contenus.

la vidéo en LSF est précis, ce qui contraste avec les données interprétées, où il y a souvent un décalage entre les sous-titres écrits (alignés sur l'audio) et l'interprétation en langue des signes.

Vocabulaire

Nous proposons un vocabulaire de 3 894 noms communs et propres à des fins d'évaluation. Ce vocabulaire correspond à une liste de noms issus des sous-titres Mediapi-RGB, apparaissant au moins 5 fois. Ces noms ont été lemmatisés à l'aide du lemmatiseur spaCy entraîné sur des textes d'actualité en français. La figure 2.19 représente la fréquence des 20 noms les plus utilisés dans ce corpus.

Découpage à partir des sous-titres

Les sous-titres de Média’Pi sont alignés avec la langue des signes. Nous découpons les vidéos de façon à ce que chaque clip de vidéo corresponde à un sous-titre. De cette façon, nous obtenons des vidéos courtes de quelques secondes auxquelles sont associées une phrase ou une proposition grammaticale en français.

Extraction de caractéristiques

De la même façon que ce qui a été expliqué pour le corpus Matignon-LSF dans la section 1.4, nous avons extrait la pose des sujets à l’aide des modèles d’estimation de pose OpenPose [CHS⁺19] et Mediapipe Holistic [BGR⁺20]. En plus de cela nous fournissons des caractéristiques issues d’un modèle I3D entraîné sur de la classification de signes et un modèle VideoSwin Transformer entraîné sur la même tâche [VMA⁺21], [LNC⁺22].

Suppression des doublons

Les émissions de Média’Pi réutilisent parfois des données de vidéos précédentes, que ce soit lors d’un *jingle* de début ou de fin d’émission ou lors d’émission qui font appel à des reportages déjà diffusés. L’existence de doublons dans le corpus est un problème car cela peut entraîner de potentiels biais lors de son utilisation. Or, passer en revue manuellement chacune des 87h du corpus en essayant de déterminer s’il s’agit d’un doublon ou non serait un processus très long et complexe. Nous avons donc cherché à mettre en place des stratégies d’automatisation de la recherche de doublons.

Un premier filtrage a consisté à repérer les blocs de sous-titres identiques d’une vidéo à l’autre. Cette méthode ne permet pas de supprimer tous les doublons car certains extraits peuvent avoir été sous-titrés à nouveau lors de chaque rediffusion et donc avoir un sous-titre légèrement différent. Aussi, il fallait s’assurer de ne pas supprimer des vidéos correspondant au même sens, donc ayant des sous-titres proches voire identiques, mais signées lors d’enregistrements distincts.

Nous avons donc mis en place un deuxième filtrage sur la similarité des vidéos indépendamment des sous-titres en nous appuyant sur les caractéristiques Video Swin. Nous avons calculé la similarité cosinus de toutes les sous-vidéos du corpus. Nous avons défini empiriquement un seuil de similarité à partir duquel nous considérons les deux vidéos comme identiques. Du fait de la nature de ces caractéristiques, la similarité cosinus ne permet pas toujours de distinguer une paire de vidéos correspondant à un doublon d’une paire de vidéos correspondant à deux enregistrements distincts mais similaires. Il existe donc une zone grise de similarité où la valeur de la similarité cosinus ne permet pas de trancher.

Cette zone grise s’explique par l’existence de paires de doublons où l’une des vidéos a fait l’objet d’une légère altération, ce qui biaise la mesure de la similarité et à l’inverse, au cas où certaines vidéos correspondant à deux enregistrements distincts sont très proches. Les figures 2.20, 2.21, 2.22 et 2.23 donnent des exemples de paires de doublons pour lesquelles la similarité cosinus des caractéristiques Video Swin ne permet pas tout à fait de faire la différence avec des enregistrements distincts de phrases proches.



Figure 2.20 – Trames de début de deux vidéos identiques dont le découpage, basé sur les sous-titres est décalé.



Figure 2.21 – Trames de deux vidéos identiques ayant subi des processus de compression différents.



Figure 2.22 – Deux extraits identiques dont l'arrière-plan a été modifié.



Figure 2.23 – Le même reportage rediffusé mais l'échelle des deux extraits est différente.

Pour limiter les potentielles conséquences négatives de doublons sur les modèles d'apprentissage profond entraîné sur Mediapi-RGB, nous regroupons les doublons potentiels dans un même ensemble de test, validation ou entraînement de façon à s'assurer de ne pas avoir la même vidéo d'un ensemble à l'autre.

2.5.2. Limitations

En plus de regroupement des doublons, la publication des vidéos en plusieurs étapes du fait de l'embargo a contraint le groupement des vidéos par date pour les ensembles de test, de validation et d'entraînement. De fait, ces ensembles ne couvrent pas la même période. Ainsi, l'ensemble de test, pleinement disponible dès 2023 correspond aux données les plus anciennes alors que les ensembles d'entraînement et de validation qui seront pleinement disponibles fin 2024 couvrent des périodes ultérieures à l'ensemble de test. S'agissant d'un corpus d'actualité, le vocabulaire utilisé et les sujets traités varient d'une année à l'autre.

2.5.3. Perspectives

Traduction

Mediapi-RGB est un corpus idéal pour l'entraînement de modèles de traduction automatique, en effet, le texte des sous-titres est parfaitement aligné avec la LSF, il a été écrit d'après la LSF et non d'après du français oral. Il s'agit du plus gros corpus de LSF traduit et d'un des plus gros corpus de Langue des Signes sourde toutes langues des signes confondues.

Modélisation

Comme Matignon-LSF, Mediapi-RGB peut être utilisé pour entraîner des modèles de langue sur la langue des signes en vue d'extraire des représentations pour d'autres tâches.

Étude de la LSF

Mediapi-RGB peut également être utilisé dans le cadre d'études linguistiques sur la LSF, par exemple pour tester le passage à l'échelle d'hypothèses émises sur des corpus de très petite taille (40 brèves, etc.).

Entraînement de modèles de segmentation / alignement

Comme expliqué plus haut, Mediapi-RGB présente l'avantage d'avoir des sous-titres alignés sur la langue des signes. Il peut donc être utilisé pour entraîner ou affiner des modèles d'alignements jusque-là indisponibles pour la LSF.

2.5.4. Conclusion

Le corpus Mediapi-RGB est le plus grand corpus de LSF traduit à ce jour et l'un des plus importants par rapport aux autres corpus de langue des signes dans le monde. Il s'agit d'un corpus de langue des signes non-interprétée et signée par des sourds ce qui en fait une des rares exceptions parmi les corpus utilisés en traitement automatique des langues des signes.

2.6. Synthèse

Dans ce chapitre nous avons expliqué l'importance des corpus pour le traitement automatique des langues des signes, nous avons discuté des différents types de corpus et de données utilisés dans la recherche. Nous avons dressé un état des lieux des ressources disponibles pour les différentes langues des signes puis nous nous sommes concentrés sur la LSF. Enfin, nous présentons deux nouveaux corpus : Matignon-LSF et Mediapi-RGB qui permettent d'ajouter 126h de LSF traduites à la disposition des chercheurs de diverses disciplines.

Représenter le signe en machine, modéliser le mouvement

3.1	Reconnaissance de signes lexicaux dans un énoncé continu	72
3.1.1	Extraction de caractéristiques	73
3.1.2	Architecture du modèle de reconnaissance	73
3.1.3	Expériences	74
3.1.4	Résultats	75
3.1.5	Conclusion	77
3.2	Stratégies d'entraînement d'extracteurs de caractéristiques à l'échelle du signe	78
3.2.1	Représentations existantes	78
3.2.2	Préparation des données	79
3.2.3	Encodage des signes	80
3.2.4	Expériences	81
3.3	Conclusion	85

Ce chapitre s'intéresse à la reconnaissance de signes en LSF à la fois en contexte continu et en contexte isolé pour évaluer les représentations machine des signes. Nous cherchons à établir quels articulateurs privilégier et nous comparons des stratégies d'apprentissage de plongements.

Dans un premier temps, nous concevons un premier modèle de reconnaissance de signes lexicaux en LSF en contexte continu, c'est-à-dire dans un énoncé continu. Ce modèle prend en entrée une séquence de langue des signes correspondant à un énoncé et doit prédire, pour toute cette séquence, la liste des signes lexicaux reconnus. L'entraînement d'un tel modèle requiert une grande quantité de données annotées. Cependant, dans le cas de la LSF, nous disposons d'une quantité limitée de

données. Pour y remédier, le modèle de reconnaissance utilisé n'exploite pas le flux vidéo brut en entrée mais s'appuie sur des points clés de posture humaine (ou pose), permettant d'aboutir à un modèle léger (requérant peu de paramètres), rapide à entraîner et nécessitant peu de données d'entraînement, en comparaison à des modèles fonctionnant à partir de données RGB brutes. Dans ce contexte de reconnaissance à partir des poses, est-il nécessaire d'encoder l'entièreté du corps du signeur, ou les mains suffisent-elles? Sur la base de ce modèle, nous quantifions le rôle des quatre articulateurs principaux : les deux mains, le visage et la pose générale du corps.

Dans un second temps (section 3.2), nous nous plaçons dans le cadre de la reconnaissance de signes isolés. En nous appuyant sur le corpus existant DictaSign-LSF, nous créons une variante, que nous appelons DictaSignLSF-ISOL. Les signes sont isolés de leur contexte : pour chaque signe lexical du corpus DictaSign-LSF, nous obtenons un ensemble de très courtes vidéos (16 trames) correspondant aux occurrences du signe. Nous évaluons ensuite deux encodeurs de signes : un ayant suivi un apprentissage par contraste et l'autre une tâche de classification classique. Notre objectif est que deux occurrences d'un même signe soient proches dans l'espace de représentation et que deux occurrences de signes différents soient éloignées.

3.1. Reconnaissance de signes lexicaux dans un énoncé continu

Nous nous plaçons ici dans un contexte de reconnaissance de signes lexicaux dans un énoncé continu en LSF, dont les vidéos ont été annotées en gloses (en signes dits conventionnels ou lexicaux). La figure 3.1 illustre ce cas de figure. Notons que les signes ont des durées différentes et que l'annotation est peu dense. En effet, une grande partie des signes réalisés correspond à des unités illustratives non-conventionnelles qui ne peuvent pas être associées à une glose issue d'un dictionnaire.




Figure 3.1 – Illustration du type d'annotation réalisée sur une vidéo extraite du corpus DictaSign-LSF-v2.

L'objectif de cette première section est de concevoir et tester un algorithme de reconnaissance de signes lexicaux dans ce contexte continu. À chaque instant de la vidéo, le modèle devra identifier la glose réalisée (ou l'absence de glose). Nous cherchons également à évaluer l'importance de différents articulateurs pour la reconnaissance de signes en LSF. En effet, si certaines méthodes de reconnaissance de signes [HZZL23, HZgZ⁺21] se focalisent sur les mains, les linguistes s'accordent pour souligner l'importance de nombreux articulateurs en LSF parmi lesquels les sourcils, les bras, les joues, la bouche, le regard. Dans cette étude, nous nous intéressons à l'apport de quatre articulateurs "gros grain" : les deux mains, le visage et le reste du corps. En évaluant l'importance de chaque articulateur, nous cherchons à déterminer si les modèles d'encodage de vidéos en langue des signes doivent inclure




Figure 3.2 – **Architecture du modèle proposé** pour la reconnaissance de signes lexicaux dans un flux continu.

ces différents articulateurs, et quelle serait la perte de performance en écartant l'un d'entre eux.

Dans un premier temps, nous décrivons les caractéristiques visuelles utilisées en entrée puis nous donnons les éléments constitutifs du modèle de reconnaissance de signes lexicaux. Les expériences sont ensuite décrites.

3.1.1. Extraction de caractéristiques

La première étape de la chaîne de traitement proposée consiste à extraire une représentation des signeurs sous forme de pose pour chaque image de la vidéo d'entrée. Pour cela, nous nous appuyons sur *Mediapipe Holistic* [BGR⁺20]. Cet outil, entraîné sur des milliers d'heures de vidéo, présente l'avantage de fournir une pose précise des sujets et de permettre une exécution en temps réel, c'est-à-dire à 25 images par seconde. Cette représentation consiste en un ensemble de points, regroupés par articulateur : 21 points par mains, 33 points pour le corps en général et 468 points pour le visage. Les points obtenus étant en 3D, chaque signeur est ainsi représenté par 543 points 3D donc 1629 valeurs. Pour limiter la taille des vecteurs d'entrée, nous appliquons une analyse en composantes principales (ACP) sur chaque articulateur pour nous ramener à 20 valeurs par articulateur. La représentation obtenue est donc particulièrement légère (80 valeurs avec 4 articulateurs) en comparaison avec la liste de coordonnées brutes (1 629 valeurs) ou une représentation obtenue à partir d'extracteurs de caractéristiques (ou *features* en anglais) récents comme VideoMAE [TSWW22] qui construit des vecteurs de 1 204 224 valeurs.

3.1.2. Architecture du modèle de reconnaissance

La figure 3.2 donne un aperçu de l'architecture de notre modèle de réseau de neurones. De façon similaire à ce qui a été proposé par [CKHB20a] et [SBH22], notre modèle est composé d'un flux d'entrée séparé pour chaque articulateur. Ainsi, avec quatre articulateurs : deux mains, visage, et pose générale du corps, nous obtenons quatre flux. Chacun des flux a sa propre couche de *Gated Recurrent Units* (GRU) [Cho14] bidirectionnels, capable de traiter les données de pose de façon séquentielle. Les GRU sont des modules récurrents, similaires aux *Long Short Term Memory* (LSTM) en permettant de gérer la mémoire temporelle avec moins de paramètres. Les différents flux sont ensuite concaténés en un seul flux pour passer à

travers une deuxième couche de GRU bidirectionnels. Le modèle se termine sur une couche pleinement connectée puis une couche CTC [GFGS06] qui permet de fournir une séquence de labels en sortie (sec. 1.3.1). La couche CTC permet de s'affranchir d'annotations à l'échelle de la trame en fonctionnant directement à l'échelle de la séquence.

Ce modèle est appliqué à la reconnaissance de signes lexicaux et constitue, à notre connaissance, la première expérience de reconnaissance de signes lexicaux en LSF. Les expériences menées dans la partie suivante vont également permettre de quantifier l'impact de chaque articulateur sur les performances de la reconnaissance. Nous avons également proposé une architecture monoflux avec concaténation précoce (fusion) des caractéristiques des 4 articulateurs. La section expérimentale propose une comparaison des deux modèles.

3.1.3. Expériences

Après avoir présenté le corpus étudié dans ces expériences, nous donnons quelques détails d'implémentation du modèle, puis décrivons la métrique utilisée. La dernière partie s'intéresse aux résultats en termes de performance de reconnaissance et illustre ces résultats avec quelques exemples.

Corpus étudié

Ce travail s'appuie sur le corpus Dicta-Sign-LSF-v2 [BBG20a] qui a été présenté dans le chapitre 2. Ce corpus a été annoté de manière dense par des experts en linguistique. Cependant, ces annotations comprennent à la fois des signes conventionnels, lexicaux (identifiés par des *labels* de gloses) et des signes illustratifs fortement dépendants du contexte. L'étude est limitée aux 100 signes lexicaux les plus fréquents afin de disposer d'un nombre significatif d'occurrences par signe. Plus précisément, les 100 premières classes disposent d'au moins 47 exemples de signes. Des parties du corpus sont sélectionnées pour garantir que les extraits contiennent au moins un signe appartenant aux 100 classes les plus fréquentes. Dicta-Sign-LSF-v2 comprend différentes vidéos issues de différents points de vue, notamment une vue avec les deux signeurs vus de côté, au-dessus des deux vues de face, individuelles. Nous écartons les vues de côté et utilisons les vidéos montrant chaque signeur individuellement. Le corpus résultant est mis à la disposition de la communauté. Nous obtenons 5 737 séquences d'une durée maximale de 254 images, c'est-à-dire 11 secondes. 10% des séquences est réservé pour le test, 10% pour la validation et le reste pour l'entraînement.

Détails d'implémentation

Nous avons utilisé les bibliothèques python Keras [C⁺15] et CTCKeras [SRP19] pour le développement du modèle. Chaque couche de Bi-GRU est composée de 128 cellules. Nous avons fixé le taux d'apprentissage (*learning rate*) à 0.1, la taille de *batch* à 32 et nous entraînons le modèle sur 50 epochs. Le temps d'entraînement est d'environ 30 minutes sur une machine équipée d'un GPU Nvidia Quadro RTX

8000. Avec le même matériel, l'inférence prend en moyenne 55 ms par séquence de 254 trames.

Métriques

Pour évaluer la performance du système de reconnaissance, nous nous appuyons, comme la plupart des travaux portant sur la reconnaissance en contexte continu, sur le taux d'erreur de mots (WER pour *Word Error Rate*) défini comme suit :

$$WER = (S + D + I) / N$$

où S , D et I correspondent respectivement au nombre de substitutions, délétions et insertions et, N est le nombre total de gloses dans l'ensemble de test. Nous indiquons également le WER lorsque nous considérons les deux meilleures hypothèses données par l'algorithme de décodage en faisceaux (*beam search*) [Low76]. On nomme cette métrique Top-2 WER. L'intervalle de confiance à 95% est calculé à partir de la méthode de Wilson avec correction de continuité. Précisons que nous considérons les annotations expertes comme la vérité terrain, ce qui pourrait être discuté. En effet, l'annotation étant une tâche fastidieuse, une erreur d'annotation n'est pas exclue. Nous supposons toutefois que, si elles existent, elles sont suffisamment rares par rapport à l'ensemble des annotations.

3.1.4. Résultats

Dans un premier temps, nous considérons un lexique de 100 signes et un modèle exploitant l'ensemble des quatre articulateurs dans un schéma multiflux. Ce modèle obtient 53,1% en WER.

Mono-flux ou multi-flux?

Comparons l'utilisation d'une architecture monoflux avec concaténation précoce (fusion) des caractéristiques des 4 articulateurs avec l'utilisation d'une architecture multiflux avec concaténation ultérieure. Avec l'architecture multi-flux pour la reconnaissance des 100 signes les plus fréquents, nous obtenons une amélioration de 7,7 point du WER par rapport au cas monoflux (WER de 53,1 % en multi-flux contre WER de 60,8 % en monoflux).

Nous pouvons supposer que le modèle multi-flux permet de mieux prendre en compte l'asynchronisme entre les articulateurs. Le caractère multiflux facilite également la capacité du modèle à apprendre des caractéristiques propres à chacun des articulateurs, telles que les configurations manuelles, les expressions faciales.

Articulateurs

Ensuite, nous évaluons la contribution de chaque articulateur par rapport à la performance globale. Le tableau 3.1 montre une comparaison détaillée du WER obtenu en fonction des articulateurs fournis en entrée. Sans surprise, la main droite (qui est la main dominante de la plupart des sujets) semble être l'articulateur qui fournit le plus d'informations. Au vu du tableau, on peut classer les articulateurs

RH	LH	Body	Face	WER	95% Conf. Int
✗	✗	✗	✓	95.5	[93.9;96.6]
✗	✗	✓	✗	94.1	[92.4;95.5]
✗	✓	✗	✗	85.4	[83.1;87.6]
✓	✗	✗	✗	72.0	[69.1;74.8]
✓	✓	✗	✗	59.9	[56.8;63.0]
✓	✓	✓	✗	55.0	[51.8;58.1]
✓	✓	✗	✓	54.6	[51.5;57.7]
✓	✓	✓	✓	53.1	[49.9;56.2]

Table 3.1 – Étude d'ablation des articulateurs d'entrée. Main droite, main gauche, pose générale du corps et maillage du visage.

# classes	Min occ./sign	WER	Top-2 WER
10	166	23.9	13.9
25	114	37.7	28.3
50	72	44.0	38.0
100	47	53.1	47.3

Table 3.2 – Performance du modèle en fonction du nombre de gloses considérées lors de l'apprentissage.

par ordre d'importance comme ceci : main droite ¹, main gauche, visage, et pose du corps.

Nombre de classes

En troisième lieu, nous avons évalué la performance du modèle en fonction du nombre de gloses prises en compte lors de l'apprentissage. Le tableau 3.3 présente à la fois le WER et le Top-2 WER obtenus en considérant les 10, 25, 50 et 100 signes les plus fréquents du corpus. Comme prévu, la performance s'améliore considérablement lorsque nous réduisons le nombre de classes, probablement parce que cela augmente mécaniquement le nombre moyen d'occurrences par signe. Le Top-2 WER montre que lorsqu'un signe est mal prédit, la prédiction correcte se trouve souvent dans la seconde hypothèse. Plus le nombre de classes est faible, plus l'écart entre le WER original et le Top-2 WER est important.

Évaluation qualitative

Le tableau 3.3 présente quelques exemples de séquences de gloses prédites. Les deux premières séquences correspondent à un WER de 50 %, ce qui est représentatif de la performance globale du système. Nous pouvons constater qu'elles ne sont pas très éloignées de la vérité terrain. Les deux premiers exemples nous permettent de

1. qui se trouve être la main dominante de la majorité des sujets

GT	DEUX CONSEQUENCE CONSEQUENCE LIGNE
Pred	DEUX CONSEQUENCE JUSTE IL-N'Y-A-PAS
GT	GARE AUTREFOIS UN PERSONNE
Pred	GARE GARE AUTREFOIS PERSONNE
GT	AJOUTER VRAI AJOUTER AUTREFOIS
Pred	AJOUTER REGARDER AJOUTER AUTREFOIS

Table 3.3 – Exemples de séquences de gloses prédites avec la vérité terrain correspondante. Les deux premières séquences ont obtenu un WER de 50 %, la dernière un WER de 75 %.

constater que notre modèle a du mal à gérer les répétitions de signes dans le corpus. Dans le premier exemple, il ne prend pas en compte la répétition de la glose CONSEQUENCE et dans le second exemple il ajoute une répétition de la glose GARE. Il faut noter que la répétition a un rôle particulier en langue des signes, elle indique parfois une quantité ou un degré d'intensité. Enfin, certains signes lexicaux normalisés sont basés sur la répétition du mouvement comme le signe en LSF qui correspond à *travail*. Selon le troisième exemple, le modèle peut confondre des signes similaires ; en effet, les signes correspondant aux gloses VRAI et REGARDER correspondent à la même forme (de configuration) de la main dominante (doigts en forme de V). Cela montre que le modèle prend correctement en compte la position des articulations et des doigts pour discriminer les signes.

3.1.5. Conclusion

Dans cette étude, nous avons présenté un premier modèle de reconnaissance de signes lexicaux pour la langue des signes française dans un contexte continu. Pour faire face à la taille relativement réduite des corpus existants en LSF, nous avons proposé un modèle léger combinant l'extraction de la pose et un décodeur utilisant un réseau récurrent entraîné avec une fonction de perte CTC (évitant la nécessité d'une segmentation temporelle du corpus d'entraînement au niveau de la glose).

Enfin, nous avons évalué la contribution relative et absolue des principaux articulateurs (main droite, main gauche, visage et corps) dans les performances de décodage et avons montré l'avantage d'une approche multi-flux par rapport à une approche mono-flux.

Une façon de faciliter le travail du modèle et donc d'améliorer la reconnaissance, serait d'extraire des caractéristiques à partir des poses avant de les fournir au modèle. Ainsi, pour aller plus loin dans la réflexion, la partie suivante suppose que nous disposons d'une banque de signes lexicaux, chacun d'entre eux étant représenté par une séquence de n images (n fixe). Elle propose d'extraire un vecteur d'encodage pour chacun de ces segments vidéo. De cette façon, l'apprentissage s'effectue en exploitant uniquement des données de signes lexicaux conventionnels et peu dépendants du contexte, et sans prendre en compte des mouvements *parasites* ne correspondant

à aucun signe.

3.2. Stratégies d'entraînement d'extracteurs de caractéristiques à l'échelle du signe

Quelle que soit la tâche reliant une paire langue des signes / langue vocale donnée, la quantité de données disponible pour l'entraînement de réseaux de neurones est souvent très réduite, c'est pourquoi il est pertinent de chercher à tirer profit des données annotées disponibles sur d'autres tâches de traitement automatique. De nombreux travaux ont cherché à bénéficier de ce type de transferts en utilisant un modèle de classification entraîné sur un jeu de données de classification de signes pour extraire des caractéristiques pertinentes pour une tâche de traduction [DPV⁺21, AVM⁺21], d'alignement [BAV⁺21], de détection, ou de segmentation [BGB20]. Dans cette section, nous cherchons à déterminer si un modèle entraîné sur tâche d'apprentissage contrastif est plus ou moins pertinent qu'un réseau de classification pour l'extraction de caractéristiques des langues des signes. Nous dressons une comparaison de ces deux stratégies, en entraînant les réseaux de neurones sur les mêmes données, avec une architecture d'encodeur commune. Nous évaluons les modèles d'extraction de caractéristiques résultants quantitativement et qualitativement.

3.2.1. Représentations existantes

Les premières méthodes de traitement automatique des langues des signes utilisant l'apprentissage profond s'appuyaient sur des extracteurs de caractéristiques visuelles obtenus à partir de modèles de classification d'image comme AlexNet [KSH12, CHK⁺18] ou Inception [SLJ⁺15, VPK⁺21, CKHB20b] entraînés sur de grandes bases de données généralistes (principalement ImageNet [DDS⁺09]). La tête de classification du modèle est retirée puis les poids peuvent être affinés (par *Fine-tuning*) pour la tâche de traduction lors de l'apprentissage.

Enfin, des méthodes plus récentes se sont intéressées à l'utilisation de modèles développés et entraînés pour de la classification d'actions humaines sur des vidéos. L'usage de tels modèles diffère des modèles dédiés aux images. En effet, les modèles de classification de vidéos sont beaucoup plus lourds que les modèles de classification d'images et sont généralement adaptés à des vidéos courtes (16 trames). Ils s'appliquent donc par fenêtre glissante sur les vidéos à analyser. Enfin, ils peuvent être affinés sur de la classification de vidéos de signes. Du fait de leur nombre important de paramètres et de leur application par fenêtre glissante, ces modèles ne peuvent pas être aisément affinés lors de la tâche de traduction, par conséquent les caractéristiques sont pré-extraites en amont.

Un inconvénient des méthodes listées précédemment réside dans le poids des modèles qui peut limiter leur utilisation notamment pour des applications temps-réel. Pour faire face à cette difficulté, certains chercheurs ont mis au point des modèles de traitement automatique de langues des signes s'appuyant sur la pose humaine pré-extraite à l'aide de modèles d'estimation de pose légers comme Mediapipe Holistic [BGR⁺20]. Des travaux de la littérature montrent que l'utilisation de la pose donne

3.2. STRATÉGIES D'ENTRAÎNEMENT D'EXTRACTEURS DE CARACTÉRISTIQUES À L'ÉCHELLE DU SIGNE

de moins bons résultats que les encodeurs de vidéos pré-entraînés. Cela peut s'expliquer par deux raisons : les poses sont des estimations qui peuvent être erronées, et les modèles ne bénéficient pas de pré-entraînement sur d'autres tâches telles que la classification de signes ou d'action. Ainsi quelques travaux se sont intéressés au pré-entraînement d'extracteurs de caractéristiques à partir de la pose comme SignBERT ou SignBERT+ [HZZL23] qui entraînent un encodeur à reconstruire des poses de main masquées dans des séquences de poses contenant un signe. Les résultats obtenus avec cette méthode sont comparables à ceux obtenus à l'aide de modèles pré-entraînés sur des images ou vidéos RGB.

Cependant, à notre connaissance, il n'existe pas de comparaison des différentes tâches de pré-apprentissage pour le traitement automatique des langues des signes.

3.2.2. Préparation des données

À partir de vidéos continues en LSF, nous extrayons des segments de 16 trames associés à chacun des signes lexicaux annotés quelle que soit la durée réelle du signe. La figure 3.3 illustre la démarche.

Extractions de vidéos de signes lexicaux de DictaSign-LSF-v2

Comme indiqué précédemment, les signes lexicaux du corpus DictaSign-LSF-v2 ont été annotés temporellement par des annotateurs experts. L'annotation de chaque signe correspond à deux trames : sa trame de configuration principale et sa trame de transition vers un autre signe, chacun de ces signes lexicaux est associé à une glose. Comme première étape de préparation des données, nous extrayons chaque occurrence de signe lexical comme une vidéo indépendante de taille fixe (16 trames) en essayant de garder le mouvement de mise en place et le mouvement de transition vers la configuration suivante (signe ou fin d'énoncé). La figure 3.3 donne un aperçu du type de traitement réalisé. À la fin de cette étape, nous obtenons 22310 vidéos clips de signes lexicaux et leur glose associée.²




Figure 3.3 – Illustration du traitement réalisé sur les vidéos du corpus DictaSign-LSF-v2 pour obtenir des segments de 16 trames associés aux signes.

2. Cette adaptation du corpus Dicta-Sign sera rendu publique pour la reproductibilité.

Ensembles d'entraînement, de test et de validation multi-tâches

Dans un premier temps, nous divisons le corpus en classes vues pendant l'entraînement des différents modèles et des classes non vues (208 pour le test et 208 pour la validation) qui serviront à évaluer le comportement des modèles sur des signes qui n'ont pas été vus pendant l'entraînement. Nous divisons donc notre corpus de signes en un ensemble d'entraînement, un ensemble de validation et un ensemble dédié au test.

Utilisation d'un sous-ensemble de 100 classes Contrairement à d'autres corpus, DictaSign-LSF-v2 contient des vidéos de conversations spontanées entre signeurs sourds, de fait, on observe une grande variété de vocabulaire : sur la durée du corpus (autour de 4h), les annotateurs ont annoté 2081 classes de signes lexicaux. Ces classes sont représentées de façon inégale dans le corpus. De nombreux signes n'apparaissent qu'une ou deux fois. Pour faciliter la tâche de classification, nous entraînons et testons la tâche de classification sur un sous-ensemble des 100 classes les plus fréquentes dans le corpus.

Représentation des vidéos sous-forme de séquences de poses

L'utilisation de vidéos en entrée des modèles s'est avérée particulièrement lourde en terme de ressources de calcul. C'est pourquoi nous avons opté pour l'utilisation de squelettes obtenus à l'aide d'un modèle d'estimation de pose pour représenter les signes en entrée des différents modèles.

Recadrage des vidéos et normalisation des coordonnées

Les signeurs de DictaSign-LSF-V2 sont plus ou moins près de la caméra en fonction des sessions d'enregistrement. Les coordonnées des poses sont donc normalisées de façon à ce que la distance inter-épaules soit identique d'une séquence à l'autre, d'un signeur à l'autre. La configuration de la main est rendue invariante à sa position dans l'espace de signation, en soustrayant la position du poignet aux points de la main. On garde l'information de la position de la main grâce aux points correspondant au poignet et à la paume. On procède de la même façon avec le visage.

Pour chacune des méthodes proposées nous appliquons des retournements horizontaux aléatoires pour que les caractéristiques extraites ne dépendent pas de la main dominante du signeur (droite pour la majorité, gauche pour certains d'entre eux).

3.2.3. Encodage des signes

Les deux stratégies employées pour encoder les séquences reposent sur un modèle d'encodeur commun présenté dans la partie suivante.

Architecture d'encodeur commune

Comme le montre la littérature en la matière, la conception d'une architecture de réseau est un processus complexe encore mal formalisé, l'usage est de tester itérativement plusieurs configurations. Après avoir testé de nombreuses configurations,




Figure 3.4 – **Modèle de classification.** Le modèle prend en entrée une séquence de poses 3D. L'encodeur réduit ces données pour obtenir un vecteur à 64 dimensions. Une tête de classification prédit un label de signe pour l'ensemble de la séquence d'entrée.

je me suis finalement appuyé sur le modèle développé par Hyeol Sohn dans le cadre de la compétition *Kaggle* de classification de signes isolés de l'ASL à partir de poses Mediapipe³. Il s'agit du modèle ayant obtenu le meilleur score parmi 20210 soumissions. Il repose sur deux blocs identiques, chaque bloc est composé de trois couches de convolution 1D de dimension 192 et d'une couche de *transformer*. À la suite de ces deux blocs, le modèle original comprend un module de fort *dropout* (80%) puis une tête de classification. La tête de classification est supprimée pour faire du modèle un encodeur généraliste. On ajoute une couche dense de 128 neurones pour ne pas conclure l'architecture de l'encodeur par la couche de *dropout*. L'encodeur ainsi défini est composé de 1 701 278 paramètres et renvoie un vecteur de caractéristiques de 128 valeurs pour une vidéo de signe. On change la longueur des séquences d'entrée du modèle - définie à 64 trames pour les signes isolés - pour 16 trames, une valeur utilisée dans la littérature du traitement automatique des langues des signes.

Classification de signes

Dans le cas de la tâche de classification, nous avons ajouté une tête de classification au modèle (fig. 3.4). Il s'agit d'une couche dense dont le nombre de neurones correspond au nombre de classes avec la fonction d'activation *softmax*.

Différentiation de signes

Une façon d'entraîner des extracteurs de caractéristiques est d'apprendre à un modèle à estimer la similarité de deux exemples [CHL05]. Ce type de tâche, appelé apprentissage contrastif, peut être utilisé à la fois dans un contexte non supervisé, ou dans un contexte supervisé [KTW⁺20]. La figure 3.5 donne un aperçu de la structure générale. La fonction de coût est calculée en fonction de la similarité entre les deux vecteurs de caractéristiques. Des vecteurs correspondant à des occurrences d'un même signe doivent avoir une similarité proche de 1 alors que des vecteurs correspondant à des occurrences de deux signes différents doivent avoir une similarité proche de 0.

3.2.4. Expériences

3. https://github.com/hoyso48/Google---Isolated-Sign-Language-Recognition-1st-place/blob/main/ISLR_1st_place_Hyeol_Sohn.ipynb




Figure 3.5 – **Modèle de réseaux siamois**. Le modèle prend deux séquences de poses 3D en entrée. L'encodeur doit prédire des vecteurs de représentation similaires dans le cas où les deux séquences correspondent au même signe, et des vecteurs distincts pour des signes différents.

Training set	Top-1	Top-2	Top-5
100 classes de signes les plus fréquents	71.21	82.37	90.85
1870 classes de signes	0.71	0.90	1.28

Table 3.4 – *Accuracy* obtenue avec la tâche de classification sur l'ensemble de test. Ici, l'ensemble de test contient des signes qui ont été appris lors de l'entraînement.

Détails d'implémentation

Chacun des deux modèles est entraîné pour 150 epochs et les poids finalement conservés sont ceux ayant obtenu le meilleur taux de prédictions (ou score d'*accuracy*) sur l'ensemble de validation. Nous avons utilisé l'optimiseur Adam, le taux d'apprentissage (*learning rate*) est réduit de 90% tous les 10 epochs dans le cas où il n'y a pas eu d'amélioration de l'*accuracy* de validation.

Pour précision, l'*accuracy* est calculée comme suit :

$$accuracy = \frac{TP + TN}{TP + TN + FP + FN} \times 100$$

avec TP (respectivement TN) le nombre de vrais positifs (resp. les vrais négatifs) et FP (resp. FN) les faux positifs (resp. les faux négatifs). Les résultats qui suivent s'intéresseront à l'*accuracy* obtenue pour le Top- n , où l'on considère correcte une reconnaissance du signe lorsque son score apparaît dans les n meilleurs résultats de reconnaissance.

Entraînement des modèles Comme indiqué précédemment, la performance de chaque modèle est mesurée ici à l'aide de l'*accuracy* sur l'ensemble de test, en considérant Top-1, Top-2 et Top-5.

Le tableau 3.4 fournit les résultats d'*accuracy* obtenus en utilisant le modèle de classification tandis que le tableau 3.5 donne les résultats obtenus par le modèle d'apprentissage contrastif. Le modèle de classification donne sans surprise de bons

3.2. STRATÉGIES D'ENTRAÎNEMENT D'EXTRACTEURS DE CARACTÉRISTIQUES À L'ÉCHELLE DU SIGNE

Training set	Test set		
	Vues	Non vues	Toutes
100 classes les plus fréquentes	81.88	76.38	78.09
1870 classes (toutes)	81.59	75.97	78.85

Table 3.5 – **Accuracy obtenue par la tâche d'apprentissage contrastif** sur les ensembles de test de signes vus et non vus. Notons que la taille de l'ensemble de test correspondant aux classes *vues* dépend du nombre de classes utilisées dans l'ensemble d'apprentissage. Par conséquent, sa contribution dans les résultats de la colonne *Toutes* varie également.

résultats. Concernant l'apprentissage contrastif, on n'observe pas de différence notable entre l'entraînement sur les 100 classes les plus fréquentes et l'entraînement sur les 1870 classes. Le score sur les classes non vues nous indique la capacité du modèle à généraliser. Dans les deux cas, autour de 25% des prédictions sur les classes non vues sont erronées.

Bien que la tâche visée paraisse simple, ces résultats montrent qu'il y a encore beaucoup de travail à faire sur le sujet de la reconnaissance des signes en LSF. En effet, nous pouvons supposer que ces résultats sont dus à la grande variabilité inter-signeurs et à la quantité limitée de données. D'autre part, bien qu'isolé dans des segments vidéo, chaque signe est extrait d'une vidéo d'énoncé continu, et a donc été réalisé en contexte, avec de la co-articulation. Il est probable que les transitions inter-signes entraînent des imprécisions dans les prédictions.

Évaluation de la qualité des représentations

Les deux modèles précédents ont permis d'associer un vecteur de représentation, ou plongement, à chacune des séquences de 16 images. Même si les performances d'*accuracy* sont une première indication, il est intéressant d'évaluer la qualité des plongements obtenus. Nous considérons qu'une représentation est bonne lorsqu'elle permet une bonne séparabilité entre les différentes classes, et qu'elle montre une faible variabilité au sein de chaque classe. Le score N2 présenté dans la suite est un exemple d'indicateur de bonne séparabilité inter-classe.

Score N2 La mesure N2 a été proposée par les auteurs de [LGL⁺19]. Cette mesure calcule le ratio de deux sommes : (i) la somme des distances entre chaque échantillon et son plus proche voisin de la même classe (intra-classe); et (ii) la somme des distances entre chaque échantillon et son plus proche voisin d'une autre classe (inter-classe) :

$$\text{intra_extra} = \frac{\sum_{i=1}^n d(x_i, NN(x_i) \in y_i)}{\sum_{i=1}^n d(x_i, NN(x_i) \in y_j \neq y_i)} \quad (3.1)$$

où $d(x_i, NN(x_i) \in y_i)$ correspond à la distance de l'échantillon x_i à son plus proche voisin (NN) de sa propre classe y_i et $d(x_i, NN(x_i) \in y_j \neq y_i)$ représente la distance de x_i au plus proche voisin d'une autre classe $y_j \neq y_i$ (le plus proche ennemi de x_i). À partir du calcul intra/inter-classes, le score N2 se calcule en suivant cette équation :

Encodeur	Classes	N2	SD
Classifieur	100	0.4768	80.13
	1,870	0.4605	76.54
Contrastif	100	0.4487	76.38
	1,870	0.4452	75.97

Table 3.6 – Scores N2 obtenus sur les vidéos de 208 classes de signes non vus, pour les deux types d'encodeur, et pour les deux types d'entraînement : en utilisant les 100 classes les plus représentées, ou l'ensemble des classes.

$$N2 = 1 - \frac{1}{1 + \text{intra_extra}} = \frac{\text{intra_extra}}{1 + \text{intra_extra}} \quad (3.2)$$

Plus le score N2 est bas, plus les classes sont distinctes les unes des autres, donc meilleure est la représentation.

Différentiation avec encodeur gelé Chacun des deux encodeurs a été entraîné pour produire un vecteur de représentation à partir d'une vidéo de signe. Une façon d'évaluer leur qualité, et en particulier leur capacité à généraliser, est de leur présenter des vidéos de nouveaux signes, qui n'ont pas été vus pendant l'entraînement. Nous comparons leur capacité à déterminer si deux signes sont identiques ou différents. Pour comparer les vecteurs obtenus en sortie des encodeurs, la similarité cosinus est employée. Deux vecteurs sont considérés proches lorsque leur similarité est supérieure à 0,5 et distincts en deçà de 0,5. Cela permet d'estimer une mesure d'*accuracy* globale pour chacun des encodeurs, notée SD, pour *sign differentiation*.

Ainsi, le tableau 3.6 montre les valeurs de N2 et de SD obtenues sur les 208 classes n'ayant pas été vues à l'entraînement.

Les résultats sont proches pour les deux modèles. L'encodeur contrastif offre globalement une meilleure séparabilité des classes (selon la métrique N2 qui est plus faible), tandis que l'encodeur classifieur a un avantage lorsqu'il s'agit de comparer les signes 2 à 2 (un SD plus élevé).

Évaluation qualitative

Pour visualiser la pertinence des représentations obtenues, nous plongeons 7 signes, issus de l'ensemble de test des classes non vues, à l'aide des différents encodeurs. L'évaluation sur des classes non vues nous permet de voir si l'encodeur généralise bien en dehors du vocabulaire limité sur lequel il a été appris.

Les signes choisis, illustrés par la figure 3.6, sont les suivants :

- **Étranger** : signe bimanuel non symétrique, avec les mains ouvertes, à plat
- **Évident** : signe bimanuel symétrique, où les deux mains sont en configuration 1 (pouce levé formant le chiffre 1) et partent tous les deux des yeux pour aller vers l'avant
- **Libre** : signe bimanuel symétrique, configuration des mains L, mouvement partant du visage et allant vers le haut

- **Avis (Pour moi)** : la main ouverte, doigts écartés sur la poitrine
- **Rien** : main en configuration en chiffre 1 (pouce levé) allant du menton vers l'avant bas de l'espace de signation
- **Simple** : signe bimanuel symétrique, paumes ouvertes allant de la poitrine vers l'extérieur
- **Sud** : poing fermé partant du haut vers le bas

Les signes RIEN et SUD ont comme point commun d'être monomanuels avec un mouvement dynamique de haut en bas. EVIDENT et RIEN partagent la même configuration, avec des mouvements différents. ETRANGER et SIMPLE partagent une même configuration mais des mouvements distincts. AVIS est peu comparable aux autres signes, du fait de son mouvement vers la poitrine du signeur. Enfin, LIBRE est un signe qui se distingue par des configurations très claires en L.

Les plongements obtenus sont ensuite visualisés à l'aide des outils t-SNE, MDS et PCA sur les trois premières composantes. Pour chacune des visualisations, on s'appuie sur les fonction éponymes de la librairie `scikit-learn`. La t-SNE est initialisée avec une ACP et à un nombre d'itérations maximum de 2000 et une perplexité de 30. La MDS est calculée sur les distances cosinus.

Les plongements obtenus à l'aide de l'encodeur classifieur sont visible sur la figure 3.7 tandis que ceux obtenus avec le modèle contrastif sont visibles sur la figure 3.8.

Quelle que soit la représentation, apprise par classifieur ou par encodeur contrastif, les signes LIBRE, SIMPLE et SUD apparaissent comme les plus distincts. RIEN et SUD sont proches, ce qui peut s'expliquer par la similarité du mouvement de haut en bas. EVIDENT et RIEN ont également des représentations proches. AVIS se distingue peu des autres signes. Une hypothèse avancée est que ce signe est très court et n'est pas toujours bien capté dans la vidéo de 16 images. Les figures permettent également d'illustrer les différences en termes de variabilité intra-classe. Des signes simples comme SUD (un mouvement de haut en bas avec le poing fermé) et ETRANGER, représentés respectivement en vert et rouge sur les figures, montrent une faible dispersion des représentations. Dans de nombreux cas les différentes projections ne montrent pas de clusters clairs qui correspondraient chacun à un signe, certains signes sont mélangés. On peut suggérer deux hypothèses qui pourraient expliquer un tel scénario : soit les représentations obtenues sont trop complexes pour faire apparaître des clusters avec seulement deux composantes, soit l'encodeur n'est pas suffisamment performant. Les représentations obtenues avec la tâche de classification semblent mieux isoler les signes.

Au vu des expériences menées et de leur évaluation, on n'observe pas de différence de qualité notable entre un encodeur entraîné sur une tâche de classification ou une tâche de différenciation. L'encodeur entraîné sur la tâche de classification des 100 classes les plus fréquentes fournit les meilleurs résultats pour ce qui est de différencier des signes.

3.3. Conclusion

Dans ce chapitre, nous avons proposé une première méthode de reconnaissance de signes en continu sur un corpus de LSF, en adaptant une méthode issue de la reconnaissance de la langue parlée complétée [SBH22]. Nous avons montré qu'un




Figure 3.6 – Extraits des vidéos des sept signes utilisés dans l'analyse qualitative.




Figure 3.7 – Visualisations de projections obtenues avec la **tâche de classification** entraînée sur les 100 classes les plus fréquentes. Chaque point correspond à une occurrence et chaque couleur correspond à un signe lexical, la légende donne les gloses associées aux signes choisis.




Figure 3.8 – Visualisations de projections obtenues avec la **tâche d'apprentissage contrastif** des occurrences de 7 signes issus de l'ensemble de test des classes non vues. Chaque point correspond à une occurrence et chaque couleur correspond à un signe lexical, la légende donne les gloses associées aux signes choisis.

modèle multiflux, où chacun des articulateurs principaux est traité séparément, permet une meilleure reconnaissance des signes considérés. Nous utilisons ce modèle pour comparer l'apport des différents articulateurs de la LSF, nos résultats nous permettent d'établir que la main dominante porte le plus d'informations, suivie par la deuxième main, le visage et enfin le reste du corps. L'étude qualitative des résultats nous a permis de montrer que les erreurs du modèle étaient principalement liées au phénomène de répétition en LSF et aux signes ayant des configurations proches.

Dans un second temps, nous nous sommes appuyés sur deux stratégies d'apprentissage pour obtenir des plongements de signes : un apprentissage contrastif et un scénario de classification classique. Nous fournissons une évaluation quantitative et qualitative des plongements obtenus à partir de vidéos de signes non vus pendant l'entraînement. Le scénario de classification classique donne les meilleurs résultats. L'hypothèse que nous faisons est qu'un schéma de classification permet de mieux prendre en compte la forte variabilité intra-classe, en apprenant des encodages qui maximisent les résultats de classification de manière globale. Le modèle contrastif, en comparant les signes un à un individuellement, peut peiner à séparer certaines occurrences de signes.

De ces travaux sur les représentations de signes émergent différentes perspectives de travail. On pourrait chercher à améliorer les scénarios d'entraînement, par exemple en utilisant une fonction de coût équilibrée pour la tâche de classification sur les 1870 classes, c'est-à-dire en pondérant le poids des classes en fonction de leur nombre d'occurrences. Il serait également intéressant de tester différents scénarios d'apprentissage contrastif tels que les *triplet loss*, *n-pair loss* ou *Lifted Structured Loss*.

Les scénarios auto-supervisés constituent une autre piste à l'image de SignBERT [HZZL23] qui s'appuie sur BERT, ou encore VQ-VAE (*Vector Quantised-Variational AutoEncoder*) [MKMB24] dans le projet VQ-SIGN. J'ai mené des expériences préliminaires sur l'entraînement d'un encodeur pour la tâche de reconstruction à base d'auto-encodeur classique mais les résultats sont peu concluants. Les auteurs de [MKMB24] ont publié des analyses intermédiaires sur l'utilisation de VQ-VAE pour obtenir des représentations de signes, les résultats en demi-teinte montrent la complexité de la tâche sur les signes isolés⁴.

Il pourrait être pertinent de tester la méthodologie présentée sur un corpus d'une autre langue des signes pour déterminer si les résultats obtenus donnent les mêmes conclusions.

4. <https://www.speech.kth.se/research/vq-sign/>

Traduction automatique de la LSF

CHAPITRE 4

4.1	Introduction	90
4.2	Travaux existants	91
4.3	Modèle <i>transformer</i> encodeur-décodeur	92
4.3.1	Architecture du modèle de traduction initial	92
4.3.2	Encodage des vidéos de langue des signes	95
4.3.3	Transfert interlangue	96
4.4	Intégrer un pré-entraînement sur le texte	96
4.5	Utiliser des pseudo-gloses pour faciliter la tâche de traduction	99
4.6	Expériences	100
4.6.1	Métriques d'évaluation	100
4.6.2	Entraînement du premier modèle de traduction Transformer	102
4.6.3	Évaluation des différents encodeurs vidéos	106
4.6.4	Transfert inter-langue	107
4.6.5	Pré-entraînement sur le texte	109
4.6.6	Entraînement conjoint classification et traduction	111
4.7	Conclusion et perspectives	113

4.1. Introduction

Alors que de nombreuses langues écrites disposent d'outils de traduction automatique, les langues des signes restent à ce jour écartées de cette technologie au détriment des Sourds signants dont les langues des signes sont les langues *naturelles*. Or, les Sourds signants évoluent dans un contexte linguistique particulier où ils sont confrontés à une langue écrite ou orale qu'ils ont souvent du mal à maîtriser [DH09]. On peut émettre l'hypothèse que des outils de traduction automatique des langues des signes, tels que ceux existant pour des langues écrites, revêtiraient un intérêt particulier pour les personnes sourdes signantes.

Dans le chapitre précédent, nous avons traité de la reconnaissance continue de séquences de signes en LSF, c'est-à-dire une tâche linéaire consistant à reconnaître des gloses dans le même ordre temporel que celui de la production des signes auxquels elles sont associées. Dans ce chapitre nous abordons la traduction qui intègre cette fois-ci la question complexe de la mise en correspondance de la grammaire propre de la langue des signes, une langue non écrite, avec celle d'une langue écrite comme le Français.

Le principal frein à la mise au point de tels outils est la quantité de données nécessaire pour entraîner les modèles de traduction généralistes sur lesquels ils reposent. Depuis 2018, grâce à l'émergence de corpus de plus grande taille [KFN15, DPV⁺21, AVM⁺21, UTG23], de premiers travaux exploitant les modèles d'apprentissage profond ont pu être menés sur la langue des signes allemande [CHK⁺18, CKHB20b], la langue des signes britannique [AVM⁺21] ou la langue des signes américaine [UTG23, GDSL24, DAGiNV22]. Les corpus existants de LSF ne permettaient pas jusque là d'imaginer de telles méthodes mais la mise à disposition du corpus Mediapi-RGB, à laquelle nous avons contribué (voir chapitre 2), a changé la donne puisqu'il s'agit d'un des premiers corpus de LSF intégralement traduit (après Mediapi-Skel [BBG20b]) et de loin le plus volumineux (3 fois la taille de Mediapi-Skel). Dès lors, il s'agit d'appliquer un modèle de traduction de la LSF vers le français pour établir de premières lignes de base sur ce corpus pouvant servir d'étalons et permettant d'évaluer la pertinence du corpus et la complexité de la tâche.

Dans ce chapitre, nous explorons différentes stratégies de traduction en s'appuyant sur le nouveau corpus de LSF Mediapi-RGB et en s'inspirant des travaux déjà menés sur d'autres langues des signes. Après avoir décrit quelques-uns des travaux existants, nous décrivons dans la partie 4.3 un premier modèle de traduction fondé sur un modèle de type *Transformer*. Nous y proposons des extensions et variantes de ce premier modèle; tout d'abord en modifiant les représentations de la LS en entrée, puis en étudiant l'impact d'un transfert interlangue, d'une langue des signes à une autre. Un deuxième modèle de traduction permet d'évaluer le transfert d'une langue écrite à une autre (section 4.4). La section 4.5 propose d'exploiter un entraînement conjoint classification-traduction, où la tâche de classification permet de guider la traduction. Les expériences et résultats sont présentés dans la section 4.6.

4.2. Travaux existants

Les premiers travaux de traduction [CHK⁺18, CKHB20b] ont principalement été menés sur le corpus de langue des signes allemande Phoenix-RT-2014 [KFN15], traduit en allemand et annoté en gloses. Les méthodes développées s'appuient, pour la plupart, sur les annotations en gloses fournies avec le corpus. Malgré la durée du corpus (10,5h) qui reste modeste mais grâce au champ lexical réduit car centré sur les bulletins météorologiques, la meilleure méthode [GWM⁺24] permet d'obtenir une qualité de traduction satisfaisante, c'est-à-dire proche des résultats obtenus sur la traduction de l'anglais écrit vers l'allemand écrit sur un corpus généraliste [TK23] avec

une métrique 13% inférieure¹. La méthode [GWM⁺24] s'appuie sur un encodeur par articulateur, où chacun d'entre eux est représenté sous forme de points de pose (squelette). Chaque encodeur est appris de façon conjointe pour la reconnaissance de gloses et la traduction.

Cependant le corpus Phoenix-RT-2014 présente quelques inconvénients, il s'agit de langue des signes interprétée en direct, ce qui diffère de la langue des signes utilisée par des sourds, et les traductions comportent des erreurs.

Plus récemment les corpus de langue des signes américaine (ASL) How2Sign [DPV⁺21] (2021), Open-ASL [SBSL22] (2022) et YouTube-ASL [UTG23] (2023) ont vu le jour. Il s'agit de corpus de grande taille, au contenu sémantique varié, et qui contiennent majoritairement des énoncés réalisés par des personnes sourdes. Le corpus How2Sign, de grande qualité et enregistré en laboratoire, est devenu une référence pour la traduction automatique de l'ASL. Les autres corpus ne sont pas adaptés à l'évaluation car ils s'appuient sur des vidéos susceptibles de disparaître. En effet, celles-ci sont issues de sites internet tiers sur lesquels les auteurs des jeux de données n'ont pas la main [SBSL22, UTG23].

Le meilleur score BLEU-4² obtenu avec le corpus How2Sign est de 8,03 [TGD⁺23], ce qui montre la difficulté d'entraîner des modèles sur des corpus ayant un vocabulaire plus large. En revanche plusieurs travaux ont montré le bénéfice d'un pré-entraînement sur YouTube-ASL puis un ajustement (*fine-tuning*) pour la traduction sur How2Sign [GDSL24, UTG23, RSW⁺24]. Le score BLEU-4 monte alors à 14,7 [RSW⁺24].

4.3. Modèle *transformer* encodeur-décodeur

Comme expliqué dans la section 1.4.1, les méthodes les plus répandues en traduction des langues des signes se fondent sur des modèles *transformer* encodeur-décodeur. En entrée de l'encodeur, le flux de langue des signes est représenté sous forme de séquences de caractéristiques visuelles. Celles-ci sont obtenues à l'aide d'un encodeur entraîné sur une tâche de classification de signes isolés [TGD⁺23, AVM⁺21, AGLB22]. Le décodeur produit du texte de façon auto-régressive, exactement comme pour les modèles de traduction des langues écrites (voir section 1.4.1). Dans cette section, nous présentons en détail cette architecture.

4.3.1. Architecture du modèle de traduction initial

La figure 4.1 donne un aperçu de l'architecture utilisée, qui est détaillée ci-après.

La partie encodeur

Entrée. Dans la première version du modèle, la langue des signes est fournie en entrée sous forme de vecteurs de caractéristiques pré-extraits à partir de l'encodeur

1. La métrique utilisée ici, le BLEU-4 est décrite dans la partie expérimentale, et elle est de 29 contre 33,34.

2. Le score BLEU-4 est décrit dans la partie expérimentale.




Figure 4.1 – **Vue d'ensemble de l'architecture transformer utilisée.** Le modèle prend en entrée des caractéristiques Video Swin extraites sur les vidéos et prédit en sortie du texte en français.

VideoSwinT-BSL [LNC⁺22, PBM⁺22]. Il s'agit d'un modèle *Video Swin Transformer* [LNC⁺22] entraîné pour la classification de signes pour la langue des signes britannique [PBM⁺22] (voir chapitre 2). La dimension du vecteur obtenu est de $768 \times t$ où t correspond au nombre de trames. On ajoute du *padding* aux séquences de façon à ce qu'elles aient toutes la même longueur.

Encodage positionnel. L'architecture *transformer* ne traite pas les séquences de manière séquentielle, trame par trame, mais parallèlement grâce aux mécanismes d'attention masqués. L'encodage positionnel est crucial pour maintenir une notion explicite de l'ordre, malgré ce traitement simultané. Concrètement, chaque vecteur d'entrée est enrichi par un encodage positionnel sinusoïdal, ce qui permet au modèle de conserver la structure positionnelle des éléments dans la séquence, et ainsi d'exploiter l'ordre des trames malgré l'absence de traitement itératif.

Encodeur *transformer*. La partie encodeur consiste en deux couches d'encodeur *transformer*³, ces deux couches sont mises en série puis fournissent un vecteur de 768 valeurs par trame à la partie décodeur.

La partie décodeur

La partie décodeur prédit du texte à partir de la sortie de l'encodeur. Il s'agit d'un décodeur *transformer* auto-regressif composé d'une couche, qui est entraînée à prédire un *token* masqué en connaissant les précédents. Lors de la phase d'inférence, on ne lui fournit que le *token* de début de phrase, et le modèle prédit les *tokens* suivants, les uns après les autres.

3. Le nombre de couches a été fixé de façon empirique.

Tokenization. Le découpage du texte en *tokens* se fait lors de l'étape de *tokenisation*. Les auteurs de SentencePiece [KR18] ont montré que l'utilisation de sous-unités de mots (appelées *subwords*) pouvait donner de meilleurs résultats qu'un découpage en mots pour diverses tâches de traitement automatique des langues. Ces *subwords* peuvent être des parties de mots, des caractères ou parfois des mots entiers. Le fonctionnement de SentencePiece est statistique et non-supervisé. Le *tokenizer* est construit à partir d'un corpus qui lui est fourni en entrée et peut ensuite être réutilisé sur d'autres corpus. Le nombre de classes de *tokens*, noté n , est un paramètre fixé en amont de l'entraînement. Dans le cas de ce modèle de traduction, nous avons utilisé un *tokenizer* SentencePiece entraîné sur le corpus de textes en français OSCAR-fr [AORS22] par les auteurs de CamemBERT [MMOS⁺20]. En effet, nos résultats expérimentaux montrent que le fait d'entraîner un *tokenizer* directement et exclusivement sur le texte de Mediapi-RGB n'améliore pas les résultats de traduction mais les détériore légèrement en comparaison de la *tokenisation* avec le *tokenizer* entraîné sur OSCAR-fr, un grand jeu de données de bien plus grande taille.

La couche d'embedding. À l'issue du processus de *tokenisation*, les séquences de *tokens* sont fournies à une couche d'*embedding*. Il s'agit d'une couche cachée qui projette les *tokens* dans un espace à plusieurs dimensions (768 dans notre cas), chaque indice de *token* devient un vecteur de 768 valeurs. Cette étape, appelée plongement, permet de réduire la dimensionnalité du texte *tokenisé*. En effet, dans le cas d'un encodage *one-hot*, chaque *token* est représenté par un tableau de n valeurs ($n = 35000$ dans notre cas) et où chaque colonne contient un zéro, à l'exception de celle qui correspond à la classe du *token* donné, qui est mise à un. Avec une couche d'*embedding*, chaque *token* du texte d'entrée est représenté sous la forme d'un vecteur de dimension d où d correspond à la taille de l'*embedding* obtenu en sortie de la couche (768 dans notre cas), d étant beaucoup plus petit que n , la couche d'*embedding* permet une vraie réduction de la dimension d'entrée. La sortie de la couche d'*embedding* est ensuite concaténée à un encodage positionnel, de façon similaire à ce qui est fait dans la partie encodeur.

La couche décodeur *transformer*. Un module décodeur *transformer* fonctionne de manière similaire à un module encodeur, mais présente deux différences principales. La première est que la couche d'attention auto-régressive applique un masque sur les *tokens* futurs : le modèle doit ainsi prédire chaque token en ne tenant compte que des *tokens* précédemment générés, empêchant l'accès à des informations futures non encore prédites. La deuxième différence repose sur le mécanisme d'attention croisée. Ce mécanisme permet à la couche d'attention d'incorporer les représentations produites par l'encodeur dans le calcul de l'attention, renforçant la capacité du décodeur à générer des prédictions en se basant sur les caractéristiques extraites par l'encodeur (dans notre cas, le flux de langue des signes).

Couche dense de sortie. La couche décodeur *transformer* travaille dans l'espace d'*embedding*, et retourne une séquence de *tokens* projetés dans l'espace d'*embedding*. On s'appuie donc sur une couche dense pour revenir à un encodage en classes de tokens. Pour cela, on met en sortie de la couche d'encodeur du *transformer*, une couche

pleinement connectée dont la dimension de sortie correspond à n , c'est-à-dire au nombre de classes du *tokenizer*.

4.3.2. Encodage des vidéos de langue des signes

À partir du modèle de traduction détaillé précédemment, nous souhaitons étudier l'impact du choix de la représentation d'entrée. Nous comparons quelques encodeurs en nous appuyant sur la ligne de base présentée dans la section précédente : en gardant la même architecture, les caractéristiques VideoSwinT-BSL sont remplacées par les caractéristiques obtenues par d'autres encodeurs. Ceux-ci ont été entraînés à partir de corpus différents : DictaSignLSF-ISOL-100 (voir chapitre 3), corpus de LSF construit au LISN et BSL-1K (voir le chapitre 2). Ces deux corpus ont été choisis car ils disposent d'annotations en gloses, rendant possible un apprentissage supervisé. Le corpus BOBSL [AVM⁺21] utilisé pour entraîner l'encodeur VideoSwinT-BSL, demanderait trop de ressources (plus de 1200h de vidéo).

Coordonnées Mediapipe normalisées. Nous considérons une version du modèle où les coordonnées Mediapipe sont exploitées. Elles sont préalablement normalisées en suivant la même normalisation que celle présentée dans la section 3.2.2. Cette stratégie assez rare dans la littérature, ne permet pas de bénéficier d'un pré-entraînement sur une autre tâche.

Modèle LS Kaggle entraîné sur DictaSignLSF-ISOL-100. À l'aide de ces mêmes coordonnées Mediapipe, on extrait des caractéristiques avec l'encodeur présenté dans la section 3.2.3 et entraîné sur DictaSignLSF-ISOL-100. L'encodeur est appliqué par fenêtre glissante de 16 trames : pour chaque trame, la fenêtre comprend les 7 trames précédentes et les 8 trames suivantes et le vecteur de caractéristiques obtenu est constitué de 128 valeurs.

Modèle LS Kaggle sans pré-entraînement. Une autre version consiste à considérer le même modèle sans pré-entraînement et non gelé, c'est-à-dire que ses poids sont appris directement pendant la tâche de traduction, de bout en bout. Pour limiter l'empreinte mémoire de l'entraînement, l'extraction de caractéristique ne se fait plus par fenêtre glissante de 16 trames mais en prenant toute la longueur des vidéos utilisées pour la traduction (700 trames), la couche de *Pooling* temporel est retirée pour sortir un vecteur de 768 caractéristiques par trame.

Modèle Video Swin T entraîné sur DictaSignLSF-ISOL-100. Nous avons construit de nouveaux vecteurs caractéristiques en entraînant un modèle Video Swin Transformer (version *tiny*) sur le corpus DictaSign-ISOL-100 pour une tâche de classification des 100 signes les plus fréquents de DictaSign-LSF. Pour information, le modèle est entraîné sur 50 epochs avec une taille de batch de 8, un taux d'apprentissage de 10^{-4} en utilisant l'optimiseur Adam [KB14]. Le modèle atteint une accuracy de 68% sur l'ensemble de test (classes vues) de DictaSignLSF-ISOL-100.




Figure 4.2 – **Exemples de tâches prétextes pour l'entraînement du modèle T5.** Figure issue de [RSR⁺20].

Modèle I3D entraîné sur BSL-1K. On utilise une version du modèle I3D [CZ17], entraîné sur [SFR⁺13] par les auteurs de [AVM⁺20] sur leur ensemble de données BSL-1K [AVM⁺20]. Ce modèle a été utilisé dans d'autres travaux de traduction automatique de langue des signes britannique [AVM⁺21] et américaine [DPV⁺21].

La section expérimentale permettra de comparer les qualités des traduction obtenues à l'aide de ces différentes représentations.

4.3.3. Transfert interlangue

Des études portant sur les langues écrites ont montré qu'un pré-apprentissage sur une autre langue pouvait aider l'apprentissage sur une langue cible [KMB21]. Dans le domaine des langues des signes, le pré-apprentissage sur une autre LS est souvent limité aux extracteurs de caractéristiques. Or, de façon similaire à ce qui peut être observé sur les langues écrites ou orales, les langues des signes peuvent partager des similitudes ou du vocabulaire de façon plus ou moins significative selon qu'elles appartiennent ou non à la même famille de langues des signes (voir la section). On peut donc émettre l'hypothèse que, dans le cas de la traduction des langues des signes, un pré-apprentissage sur une langue des signes de la même famille puisse aider l'apprentissage du modèle. Étant donné que la LSF et l'ASL appartiennent à la même famille de langues des signes [Can16, PGL20], nous avons cherché à établir si un pré-entraînement sur un corpus d'ASL pouvait aider la traduction de la LSF sur Mediapi-RGB.

4.4. Intégrer un pré-entraînement sur le texte

Le domaine du traitement automatique du langage naturel s'appuie sur des corpus de très grande taille pour les langues les mieux dotées comme l'anglais et le français. Ces corpus permettent l'entraînement de grands modèles de langage. Certains modèles tels que BERT [DCLT19] offrent la possibilité d'obtenir des plongements sémantiques du texte pouvant servir en entrée d'autres modèles. Dans le contexte de la traduction automatique de LS vers texte, l'utilisation de ces modèles BERT tels quels pour obtenir des plongements n'est pas adaptée, car un plongement sémantique à l'échelle de la phrase ne permet plus à la partie décodeur d'apprendre à générer du texte par le masquage [DCLT19].




Figure 4.3 – **Aperçu de la méthode de traduction proposée par les auteurs de YouTube-ASL [UTG23].** Les vidéos sont transformées en coordonnées Mediapipe normalisées puis fournies au modèle T5.1 qui doit fournir une traduction de la langue des signes en langue écrite.

Cependant, une autre famille de modèles, les modèles de génération conditionnée de texte [LGG⁺20, ETV20, CHL⁺22, CHL⁺22], peuvent permettre de bénéficier du pré-entraînement pour la génération de texte, tout en ajoutant une modalité d'entrée. Ce sont des modèles de texte qui à partir d'un texte, génèrent un autre texte pour répondre à une tâche. Ces modèles peuvent être mono-lingues ou multi-lingues. L'utilisation de tels modèles dans le cadre de la traduction automatique LS vers texte est plus adaptée, il faut alors remplacer l'entrée textuelle du modèle par une entrée langue des signes tout en gardant la sortie texte du modèle [UTG23].

Le modèle T5 (*Text-to-Text Transfer Transformer*) [RSR⁺20] est un modèle s'appuyant sur des *transformers* pour traiter de multiples tâches du traitement automatique du langage naturel tels que des problèmes de génération conditionnée. Le pré-apprentissage du modèle se fait sur un jeu de données de taille gigantesque et sur un grand nombre de tâches prétextes, ce qui a permis au modèle d'avoir de bons résultats pour de nombreuses tâches tels que la traduction ou la réponse à des questions. La figure 4.2 donne un aperçu de différentes tâches utilisées pour le pré-entraînement.

Plusieurs travaux sur la langue des signes américaine se sont ainsi appuyés sur le modèle T5.1⁴ pour la traduction automatique de la langue des signes américaine vers le texte [UTG23, RSW⁺24, GDSDL24].


Le modèle T5 [RSR⁺20], pré-entraîné sur du texte, est affiné pour prendre une nouvelle modalité d'entrée, la langue des signes américaine. Comme pour un modèle *transformer* classique, on fournit au modèle des couples phrase en langue des signes et traduction en langue écrite et le modèle doit apprendre à passer de l'un à l'autre. Dans [UTG23], les auteurs s'appuient sur le corpus How2Sign [DPV⁺21], les vidéos sont transformées en coordonnées Mediapipe normalisées puis fournies au modèle T5. La figure 4.3 donne un aperçu de la méthode proposée par [UTG23]. Avec différentes configurations, les auteurs montrent que le pré-entraînement sur les tâches texte-vers-texte permet une amélioration des résultats en traduction de l'ASL (amélioration de 0,3 à 6 de score BLEU en fonction des données d'entraînement).

Dans le cadre de nos travaux, nous avons reproduit l'expérience présentée dans [UTG23] d'abord avec les mêmes données : le corpus How2Sign [DPV⁺21], pour

4. Le modèle T5.1 est une amélioration de l'architecture du modèle T5.

Étape 1

Pré-entraînement texte vers texte multitâche



Étape 2

Affinage pour la traduction de la LSF vers le français écrit




Figure 4.4 – **Fonctionnement de la méthode proposée.** Dans un premier temps le modèle apprend à exécuter des tâches texte vers texte. Puis, le modèle est affiné pour traduire la langue des signes française vers le français. Le *prompt* est plongé avec la couche de plongement textuel alors que les vidéos sont plongées avec des caractéristiques visuelles.

être sûr de l'implémentation⁵, puis avec les données de Mediapi-RGB. La figure 4.4 donne un aperçu de la méthode utilisée.

À titre de comparaison, nous avons également testé le modèle Flan T5 [CHL⁺22], il s'agit d'un modèle T5.1 entraîné avec de nouvelles tâches, issues du papier FLAN [WBZ⁺21]. Ce modèle a été pré-entraîné sur des tâches diverses avec un prompt, c'est à dire une instruction donnée en plus du texte d'entrée, par exemple : "Résume moi ce texte :". Nous ajoutons donc le prompt "translate this French Sign Language embedding vector to French :"⁶. On récupère la couche d'embedding de texte de FLAN-T5 pour plonger le prompt, puis on le concatène avec les caractéristiques swin. Enfin, nous avons testé BART⁷ [ETV20], il s'agit d'un modèle BART [LGG⁺20] entraîné sur un corpus d'actualités en français, le corpus OrangeSum, issu d'une collecte des articles du site Orange actualités. La tâche de pré-entraînement est la génération de résumés d'articles.

La partie expérimentale permet de comparer les résultats obtenus avec ces modèles.

4.5. Utiliser des pseudo-gloses pour faciliter la tâche de traduction

Le corpus Phoenix-2014-RTWH [KFN15] est l'un des premiers corpus à avoir permis l'utilisation de méthodes d'apprentissage profond pour la traduction d'une langue des signes vers le texte. Ce corpus étant annoté en gloses, la plupart des méthodes de traduction proposées ont cherché à s'appuyer sur ces annotations pour faciliter la tâche de traduction et ainsi obtenir de meilleurs résultats. En plus de la fonction de coût de traduction (sur les tokens de texte traduit), le modèle s'appuie sur une fonction de coût de reconnaissance de signes en sortie de l'encodeur. Ainsi, l'encodeur du modèle de traduction est conjointement entraîné à reconnaître des signes. D'après les résultats obtenus par les auteurs, cet apprentissage conjoint des tâches de reconnaissance et de traduction permet une augmentation du score BLEU-4 de 8%.

Le corpus sur lequel nous travaillons, Mediapi-RGB n'est pas annoté en gloses. L'annotation en gloses est une tâche longue et coûteuse qui doit être idéalement menée par des experts. Cependant, nous avons noté que deux instances d'un même signe tendaient à être très similaires dans l'espace de représentation obtenu avec l'encodeur VideoSwinT-BSL. À l'aide de l'algorithme k -moyennes, nous regroupons les vecteurs de caractéristiques similaires en clusters. Ainsi, nous obtenons un label de cluster par trame. Ensuite les labels identiques sur les trames successives sont regroupés en un seul identifiant ce qui donne une suite réduite d'identifiants en s'affranchissant du niveau trame. Ces identifiants de cluster (appelés labels dans la suite) sont ensuite utilisés selon le principe proposé par les auteurs de [CKHB20b], à la place des gloses.

Dans le cadre de notre collaboration au sein de l'équipe CRISSP du GIPSA-lab et des équipes du LISN⁷, nous adaptons ce principe de modèle de traduction à notre étude comme suit, avec le modèle décrit par la figure 4.5. Tout d'abord, la vidéo

5. Les auteurs de [UTG23] n'ont pas partagé leur code.

6. En français : "Traduis ce vecteur de plongement de langue des signes française vers le français."

7. Ce travail fait l'objet d'une collaboration avec Diandra Fabre, Julie Lascar et les équipes encadrantes et est l'objet d'une publication soumise à une conférence.




Figure 4.5 – Illustration du modèle d'apprentissage conjoint classification-traduction.

brute à images est encodée en une séquence de segments visuels (typiquement les paramètres video-swin transformers). Cette séquence de labels est ensuite traitée par un encodeur composé de blocs de *Transformers*. La sortie de l'encodeur est envoyée dans deux branches parallèles : un décodeur auto-régressif, également construit avec des blocs de *Transformers*, qui génère du texte *token* après *token*, et un classifieur *feed-forward* qui prédit les probabilités *a posteriori* d'un ensemble de labels donnés à chaque trame de la séquence vidéo. L'ensemble du modèle est entraîné dans un cadre multi tâches, optimisant à la fois un coût classique de traduction pour le décodeur et un coût CTC pour le classifieur de signes en labels de pseudo-gloses. Il est important de noter que l'utilisation du CTC permet de s'affranchir de l'alignement temporel sur les trames pour chaque label (voir fig. 4.5)

4.6. Expériences

Cette section vise à détailler les expériences menées et à étudier les résultats obtenus, en termes de qualité de traduction. Nous commençons par décrire les métriques utilisées.

4.6.1. Métriques d'évaluation

L'évaluation se fait sur les vidéos de l'ensemble de test. Il faut donc générer chacune des phrases de façon auto-régressive, c'est-à-dire *token* après *token* (voir chapitre 4, section 1.4.1) jusqu'à ce qu'on rencontre le token de fin de phrase (`<eos>`).

BLEU

La métrique BLEU [PRWZ02], ou *Bilingual Evaluation Understudy*, est utilisée pour évaluer la qualité des traductions automatiques en comparant une traduction

candidate avec une traduction de référence. Le calcul de score BLEU se fait en plusieurs étapes. Dans un premier temps la phrase prédite et la phrase de référence (vérité terrain), sont tokenisées.

$ref = \text{Il fait beau aujourd'hui}$
 $pred = \text{Aujourd'hui il fait beau beau beau}$

Puis à l'étape de tokenisation :

$ref = \text{Il, fait, beau, au, jour, d', hui}$
 $pred = \text{Au, jour, d', hui, il, fait, beau, beau, beau}$

Les séquences de tokens sont ensuite mises sous la forme de séquences de n -grammes, pour n allant de 1 à 4. Pour chaque valeur de n , on calcule la précision modifiée obtenue. Le calcul de la précision classique se fait de la façon suivante :

$$\text{Précision} = \frac{\text{Vrais Positifs}}{\text{Vrais Positifs} + \text{Faux Positifs}} \quad (4.1)$$

La précision modifiée consiste à plafonner le comptage de chaque vrai positif avec son nombre d'occurrences dans la vérité terrain. Si on prend l'exemple précédent, le mot "beau" serait compté plusieurs fois comme vrai positif avec la précision classique mais il n'est compté qu'une seule fois avec la précision modifiée.

Une des limitations de la précision modifiée est qu'elle ne prend pas en compte les délétions, c'est à dire les n -grammes de la référence qui n'apparaissent pas dans la prédiction. Pour prendre ce phénomène en compte, le calcul du score BLEU intègre une pénalité de brièveté : si la longueur " c " de la phrase prédite est inférieure à la longueur " r " de la référence alors la précision modifiée est diminuée d'un facteur exponentiel. Le score BLEU final correspond alors à la moyenne géométrique pondérée des précisions modifiées, multipliée par la pénalité de brièveté BP :

$$\text{BP} = \begin{cases} 1 & \text{if } c > r \\ e^{(1-r/c)} & \text{if } c \leq r \end{cases} \quad (4.2)$$

$$\text{BLEU} = \text{BP} \cdot \exp \left(\sum_{n=1}^N w_n \log p_n \right) \quad (4.3)$$

où w_n correspond au poids issu d'un vecteur de poids. Par défaut, le vecteur de poids du score bleu donne un poids w_n de $\frac{1}{N}$ pour toutes les précisions modifiées p_n .

Limitations Le score BLEU ne prend pas en compte le sens mais seulement la présence ou non de n -grammes. Le score BLEU dépend de plusieurs paramètres comme le tokenizer utilisé ou le type de pénalité de brièveté. Pour que les résultats soient comparables d'une évaluation à l'autre, les auteurs de [Pos18] ont proposé Sacre-BLEU, une façon uniformisée de calculer le score BLEU pour plus de comparabilité. L'interprétation d'un score BLEU pour jauger la qualité d'une traduction dépend de

la langue, la variabilité de la langue (casse typographique, conjugaison, genre, pluriel, ponctuation, etc.) influe sur les résultats du score BLEU, ou chaque token a la même valeur. Une erreur d'accent ou de ponctuation peut avoir le même poids qu'une erreur de mot.

BERT score

Le BERT score [ZKW⁺] suit le principe du score BLEU classique mais ne se calcule pas sur les tokens mais sur les plongements BERT de chaque mot à l'aide d'une mesure de la similarité cosinus. Ce qui permet théoriquement de prendre en compte le sens et de ne pas pénaliser les prédictions qui utiliseraient des synonymes. La figure 4.6 donne un aperçu du fonctionnement de cette métrique.




Figure 4.6 – **Aperçu du fonctionnement de la métrique BERT score.** Figure issue de [ZKW⁺].

BLEURT

BLEURT est une alternative à BLEU proposée par Sellam et al. [SDP20]. C'est une métrique qui s'appuie sur un encodeur BERT pré-entraîné sur plus de 100 langues dont le français, puis affiné pour une tâche d'évaluation de qualité de traduction d'abord sur des données synthétiques, puis sur des données issues d'évaluations humaines. Le score BLEURT montre une bonne corrélation avec les évaluations humaines.

Un des inconvénients de BLEURT est qu'il mobilise un modèle pour l'obtention de la métrique, ce qui rend le calcul plus long (autour de 2h pour l'ensemble de test de Médiapi-RGB).

4.6.2. Entraînement du premier modèle de traduction Transformer

L'architecture présentée dans la partie 4.3 est implémentée à l'aide des bibliothèques Tensorflow [AAB⁺15] et Keras-NLP [WQB⁺22], le modèle est composé de 173 millions de paramètres. L'entraînement se fait sur un GPU NVidia A6000.

Hyperparamètres

Afin d'entraîner le modèle que nous obtenons, nous avons utilisé les hyperparamètres présentés dans le tableau 4.1.

Chacun de ces hyperparamètres peut avoir un impact — plus ou moins important — sur la qualité de la traduction. Il n'existe pas de méthodes permettant de déterminer les hyperparamètres optimaux sans entraîner le modèle. Or, puisque

Table 4.1 – Hyperparamètres du modèle de traduction *transformer* sur Mediapi-RGB.

Hyperparamètre	Valeur
Taux d'apprentissage	10^{-3}
Fonction de coût	Entropie croisée
Taille du vocabulaire	35000
Tokenizer	SentencePiece entraîné sur OSCAR-fr
Longueur maximale de séquence de tokens	50
Dimension de l'embedding de texte	768
Longueur maximale de caractéristiques Swin	700
Nombre de têtes d'attention	8
Nombre de couches de l'encodeur	2
Nombre de couches du décodeur	1
Patience pour la réduction du taux d'apprentissage	7
Patience pour l'arrêt précoce	15
Optimiseur	RMSPProp
Dimension du réseau <i>feed-forward</i>	64
Taux de Dropout	0.4

L'entraînement d'une version du modèle sur Mediapi-RGB prend environ 12h, faire varier chacun de ces hyperparamètres pour en déterminer la meilleure valeur s'avère être une tâche démesurément coûteuse en ressources (temps, énergie) avec la configuration matérielle précisée plus haut. Pour tenter de faire face à ce problème, nous avons commencé par utiliser les hyper-paramètres utilisés sur d'autres travaux de traduction de langue des signes [TGD⁺23, CKHB20b], puis nous nous sommes appuyés sur les algorithmes de recherche d'hyperparamètres *HyperBand* [LJD⁺18] et *GridSearch* [SD19]. Ces algorithmes permettent d'explorer l'espace des hyperparamètres à partir d'un petit nombre d'epochs. Dans notre cas, leur utilisation ne nous a pas permis d'obtenir de meilleurs résultats que ceux obtenus avec la configuration de base.

Programme d'apprentissage

On définit le nombre maximal d'epochs à 100 mais on arrête l'entraînement plus tôt quand il n'y a pas d'amélioration de la fonction de coût sur la validation pendant 15 epochs (principe d'*early stopping*). Avec ce scénario, l'entraînement s'est arrêté au bout de 67 epochs pour les résultats présentés dans le tableau 4.2, on conserve le modèle ayant une valeur de fonction de coût la plus basse (obtenu lors du 52^{ème} epoch). Le taux d'apprentissage est réduit après 7 epochs sans amélioration de la fonction de coût sur la validation. Simultanément à la réduction du taux d'apprentissage, on rétablit les poids ayant obtenu la plus basse valeur de la fonction de coût sur la validation. Un epoch (entraînement et validation) prend environ 8 minutes, ce qui donne une durée d'entraînement d'environ 9h sur un GPU NVidia A6000.

Table 4.2 – **Scores BLEU, BLEURT et BERT (F1)** obtenus avec notre baseline de traduction sur les données d'entraînement et de test de Mediapi-RGB.

	Train			Test					
	BLEU-4	BLEURT	BERT-S	BLEU-1	BLEU-2	BLEU-3	BLEU-4	BLEURT	BERT-S
Baseline	6.39	12.69	70.85	21.56	11.06	6.74	4.38	10.83	69.96

Résultats

Le tableau 4.2 donne les scores BLEU, BLEURT et BERT F1 obtenus sur l'ensemble d'entraînement et de test avec le modèle *transformer*.

Enfin, le tableau 4.3 donne des exemples de résultats pour différentes valeurs de score BLEURT classées du plus haut au plus bas. On observe une bonne corrélation du score BLEURT avec la qualité des traductions. Le score BERT semble aussi bien suivre le sens du texte mais ne descend jamais en dessous de 60, même pour des traductions très mauvaises.

Le score BLEU-4, qui est la référence dans le domaine de la traduction automatique n'est pas toujours corrélé avec le sens. Il peut être de 0 alors que le sens de la phrase est conservé. Cela s'explique par la façon dont il est calculé en s'appuyant uniquement sur les suites de *tokens* sans prise en compte du sens.

Pour avoir une vision plus précise des résultats, nous nous appuyons sur les noms du vocabulaire que nous fournissons avec Mediapi-RGB (voir chapitre 2). Nous extrayons les noms dans la référence et dans la traduction, et pour chacun des noms de la référence nous calculons le score F1 [TH15] par rapport à la référence. La figure 4.7 donne les 45 mots les mieux reconnus. On observe un nombre important de mots relatifs à la date, *février* est correctement prédit dans plus de 90% des phrases de l'ensemble de test. Les mois et les jours de la semaine suivent. On retrouve les lemmes⁸ les plus fréquents de l'ensemble d'entraînement, mais il n'y a pas de corrélation exacte avec le nombre d'occurrences. Par exemple le mot "Macron" est mieux reconnu que "président" qui apparaît pourtant deux fois plus souvent. On voit plusieurs chiffres qui apparaissent pourtant peu souvent dans le corpus, ce qui laisse supposer que le modèle a intégré en partie le fonctionnement du comptage en LSF.

La figure 4.8 montre la distribution des scores de BLEURT sur l'ensemble de test. On observe que la grande majorité des résultats est autour de 0.

Le tableau 4.4 donne une comparaison avec les résultats obtenus sur des corpus d'autres langues des signes et d'autres langues écrites, le score BLEU-4 est dépendant de la langue cible, donc difficilement comparable d'une langue à l'autre. Il est à considérer comme un ordre de grandeur plutôt que comme un étalon. Remarquons que le score BLEU semble corrélé avec la taille du vocabulaire. On peut voir que ce premier modèle de traduction sur la LSF avec Mediapi-RGB donne des résultats du même ordre de grandeur que les autres corpus similaires existants pour d'autres langues des signes. Le score BLEURT permet une bonne évaluation de la traduction.

8. Un lemme correspond à la forme canonique d'un mot, c'est à dire la façon dont il serait écrit dans le dictionnaire, par exemple "mangerais" deviendrait "manger" et "bergères" deviendrait "berger".




Figure 4.7 - **Les 45 noms de l'ensemble de test ayant le plus haut score F1 en traduction.** Le score F1 obtenu est en bleu et le nombre d'occurrences (par lemme) dans l'ensemble d'entraînement est en rouge.
 Pour rappel $F_1 = 2 \cdot \frac{(\text{précision} \cdot \text{rappel})}{(\text{précision} + \text{rappel})}$

Table 4.3 – **Exemples de traductions obtenues sur l'ensemble de test de Mediapi-RGB** à l'aide du modèle *transformer* encodeur-décodeur.

Référence	Prédiction	BLEU-4	BLEURT	BERT-S
Bienvenue dans i'Média !	bienvenue dans i'Média !	0.0	90.29	96.41
Bonjour, nous sommes aujourd'hui le mercredi 10 avril 2019.	Nous sommes le mercredi 10 avril 2019,	28.32	83.37	87.22
Si vous connaissez les signes de ces quelques mots, n'hésitez pas à nous envoyer une vidéo !	Si vous connaissez les signes de ces mots, merci de nous envoyer vos vidéos !	40.41	76.49	89.10
Dix personnes ont perdu la vie.	et 10 personnes sont mortes.	0.0	62.45	79.37
Le ministre de l'Éducation nationale Jean-Michel Blanquer	Le ministre de l'Éducation nationale, Jean-Michel Blanquer, a annoncé	0.0	51.93	88.21
Il remporte ainsi son huitième titre, le premier depuis un an.	Il a remporté la 8e titre de titre de champion de champion de France.	0.0	42.01	66.26
Hier, lors de la 2ème journée de la Ligue des champions football,	Le football de Ligue des champions, hier soir,	0.0	31.25	76.13
Il créa un groupuscule de djihadistes.	Il a créé une formation de violences,	0.0	21.31	75.72
Afin de discuter des moyens de sauver l'entreprise.	Et pour les entreprises qui se rendre sur le groupe.	0.0	10.58	74.87
La loi algérienne prévoit que chaque candidat doit réunir 60 000 signatures d'électeurs ou 600 signatures d'élus.	Le président de loi, Donald Trump a été condamné à 6 mois de prison avec un groupe politique et 16.	0.0	05.41	64.86

Si certaines traductions parviennent à conserver le sens de la phrase de référence, la plupart des traductions obtenues avec le modèle sont de très mauvaise qualité (figure 4.8). Les dates semblent mieux traduites que le reste de l'ensemble de test.

À partir de ce premier modèle de traduction, appelé *Baseline*, étudions l'impact de l'encodage vidéo.

4.6.3. Évaluation des différents encodeurs vidéos

Nous utilisons à présent le modèle de traduction précédent (et décrit dans la section 4.3) en modifiant le type d'encodage des vidéos d'entrée. Le tableau 4.5 donne les résultats obtenus sur l'ensemble de test de Mediapi-RGB avec chacun des encodeurs décrits dans la section 4.3.2. L'encodeur VideoSwin entraîné sur de la BSL, celui utilisé précédemment, reste celui qui produit les meilleurs résultats.

En utilisant les caractéristiques I3D, les résultats sont étonnamment faibles. Il




Figure 4.8 – **Répartition des scores BLEURT (en fonction du score divisé par 100 en abscisse) obtenus sur l'ensemble de test.**

aurait peut être fallu tenter d'adapter le modèle en ajoutant des couches d'encodeur *transformer* par exemple pour mieux tirer parti de ses caractéristiques. On peut souligner l'importance d'utiliser un encodeur sur les coordonnées Mediapipe, ce qui permet d'améliorer d'environ 1.0 le score Bleu-4 par rapport aux coordonnées brutes. L'encodeur VideoSwin entraîné sur DictaSignLSF-ISOL-100 obtient le meilleur score BLEU, on peut être surpris par ce résultat car le modèle LS Kaggle entraîné sur les mêmes données avait obtenu un meilleur score d'*accuracy* sur l'ensemble de test de DictaSignLSF-ISOL-100. Cela suggère que les caractéristiques Video Swin conservent plus d'informations utiles à la traduction alors que les caractéristiques obtenues à l'aide du modèle LS Kaggle seraient mieux adaptées à la classification.

4.6.4. Transfert inter-langue

Encodeur commun

Afin de pouvoir bénéficier des poids appris sur un corpus pour un apprentissage sur un autre corpus, il faut que les données vidéos des deux corpus soient représentées sous la même forme. L'encodeur Video Swin pré-entraîné sur la langue des signes britannique [PBM⁺22] que nous avons utilisé dans la section précédente pour extraire les caractéristiques sur Mediapi-RGB n'est plus disponible, la mise à jour du code ne permet plus l'utilisation des poids et il ne nous est pas possible de retrouver les poids que nous avons utilisés pour extraire les caractéristiques sur Mediapipe. Ainsi, il ne nous est pas possible d'extraire le même type de caractéristiques sur d'autres corpus qui seraient utilisés comme pré-entraînement. Le ré-entraînement de ce modèle est une tâche lourde du fait de la quantité de données à manipuler (plus de 1000 heures du corpus de BSL BOBSL [AVM⁺21]). Nous nous appuyons donc sur le modèle Video Swin entraîné sur DictaSignISOL-100 pour extraire les caractéristiques des deux jeux de données.

Table 4.4 – Comparaison des résultats de traduction obtenus sur les jeux de données de langues des signes.
Tableau adapté de [TGD⁺23].

Jeu de données	LS	Langue écrite	Durée (h)	Vocabulaire (K)	BLEU	Domaine
KETI	KSL	Coréen	27.99	0.79	57.37	Situations d'urgence
PHOENIX-2014T [KFN15]	DGS	Allemand	10.5	2.4	25.59	Bulletins météo
CSL Daily	CSL	Mandarin	23.27	3.6	23.92	Vie quotidienne
OpenASL [SBSL22]	ASL	Anglais	288	33	6.72	YouTube (actualités + vlogs)
How2Sign [DPV ⁺ 21]	ASL	Anglais	79.1	22.4	8.03	Instructionnel
BOBSL [AVM ⁺ 21]	BSL	Anglais	1,447	77	1.00	Large gamme d'émissions TV
Mediapi-RGB	LSF	Français	85.9	35.6	4.38	Actualités, sports et politique

Table 4.5 – **Comparaison des représentations d'entrée pour la traduction à l'aide de la baseline transformers**

Caractéristiques d'entrée	Données	Set up	BLEU-4	BLEURT
Coordonnées Mediapipe normalisées	-	-	0.77	
Classifieur LS Kaggle	DictaSignLSF-ISOL-100	Gelé	1.70	
Classifieur LS Kaggle sans pré-entraînement	-	Non gelé	1.83	
I3D	BSL5K	Gelé	0.61	-
VideoSwin T	BOBSL	Gelé	4.38	10.83
VideoSwin T	DictaSignLSF-ISOL-100	Gelé	2.12	6.93

Pré-entraînement sur de l'ASL

Les phrases écrites de How2Sign sont traduites en français à l'aide de la librairie python `deep-translate` et des API de Google traduction et DeepL. Ensuite, on entraîne le modèle *transformer* présenté précédemment sur How2Sign. Le modèle prend en entrée les caractéristiques obtenues avec l'encodeur VideoSwin entraîné sur DictaSignLSF-ISOL-100, en sortie, il doit prédire les phrases de How2Sign en français.

Affinage sur la LSF

Dans un deuxième temps, le modèle appris sur How2Sign est spécialisé (fine-tuned) sur Mediapi-RGB. Les poids appris sur How2Sign sont conservés à l'initialisation mais on change de jeu de données, on parle alors d'affinage (ou *fine-tuning*). À l'issue de l'affinage, le modèle est évalué sur Mediapi-RGB.

Résultats

Jeu de données	Caractér.	BLEU-1	BLEU-2	BLEU-3	BLEU-4	BLEURT
Mediapi- RGB	Mediapipe normalisées	8.05	1.51	0.46	0.14	-
How2Sign → Mediapi- RGB	Mediapipe normalisées	11.05	2.10	0.64	0.22	-
Mediapi- RGB	VideoSwinT-DS	16.10	6.26	3.37	2.12	6.93
How2Sign → Mediapi- RGB	VideoSwinT-DS	16.41	6.29	3.43	2.22	6.85

Table 4.6 – Scores de traduction obtenus avec ou sans pré-entraînement sur How2Sign.

Le tableau 4.6 donne les résultats de traduction sur Mediapi-**RGB** avec et sans pré-entraînement sur How2Sign [DPV⁺21]. Les résultats obtenus avec et sans pré-entraînement sont très proches. Cela peut s'expliquer par le peu de vocabulaire commun entre les deux corpus. Mediapi-**RGB** traite de l'information, du sport et de la politique alors que How2Sign traite de tâches liées aux loisirs ou à la vie courante. Le tableau 4.7 donne des exemples de sous-titres issus de How2Sign puis traduits en français.

4.6.5. Pré-entraînement sur le texte

Détails d'implémentation. Comme pour le modèle *transformer* présenté dans la section 4.3, on entraîne le modèle avec un maximum de 100 epochs. On s'appuie sur l'implémentation du modèle T5 proposée par HuggingFace [Wol19]. Pour les différentes configurations, on s'appuie sur les poids associés fournis par les auteurs sur le site de HuggingFace. Les hyperparamètres sont choisis à partir de ceux utilisés par les auteurs de [UTG23]. L'architecture modèle T5-base repose sur 220 millions de paramètres.

Le tableau 4.8 donne les résultats obtenus avec chacun des corpus. Le résultat obtenu sur How2Sign (BLEU-4 de 1.36) est proche de celui obtenu par les auteurs de [UTG23] (BLEU-4 de 1.22) ce qui valide notre implémentation, le résultat sur Mediapi-**RGB** est plus bas. Quand on regarde les résultats on peut voir que les deux modèles ne fonctionnent pas du tout et prédisent toujours les mêmes phrases dans la langue cible.

En s'appuyant sur les caractéristiques pré-calculées avec VideoSwin-BSL, qui sont les plus performantes d'après le tableau 4.5

Le tableau 4.9 donne les résultats obtenus avec chacun des modèles. Le modèle FLAN-T5 [CHL⁺22] donne le meilleur score BLEU mais reste loin derrière le score obtenu avec la ligne de base *transformer* sans pré-entraînement (sec. 4). Le tableau 4.10 donne des exemples de traductions obtenues avec le modèle FLAN-T5. Nous pouvons remarquer que les phrases prédites sont plutôt correctes mais qu'elles sont éloignées de la vérité terrain. Les auteurs de [UTG23] résolvent ce problème en pré-entraînant le modèle pour la traduction du corpus YouTube-ASL [UTG23] de 984h.

Nous allons travailler sur un exercice de bras qui vous aidera à avoir des mouvements de mains gracieux devant vous.

J'appelle cela peindre le mur.

Nous allons donc monter et descendre ; changeons de main, descendons et montons ; descendons et montons.

Et laissez vos doigts se détendre.

Maintenant, ensemble, vous allez aller à l'opposé.

Faites-le de manière très mécanique au début, puis assouplissez-le lentement à mesure que vous vous sentez à l'aise.

Il est très facile d'amener les doigts à diriger, alors essayez de ne pas les laisser faire.

Table 4.7 – **Exemples de sous-titres issus de How2Sign [DPV⁺21] traduits de l'anglais vers le français.** Les vidéos de How2Sign portent sur des tutoriels issus du corpus How2.

Table 4.8 – **Reproduction de l'expérience de [UTG23] sur How2Sign et Mediapi-RGB** avec le modèle T5.1 [RSR⁺20] sur les coordonnées Mediapipe [BGR⁺20] normalisées.

Dataset	BLEU-1	BLEU-2	BLEU-3	BLEU-4
How2Sign	17.73	6.46	2.66	1.36
Mediapi-RGB	-	-	-	0.57

Model	prompt	version	BLEU-1	BLEU-2	BLEU-3	BLEU-4	BLEURT
T5	yes	base	-	-	-	0.04	
T5.1	yes	base	9.51	2.19	0.97	0.57	2.62
FLAN-T5	yes	base	13.57	4.43	2.14	1.34	4.86
BartheZ	no	base	11.25	4.11	2.40	1.70	6.52

Table 4.9 – **Modèles pré-entraînés sur du texte.** L'entrée textuelle est remplacée par les caractéristiques VideoSwin-BSL.

Malheureusement, les auteurs ne mettent pas à disposition les poids de leur modèle. Reproduire, un tel pré-entraînement sur ce type de corpus est difficilement envisageable dans le cadre de cette thèse car cela demanderait des ressources importantes, et une durée d'expérience de l'ordre de plusieurs mois.

À ce stade des expériences, le modèle de traduction initial est celui qui offre les meilleurs résultats. Pour rappel, il s'agit d'un modèle *Transformer* encodeur-décodeur prenant en entrée des caractéristiques VideoSwinT-BSL. Les transferts interlangues, que ce soit du côté de la langue des signes ou de la langue écrite, n'ont pas permis d'améliorer nos premiers résultats. La dernière section évalue les résultats du modèle de traduction guidé par la classification.

4.6.6. Entraînement conjoint classification et traduction

Cette dernière partie de résultats s'intéresse au modèle qui réalise conjointement classification et traduction, introduit dans la partie 4.5.

Nous n'avons pas ici cherché à optimiser l'architecture des modèles, les expériences préliminaires ayant montré qu'une augmentation importante de la complexité du modèle n'entraîne qu'une amélioration limitée des performances. Dans ce cadre, la configuration des paramètres VideoSwinT-BSL en entrée de l'encodeur combinée avec l'utilisation de 500 clusters ($([HBT^+21])$) dans la tâche de classification permet le meilleur gain en atteignant un score BLEURT moyen de 12,29 soit une amélioration de 3,3 points par rapport au cas sans classification. Plus précisément, la comparaison des deux répartitions de BLEURT correspondantes indique que ce gain a lieu principalement dans l'intervalle $[10;35]$ du score BLEURT (voir figure (a) de la Table 4.11) et profite à 910 séquences de phrases (voir figure (b) de la Table 4.11) des données de test. L'analyse des meilleurs gains (supérieurs à 25) dans l'intervalle d'intérêt $[10;35]$ du BLEURT montre que l'effet de classification en clusters permet de capturer un certain niveau de sens et de prédire une syntaxe en Français correcte pour des séquences de phrase laissées pour compte par l'architecture de traduction de base signe vers texte (Voir Table 4.12). Un autre résultat intéressant qui ressort de nos analyses est que sens et syntaxe sont assez bien prédits pour des BLEURT supérieurs à environ 25 et qu'il est certainement donc inutile de tenter d'atteindre la perfection du score 100.

Une hypothèse pour expliquer ces gains est que la tâche de classification en labels de clusters peut être considérée comme une étape de tokenisation des paramètres

Référence	Prédiction
Bonjour nous sommes le lundi 7 octobre 2019,	Bonjour, nous sommes le lundi 30 mars 2020.
et une moindre reconnaissance de leurs compétences spécifiques par l'État.	et à l'inquiétude des autorités locales.
en marge de la manifestation des Gilets jaunes,	Le Premier ministre, Jean Castex, a annoncé hier
Bonjour, nous sommes aujourd'hui le mercredi 17 avril 2019.	Nous sommes le mercredi 17 février 2021.
face aux Russes Andrey Rublev et Karen Khachanov 6-4, 6-1.	et a dû s'imposer en vigueur le 30 septembre.
l'ouest du pays, la ville de Bombay est paralysée sous le déluge, et on dénombre déjà 35 morts.	Depuis le début de l'épidémie, il a eu l'idée de mettre en place des mesures de confinement à chaque habitant.
L'Espagne a été sacrée championne du monde de basket hier,	et à l'occasion de la Journée internationale des droits des femmes.
Il était donc sans-papiers.	Cette attaque a été envisagée par la population.
ainsi que l'assistant parlementaire de la députée de Moselle Martine Wonner.	et l'association FSCS (Femmes sourdes et Solidaires)
L'immense majorité des propositions, tous pays confondus, traitait de la formation professionnelle.	et à l'indépendance de l'Europe, en l'absence d'interprètes en langue des signes.
accessibilité réelle dans les administrations et à la télévision ;	Enfin, en Île-de-France, en Espagne,
l'université a intégré trois vidéos qui créent la polémique.	et à l'autre côté, les médias et les journalistes.
ils prévoient d'ailleurs des manifestations les 21 et 24 septembre.	et à l'origine de la crise.
mettre fin à l'hémorragie des militants,	Les électeurs seront en nombre d'un à deux à chaque fois.
Bonjour, nous sommes aujourd'hui le mercredi 26 juin 2019.	Nous sommes le mercredi 30 septembre.
C'est donc Christian Jacob qui a été élu avec 62,58 % des voix,	et l'a démissionné en septembre dernier.
Une démission qui fait suite à la publication vendredi d'une vidéo tournée en 2017 à son insu.	Cette dernière a été éliminée en finale à Bourges en 2017.
Européennes : un nouveau duel RN/LREM ?	et à l'occasion de la Journée internationale des droits des femmes.
parmi lesquels des hommes, des femmes et leurs familles.	et l'autre en arrière.
Bienvenue dans l'Média !	Bienvenue dans i'Média !

Table 4.10 – Exemples de prédictions avec le modèle FLAN-T5 pré-entraîné en multi-tâches texte vers texte et affiné sur la traduction automatique de la LSF vers le français

continus (les video-swin) contrainte par le niveau discret des labels de clusters, tout en conservant l'information visuelle de contexte des Video-swin. Ensuite, cette discrétisation permet d'obtenir un nombre de *tokens* visuels comparable au nombre de *tokens* textuels, ce qui nous rapproche du contexte plus classique de traduction entre langues écrites et facilite la mise en relation (par les mécanismes d'attention du *Transformer*) de la langue cible et de la langue source. Ceci étant dit, il reste à comprendre cette amélioration, par exemple par la mise en relation des clusters avec des éléments lexicaux, ce qui semble cohérent avec le faible nombre de couches utilisées dans les *transformers*.

Par ailleurs, des travaux menés au LISN dans le contexte du projet de collaboration "Serveur Gestuel" dont le GIPSA-lab est aussi partenaire, visent à partir du corpus MediaPi-RGB à constituer un dictionnaire de signes identifiés automatiquement selon une méthode de mise en correspondance par similarité de phrases contenant les signes cibles [LGBD24b]. On pourrait ainsi imaginer une architecture de traduction avec une tâche hybride de classification tirant profit à la fois d'un conditionnement dense (les clusters) et d'un autre moindre (le dictionnaire de signes).




Table 4.11 – (a) Répartition du score BLEURT (en fonction du score divisé par 100 en abscisse) pour le cas avec tâche de classification en 500 clusters (bleu) et le cas sans (rouge) (b) Focus sur la différence des 2 répartitions en fonction du score BLEURT (divisé par 100)

4.7. Conclusion et perspectives

Dans ce chapitre nous avons mis au point les premières méthodes de traduction automatique de la LSF vers le français, en nous appuyant sur les travaux menés sur d'autres langues des signes. Nous avons utilisé une ligne de base de traduction *transformer* qui prend en entrée des caractéristiques du domaine vidéo issues d'un encodeur VideoSwin transformer entraîné sur de la classification de signes isolés de langue des signes britannique. Les résultats obtenus sont mitigés, les prédictions ne conservent pas le sens de la langue des signes mais arrivent à conserver le sujet général (la justice, la politique, la santé, etc.). Dans l'ensemble les phrases prédites suivent plutôt bien la langue française même si on observe parfois des fautes ou des répétitions.

Une des difficultés est que la base de données couvre les actualités du moment sur des périodes différentes (années) et contient donc des thématiques très variées. En outre plus de 10 signeurs différents interviennent dont certains ont changé de physionomie (barbe/moustache par exemple).

Dans un second temps nous avons donc tenté de bénéficier d'un apprentissage par transfert entre le corpus d'ASL How2Sign et Mediapi-RGB. Pour cela nous avons dû nous appuyer sur un autre encodeur que celui utilisé pour la ligne de base. Nous avons entraîné puis comparé différents encodeurs sur la ligne de base de traduction. L'encodeur Video Swin T entraîné sur DictaSign a fourni le meilleur résultat. À l'aide de ce nouvel encodeur, nous avons donc extrait les caractéristiques des vidéos de Mediapi-RGB et de How2Sign.

De plus gros corpus d'ASL comme Open-ASL [SBSL22] ou YouTube ASL [UTG23] paraissent particulièrement adaptés pour pré-entraîner des modèles de traduction de la LSF. Cependant, ces corpus basés sur de nombreuses sources de contenus vidéos en ligne ne sont pas utilisables selon le droit français, pour les utiliser, il faudrait demander l'autorisation des multiples ayants droits. Il faudrait donc s'appuyer sur d'autres corpus, comme BOBSL et Matignon-LSF. Le corpus BOBSL [AVM⁺21] en langue des signes britannique (BSL), est de très grande taille (1400h) mais a trois inconvénients : il s'agit de langue des signes interprétée, l'alignement du corpus n'est pas complet et la BSL est plus éloignée de la LSF que l'ASL. Ensuite, le corpus Matignon-LSF [HFO⁺24] offre des perspectives intéressantes. Certes de taille plus modeste que Mediapi-RGB avec environ 40h de vidéos, sans alignement entre vidéos et texte puisqu'il s'agit de langue des signes interprétée (voir chapitre 2), il pourrait servir de pré-entraînement pour permettre au modèle d'assimiler une plus grande quantité de LSF et de français sur des sujets liés à la politique, un thème que l'on retrouve dans Mediapi-RGB [OBG⁺24].

Dans un troisième temps, nous avons conditionné l'architecture de traduction de base par une étape de classification de signes et constaté qu'elle facilite le travail de mise en relation de l'écrit du Français avec la LSF. Ainsi, cela permet pour un certain nombre de séquences laissées pour compte par la ligne de base signe-vers-texte, d'en capturer le sens et de prédire une syntaxe correcte du texte en Français. Ces résultats ouvrent ainsi des perspectives vers des architectures de classification hybrides qui pourraient tirer profit d'annotations automatiques plus ou moins supervisées et de différents niveaux de densité.

Table 4.12 – Exemples de résultats de traduction à partir du modèle transformer (T), à partir de la classification-traduction où la traduction est guidée par la classification (CT). La vérité terrain est indiquée (VT).

Modèle	Phrases	BLEURT
VT	,conséquence concrète :	
T	les deux syndicats expriment leur déception :	7,94
CT	"concrètement, "	33,12
VT	"vainqueur de deux étapes et maillot jaune pendant 14 jours, "	
T	"deux frères Kouachi pénètrent : ""charlie"" , tirant sur les gens"" , "	-1,73
CT	"il a remporté deux fois par le maillot jaune, , "	28,86
VT	"il doit maintenant constituer son équipe, "	
T	"la prostitution touche tous les milieux sociaux, "	4,27
CT	"actuellement, il n'y a pas de véritable groupe, "	29,52
VT	"né de parents sourds, il s'est engagé très tôt pour la communauté sourde. "	
T	"la maison départementale des personnes handicapées (cph), "	-0,738
CT	les parents sourds sont également mobilisés pour répondre aux questions de la communauté sourde.	27,03
VT	"concernant la limitation de vitesse sur les routes à 80 km/h, elle pourrait revenir à 90 km/h. "	
T	"3/ la trajectoire nommée "" auditive"" . "	-0,12
CT	- 80 km/h ne seront plus limités à 80 km/h.	26,94
VT	,et le bilan de la répression a dépassé les 100 morts et fait encore de nombreux blessés.	
T	les taux de pauvreté étant élevé.	3,41
CT	100 personnes sont mortes.	33,00
VT	"23 titres du grand chelem à son actif, "	
T	il remporte son titre de champion d'Europe.	-1,49
CT	, "pour autant que 23 titres de grand chelem, "	25,57
VT	"elle avait réclamé des aménagements de poste pour s'adapter à sa surdité, "	
T	pour réclamer des artistes sourds et handicapés.	-5,39
CT	elle réclame alors des mesures pour favoriser l'emploi des sourds.	23,76
VT	et ils ont décidé de poursuivre les blocages.	
T	"prenez soin de vous, restez à la maison !"	-2,18
CT	c'est donc décidé de continuer.	24,62
VT	,et j'allais oublier : très bon festival clin d'oeil !, :	
T	et légalement d'autres titres.	-0,19
CT	et le festival clin d'oeil aussi !	34,36

Conclusion

Au cours de ce travail de thèse, mené entre le Gipsa-Lab et le LISN, nous avons mené plusieurs travaux exploratoires pour le traitement automatique de la langue des signes française, une langue visuo-gestuelle peu dotée. Le peu de travaux d'apprentissage automatique existants s'étaient concentrés sur l'alignement automatique, la segmentation ou la reconnaissance de types de signes. Une des contraintes majeures résidait dans la rareté des données. Après un bilan des contributions de la thèse, ce chapitre aborde les limitations de ces travaux et propose des perspectives.

Contributions

Matignon-LSF

Dans un premier temps, dans le cadre d'un travail collaboratif, nous avons mis à disposition de la communauté scientifique deux nouveaux corpus de LSF : Matignon-LSF et Mediapi-RGB. Matignon-LSF est issu des comptes-rendus des conseils des ministres. Il s'agit d'allocutions hebdomadaires d'une trentaine de minutes, sous-titrées et interprétées en LSF en direct. Chaque nouvelle allocution est filmée et diffusée sur internet sous la licence ouverte *Étalab*. Nous avons extrait les sous-titres en français, et l'interprétation en LSF de façon à constituer un corpus bilingue. Nous proposons également des caractéristiques pré-calculées pour faciliter l'utilisation des données. Tous les scripts sont rendus publics pour que chacun puisse enrichir le corpus avec de nouvelles vidéos. Il s'agit du premier corpus de LSF interprétée. Il présente l'avantage d'être de grande taille en comparaison avec les corpus existants puisqu'avec ses 39 heures, il arrive juste après Mediapi-RGB. Par ailleurs, il est complètement ouvert à la recherche à la fois publique et privée. Les sous-titres fournis sont actuellement synchronisés avec la parole. De futurs travaux s'intéresseront à les synchroniser directement avec la LSF de façon à faciliter l'entraînement de modèles de traduction LSF vers texte.

Mediapi-RGB

Mediapi-RGB est le plus grand corpus de LSF à ce jour et un des plus gros corpus traduit de LS à travers le monde. Il s'agit de 89h d'émissions en LSF signées par des sourds issues du média en ligne en LSF *Média'Pi*. Comme pour Matignon-LSF, des caractéristiques pré-calculées sont fournies avec le corpus. Nous faisons également une analyse statistique du corpus : fréquence du vocabulaire, longueur des segments, etc. Mediapi-RGB est un corpus de LS signée par des sourds ce qui en fait une

des rares exceptions dans les corpus utilisés à travers le monde pour la recherche en traitement automatique des langues des signes. Enfin, il permet un changement d'échelle car il s'agit de loin du plus gros corpus bilingue de LSF disponible à ce jour.

En publiant ces deux corpus, nous avons porté la quantité totale de données pour la langue des signes française de 30h en 2021 à 160h en 2024.

Premier modèle de reconnaissance de signes en LSF

Inspiré par le modèle multi-flux issu de [SBH22] pour la reconnaissance de phonèmes en langue parlée complétée, nous avons proposé un premier modèle de reconnaissance de signes dans un flux continu. Il s'agit du premier travail portant sur la reconnaissance de signes en LSF. Les vidéos de langue des signes sont représentées sous la forme de poses humaines estimées à l'aide de Mediapipe Holistic [BGR⁺20], elles sont normalisées et découpées en quatre flux (contre 3 dans le modèle original de LPC) : le visage, la main gauche, la main droite et la pose générale du corps. Chacun de ces articulateurs passe par une réduction par ACP avant d'être fourni en entrée au modèle.

L'entraînement, la validation et l'évaluation se font sur le corpus DictaSign-LSF [BBG20a], le seul corpus de LSF densément annoté en gloses. On obtient un WER de 53% sur les 100 gloses les plus fréquentes du corpus. Les erreurs observées montrent que le modèle peine à traiter les répétitions de signes et peut confondre des signes ayant des formes proches.

Quantification de l'apport des différents articulateurs en LSF

L'architecture multi-flux de ce modèle de reconnaissance de signes nous a permis, au travers d'une étude ablative, de quantifier l'apport de chaque articulateur pour la reconnaissance de signes en LSF. Ainsi, on établit que l'ordre d'importance de ces articuleurs est le suivant : la main droite⁹, la main gauche, visage et pose du corps.

Comparaison de deux stratégies d'extraction de caractéristiques

Alors que de nombreux travaux existent sur la représentation des langues écrites [DCLT19, MMOS⁺20], les travaux portant sur les représentations des langues des signes s'avèrent plus rares [HZZL23, HZgZ⁺21]. La plupart des modèles de traitement automatique des langues des signes (traduction [TGD⁺23, AVM⁺21], reconnaissance de signes [MBP⁺22, AVM⁺21], alignement [BAV⁺21]) s'appuient sur des caractéristiques obtenues à partir d'encodeurs entraînés pour la classification de signes. À partir de la même architecture d'encodeur, nous avons comparé les caractéristiques obtenues sur une tâche de classification et sur une tâche d'apprentissage contrastif. La qualité des caractéristiques obtenues est comparée à l'aide de visualisations MDF, PCA et t-SNE, et à l'aide de l'indice de séparabilité N2 [LGL⁺19]. Il en ressort que les caractéristiques obtenues à l'aide de la tâche de classification sont de meilleure qualité.

9. La main droite est la main dominante de la plupart des signeurs de DictaSign-LSF [BBG20a].

Premier modèle de traduction de la LSF

La mise à disposition du corpus Mediapi-RGB [OBG⁺24], qui représente un changement d'échelle pour le traitement automatique de la LSF, a permis d'entraîner un premier modèle de traduction automatique de la LSF vers le français. Le modèle proposé s'appuie sur une architecture *transformers* encodeur-décodeur prenant en entrée les vidéos de LSF, représentées sous forme de caractéristiques obtenues à l'aide de l'encodeur VideoSwinT-BSL [PBM⁺22]. Les premiers résultats sont très loin de la qualité de la traduction obtenue sur les langues les mieux dotées comme le français et l'anglais, mais sont proches des résultats obtenus sur d'autres langues des signes avec des corpus comparables. On observe que le modèle fonctionne globalement mieux pour les dates que pour le reste des données.

Comparaisons de plusieurs encodeurs pour la traduction de la LSF

Le modèle VideoSwinT-BSL n'étant plus disponible, nous testons d'autres encodeurs sur la tâche de traduction automatique de Mediapi-RGB. Nous nous appuyons sur l'encodeur I3D [CZ17] entraîné sur une tâche de classification de signes de la langue des signes britannique par les auteurs de [AVM⁺20] et sur trois autres encodeurs : deux encodeurs entraînés sur DictaSign-LSF-100 l'un sur les vidéos-RGB, l'autre sur des séquences de poses humaines, et un autre sans pré-entraînement, entraîné directement sur les données de Mediapi-RGB pour la tâche de traduction. Les coordonnées de pose Mediapipe normalisées ont également été testées en entrée du modèle, sans passage par un encodeur préalable. On obtient les meilleurs résultats de traduction avec l'encodeur entraîné sur la classification de signes de DictaSign-LSF à partir des vidéos RGB.

Expérience de transfert interlingue pour la traduction de la LSF

Le domaine de la traduction automatique des langues écrite fait la part belle au transfert interlingue, en particulier pour les langues peu dotées. On ajoute des données d'entraînement d'une langue tierce pour améliorer la traduction de la langue peu dotée [LGG⁺20]. Le transfert entre langues tend à mieux fonctionner entre deux langues proches [CAM21]. Nous avons cherché à tirer profit de corpus de langue des signes américaine, une langue des signes proche de la LSF [Can16], pour pré-entraîner un modèle de traduction. Nous nous sommes appuyés sur How2Sign [DPV⁺21], un corpus de tutoriels en ASL (langue des signes américaine) traduits en anglais. Nous avons traduit les sous-titres anglais en français pour faciliter le transfert. Nous initialisons le modèle en pré-entraînant sur une tâche de traduction ASL vers français. Les résultats obtenus montrent que le pré-entraînement sur How2Sign [DPV⁺21] ne permet pas d'amélioration de la traduction sur Mediapi-RGB [OBG⁺24]. Cela peut s'expliquer par la trop grande différence de sujet entre les deux corpus ou la taille insuffisante du corpus de pré-entraînement (79h).

Pré-entraînement sur des tâches texte vers texte pour la traduction automatique de la LSF

Plusieurs travaux portant sur la traduction automatique de la langue des signes américaine vers l'anglais se sont intéressés à l'utilisation modèles pré-entraînés sur des tâches texte vers texte (traduction, réponses à des questions, résumés) sur de grandes quantités de données textuelles multi-lingues. Nous avons testé plusieurs types de modèles texte vers texte ayant suivi plusieurs types de pré-entraînements. Les résultats laissent penser que Mediapi-RGB n'est pas de taille suffisante pour l'ajustement des différents modèles.

Utilisation de pseudo-gloses pour aider la traduction de la LSF

Avec l'expérience de classification et traduction conjointe, nous avons pu nous rapprocher des méthodes s'appuyant sur des gloses pour guider la traduction, sans avoir besoin d'annotation en gloses. Nous avons montré que remplacer les gloses par des labels de clusters obtenus automatiquement pouvait permettre une amélioration de la traduction. Cette architecture a permis de récupérer sens et syntaxe pour un certain nombre de séquences non prises en compte avec la ligne de base. Ces résultats restent à être expliqués en particulier au regard de la complexité de l'architecture et des caractéristiques linguistiques de la langue des signes (niveau lexical, icônique,...).

Limitations et perspectives

Dans cette section nous évoquons les principales limitations de ce travail de thèse et les principales perspectives pour y faire face ou pour approfondir les travaux présentés.

Quantité de données

La quantité de données nécessaire pour obtenir une traduction de qualité entre deux langues est difficile à estimer. À titre d'exemple, le corpus de référence pour les travaux portant sur la traduction automatique du français vers l'anglais, une tâche presque résolue aujourd'hui, s'appuie sur le corpus WMT EN-FR qui contient 36 millions de phrases. À titre de comparaison, Mediapi-RGB comporte 50 084 phrases (ou sous-titres). 36 millions de phrases de LSF correspondraient à environ 50 000 heures d'enregistrement, ce qui semble inatteignable au vu du paysage actuel de la production vidéo en LSF.

L'utilisation de données dans d'autres langues des signes est une piste mais seulement partielle puisque le corpus existant le plus volumineux à ce jour (BOBSL [AVM⁺21] en langue des signes britannique) ne contient que 1.2 million de phrases. Le transfert de modèles appris sur des langues écrites vers les langues des signes reste donc une perspective pertinente. Joindre les deux types de pré-apprentissage semble être la solution la plus envisageable à moyen terme.

Enfin, de façon plus transversale on peut interroger la faible quantité de vidéos produites en LSF, est-ce que cela est dû à un nombre de locuteurs trop faibles? Est-ce que c'est un héritage de l'interdiction de l'enseignement de LSF? Est-ce que cela

vient des difficultés des personnes sourdes à se faire une place dans une société à dominante entendante?

Perspectives expérimentales

On pourrait envisager l'utilisation des grands jeux de données de langues des signes étrangères existants pour pré-entraîner les modèles de traduction. On pourrait aussi s'intéresser à l'apprentissage auto-supervisé pour pré-entraîner les modèles ou extraire des représentations de la LSF à l'échelle du signe ou à l'échelle de la phrase.

Positionnement

Comme évoqué en préambule de ce manuscrit, ce travail de recherche a été mené par une équipe exclusivement entendante. Aucun d'entre nous ne signe couramment ou est réellement intégré dans une communauté sourde signante. Ces différents points peuvent biaiser la recherche que nous menons par notre manque de familiarité avec notre objet d'étude qui reste loin de notre quotidien. L'intégration de personnes sourdes dans les équipes de recherche est complexe car les postes requièrent la validation de longues études (bac+5 minimum pour un ingénieur de recherche ou un doctorant). Or, les personnes sourdes font face à de multiples difficultés lors de leur parcours scolaire, les cours à l'université ne sont pas toujours interprétés du fait du manque de moyens et du manque d'interprètes, ce qui freine la compréhension des étudiants sourds et par conséquent la longueur de leur études. Certains laboratoires étrangers ont trouvé des solutions pour intégrer des personnes sourdes peu diplômées en passant par des contrats adaptés.

Risques culturels

Il ne faut pas que le mirage de nouveaux outils de traitement automatique des langues des signes ait un impact sur l'intérêt porté à ces langues de la part des entendants. L'offre de formation en LSF est toujours très insuffisante tout comme les moyens dédiés à l'interprétation et l'accessibilité dans de nombreux domaines à commencer par l'enseignement. Ces enjeux sont connexes au développement de nouveaux outils.

Impact environnemental

L'obtention des résultats obtenus dans de ce manuscrit a nécessité l'entraînement de plus de 400 modèles d'apprentissage profond sur des serveurs de calculs, à l'aide du module python CarbonTracker [AKS20], on estime la quantité de CO₂ émise à 200kg, ce qui correspond à environ 600km parcourus en voiture.

Bibliographie

- [AAB⁺15] Martín Abadi, Ashish Agarwal, Paul Barham, Eugene Brevdo, Zhi-feng Chen, Craig Citro, Greg S. Corrado, Andy Davis, Jeffrey Dean, Matthieu Devin, Sanjay Ghemawat, Ian Goodfellow, Andrew Harp, Geoffrey Irving, Michael Isard, Yangqing Jia, Rafal Jozefowicz, Lukasz Kaiser, Manjunath Kudlur, Josh Levenberg, Dandelion Mané, Rajat Monga, Sherry Moore, Derek Murray, Chris Olah, Mike Schuster, Jonathon Shlens, Benoit Steiner, Ilya Sutskever, Kunal Talwar, Paul Tucker, Vincent Vanhoucke, Vijay Vasudevan, Fernanda Viégas, Oriol Vinyals, Pete Warden, Martin Wattenberg, Martin Wicke, Yuan Yu, and Xiaoqiang Zheng. TensorFlow : Large-scale machine learning on heterogeneous systems, 2015. Software available from tensorflow.org.
- [ABHS20] Alham Fikri Aji, Nikolay Bogoychev, Kenneth Heafield, and Rico Sennrich. In neural machine translation, what does transfer learning transfer? In Dan Jurafsky, Joyce Chai, Natalie Schluter, and Joel Tetreault, editors, *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 7701--7710, Online, July 2020. Association for Computational Linguistics.
- [ACP⁺20] Nikolas Adaloglou, Theodoris Chatzis, Ilias Papastratis, Andreas Stergioulas, Georgios Th Papadopoulos, Vassia Zacharopoulou, George J Xydopoulos, Klimnis Atzakis, Dimitris Papazachariou, and Petros Daras. A comprehensive study on sign language recognition methods. *arXiv preprint arXiv :2007.12530*, 2020.
- [ADH⁺21] Anurag Arnab, Mostafa Dehghani, Georg Heigold, Chen Sun, Mario Lučić, and Cordelia Schmid. Vivit : A video vision transformer. In *Proceedings of the IEEE/CVF international conference on computer vision*, pages 6836--6846, 2021.
- [AGLB22] Patricia Cabot Alvarez, Xavier Giro, Nieto Laia, and Tarres Benet. Sign language translation based on transformers for the how2sign dataset. *Image Processing Group Signal Theory and Communications Department Universitat Politècnica de Catalunya. BARCELONATECH*, 2022.
- [AKS20] Lasse F. Wolff Anthony, Benjamin Kanding, and Raghavendra Selvan. Carbontracker : Tracking and predicting the carbon footprint of training deep learning models. ICML Workshop on Challenges in

- Deploying and monitoring Machine Learning Systems, July 2020. arXiv :2007.03051.
- [AORS22] Julien Abadji, Pedro Ortiz Suarez, Laurent Romary, and Benoît Sagot. Towards a Cleaner Document-Oriented Multilingual Crawled Corpus. *arXiv e-prints*, page arXiv :2201.06642, January 2022.
- [AVM⁺20] Samuel Albanie, Gül Varol, Liliane Momeni, Triantafyllos Afouras, Joon Son Chung, Neil Fox, and Andrew Zisserman. Bsl-1k : Scaling up co-articulated sign language recognition using mouthing cues. In *Computer Vision--ECCV 2020 : 16th European Conference, Glasgow, UK, August 23--28, 2020, Proceedings, Part XI 16*, pages 35--53. Springer, 2020.
- [AVM⁺21] Samuel Albanie, Gül Varol, Liliane Momeni, Hannah Bull, Triantafyllos Afouras, Himel Chowdhury, Neil Fox, Bencie Woll, Rob Cooper, Andrew McParland, and Andrew Zisserman. BOBSL : BBC-Oxford British Sign Language Dataset. *arXiv*, 2021.
- [Bah96] Benjamin Bahan. *Non-Manual Realization of Agreement in American Sign Language*. PhD thesis, Boston University, 1996. PDF.
- [BAV⁺21] Hannah Bull, Triantafyllos Afouras, Gül Varol, Samuel Albanie, Liliane Momeni, and Andrew Zisserman. Aligning subtitles in sign language videos. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 11552--11561, 2021.
- [BB12] Annelies Braffort and Latifa Boutora. Degels1 : A comparable corpus of french sign language and co-speech gestures. In *Proceedings of the Eight International Conference on Language Resources and Evaluation (LREC'12)*. ELRA, 2012.
- [BBG20a] Valentin Belissen, Annelies Braffort, and Michèle Gouiffès. Dicta-Sign-LSF-v2 : Remake of a Continuous French Sign Language Dialogue Corpus and a First Baseline for Automatic Sign Language Processing. In ELRA, editor, *LREC 2020, 12th Conference on Language Resources and Evaluation*, Proceedings of the 12th Language Resources and Evaluation Conference, Marseille, France, 2020.
- [BBG20b] Hannah Bull, Annelies Braffort, and Michèle Gouiffès. MEDIAPISKELEL -A 2D-Skeleton Video Database of French Sign Language With Aligned French Subtitles. In *12th Conference on Language Resources and Evaluation (LREC 2020)*, pages 6063--6068, Marseille, France, June 2020.
- [BCB⁺10] A. Balvet, C. Courtin, D. Boutet, C. Cuxac, I. Fusellier-Souza, B. Garcia, M.-T. L'Huillier, and M.-A. Sallandre. The creagest project : a digitized and annotated corpus for french sign language (lsf) and natural gestural languages. In *Proceedings of the International Language Resources and Evaluation Conference (LREC'2010)*, pages 469--475, 2010.
- [BCB14] Dzmitry Bahdanau, Kyunghyun Cho, and Yoshua Bengio. Neural machine translation by jointly learning to align and translate. *CoRR*, abs/1409.0473, 2014.

- [Bel20] Valentin Belissen. *From sign recognition to automatic sign language understanding : Addressing the non-conventionalized units*. PhD thesis, Université Paris-Saclay, 2020.
- [Ber19] Fabrice Bertin. Les sourds, une culture méconnue? *Études*, 2019(3) :55--64, March 2019.
- [BGB20] Hannah Bull, Michèle Gouiffès, and Annelies Braffort. Automatic segmentation of sign language into subtitle-units. In *ECCV Workshops*, 2020.
- [BGR⁺20] V. Bazarevsky, I. Grishchenko, K Raveendran, T. Zhu, F. Zhang, and M. Grundmann. Blazepose : On-device real-time body pose tracking, 2020.
- [BLBC⁺22] Elise Bertin-Lemée, Annelies Braffort, Camille Challant, Claire Darnet, Boris Dauriac, Michael Filhol, Emmanuella Martinod, and Jérémie Segouat. Rosetta-lsf : an aligned corpus of french sign language and french for text-to-sign translation. In *Proceedings of the 13th International Conference on Language Resources and Evaluation (LREC 2022)*, pages 4955--4962, Marseille, France, June 23 2022.
- [BLBC⁺23] Élise Bertin-Lemée, Annelies Braffort, Camille Challant, Claire Darnet, and Michael Filhol. Example-based machine translation from text to a hierarchical representation of sign language. In *24th Annual Conference of the European Association for Machine Translation (EAMT 2023)*, pages 21--30, 2023.
- [BM12] Monia Ben Mlouka. Analyse automatique de discours en langue des signes : Représentation et traitement de l'espace de signation. In *Proceedings of the Joint Conference JEP-TALN-RECITAL 2012, volume 3 : RECITAL*, pages 219--232. ATALA/AFCP, June 2012.
- [Bon91] Juan Pablo Bonet. *Réduction des lettres à leurs éléments primitifs et art d'enseigner à parler aux muets*. Unknown, 1891. Publication date : 1891.
- [Bos06] Bruno Bossard. *Conception d'un système de reconnaissance automatique de gestes bimanuels : application à la réalité virtuelle et à la langue des signes*. PhD thesis, Thèse de doctorat, Université Paris-Sud (XI), 2006.
- [BPV⁺24] Vasileios Baltatzis, Rolandos Alexandros Potamias, Evangelos Ververas, Guanxiong Sun, Jiankang Deng, and Stefanos Zafeiriou. Neural sign actors : A diffusion model for 3d sign language production from text. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 1985--1995, 2024.
- [Bra96] Annelies Braffort. A gesture recognition architecture for sign language. In *International ACM SIGACCESS Conference on Computers and Accessibility*, 1996.
- [Bra16] Annelies Braffort. *La langue des signes française (LSF) ; modélisations, ressources et applications*. Iste Science Cognitive Dirigée, 12 Janvier, 2016.

- [Bra22] Annelies Braffort. Langue des signes française : Etat des lieux des ressources linguistiques et des traitements automatiques. In *Journées Jointes des Groupements de Recherche Linguistique Informatique, Formelle et de Terrain (LIFT) et Traitement Automatique des Langues (TAL)*, pages 131--138, November 2022.
- [Bue22] François Buet. *Modèles neuronaux pour la simplification de parole, application au sous-titrage*. PhD thesis, Université Paris-Saclay, 2022.
- [Bul23] Hannah Bull. *Learning sign language from subtitles*. Theses, Université Paris-Saclay, February 2023.
- [C⁺15] François Chollet et al. Keras. <https://keras.io>, 2015.
- [CAM21] Wei-Rui Chen and Muhammad Abdul-Mageed. Machine translation of low-resource indo-european languages. In *Proceedings of the Sixth Conference on Machine Translation*, pages 347--353, 2021.
- [Can16] Yann Cantin. Des origines du noétomalalien français, perspectives historiques. *Glottopol : Revue de sociolinguistique en ligne*, (27), 2016.
- [Cat21] Fanny Catteau. Corpus catteau 2020, 2021. ORTOLANG (Open Resources and TOols for LANGuage) –www.ortolang.fr.
- [CGB21] Hussein Chaaban, Michèle Gouiffès, and Annelies Braffort. Automatic annotation and segmentation of sign language videos : Base-level features and lexical signs classification. In *16th International Joint Conference on Computer Vision, Imaging and Computer Graphics Theory and Applications (VISIGRAPP 2021)*, volume 5, pages 484--491, 2021.
- [CHK⁺18] Necati Cihan Camgoz, Simon Hadfield, Oscar Koller, Hermann Ney, and Richard Bowden. Neural sign language translation. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, June 2018.
- [CHL05] Sumit Chopra, Raia Hadsell, and Yann LeCun. Learning a similarity metric discriminatively, with application to face verification. *2005 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR'05)*, 1 :539--546 vol. 1, 2005.
- [CHL⁺22] Hyung Won Chung, Le Hou, Shayne Longpre, Barret Zoph, Yi Tay, William Fedus, Yunxuan Li, Xuezhi Wang, Mostafa Dehghani, Siddhartha Brahma, Albert Webson, Shixiang Shane Gu, Zhuyun Dai, Mirac Suzgun, Xinyun Chen, Aakanksha Chowdhery, Alex Castro-Ros, Marie Pellat, Kevin Robinson, Dasha Valter, Sharan Narang, Gaurav Mishra, Adams Yu, Vincent Zhao, Yanping Huang, Andrew Dai, Hongkun Yu, Slav Petrov, Ed H. Chi, Jeff Dean, Jacob Devlin, Adam Roberts, Denny Zhou, Quoc V. Le, and Jason Wei. Scaling instruction-finetuned language models, 2022.
- [Cho14] Kyunghyun Cho. Learning phrase representations using rnn encoder-decoder for statistical machine translation. *arXiv preprint arXiv :1406.1078*, 2014.

- [CHS⁺19] Zhe Cao, Gines Hidalgo, Tomas Simon, Shih-En Wei, and Yaser Sheikh. Openpose : Realtime multi-person 2d pose estimation using part affinity fields, 2019.
- [CJH⁺21] Jinmiao Cai, Nianjuan Jiang, Xiaoguang Han, Kui Jia, and Jiangbo Lu. Jolo-gcn : mining joint-centered light-weight information for skeleton-based action recognition. In *Proceedings of the IEEE/CVF winter conference on applications of computer vision*, pages 2735--2744, 2021.
- [CKHB20a] Necati Cihan Camgoz, Oscar Koller, Simon Hadfield, and Richard Bowden. Multi-channel transformers for multi-articulatory sign language translation. In *Computer Vision--ECCV 2020 Workshops : Glasgow, UK, August 23--28, 2020, Proceedings, Part IV 16*, pages 301--319. Springer, 2020.
- [CKHB20b] Necati Cihan Camgoz, Oscar Koller, Simon Hadfield, and Richard Bowden. Sign language transformers : Joint end-to-end sign language recognition and translation. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2020.
- [CSB⁺19] Carlos Caetano, Jessica Sena, François Brémont, Jefersson A Dos Santos, and William Robson Schwartz. Skelemotion : A new representation of skeleton joint sequences based on motion information for 3d action recognition. In *2019 16th IEEE international conference on advanced video and signal based surveillance (AVSS)*, pages 1--8. IEEE, 2019.
- [CSR⁺21] Necati Cihan Camgöz, Ben Saunders, Guillaume Rochette, Marco Giovanelli, Giacomo Inches, Robin Nachtrab-Ribback, and Richard Bowden. Content4all open research sign language translation datasets. *CoRR*, abs/2105.02351, 2021.
- [Cux00] Christian Cuxac. *La Langue des Signes Française : les voies de l'iconicité*. Ophrys, Paris, 2000.
- [CvMG⁺14] Kyunghyun Cho, Bart van Merriënboer, Caglar Gulcehre, Dzmitry Bahdanau, Fethi Bougares, Holger Schwenk, and Yoshua Bengio. Learning phrase representations using RNN encoder--decoder for statistical machine translation. In Alessandro Moschitti, Bo Pang, and Walter Daelemans, editors, *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 1724--1734, Doha, Qatar, October 2014. Association for Computational Linguistics.
- [CYCT20] Ka Leong Cheng, Zhaoyang Yang, Qifeng Chen, and Yu-Wing Tai. Fully convolutional networks for continuous sign language recognition. In *Computer Vision--ECCV 2020 : 16th European Conference, Glasgow, UK, August 23--28, 2020, Proceedings, Part XXIV 16*, pages 697--714. Springer, 2020.
- [CZ17] Joao Carreira and Andrew Zisserman. Quo vadis, action recognition? a new model and the kinetics dataset. In *proceedings of the*

- IEEE Conference on Computer Vision and Pattern Recognition*, pages 6299--6308, 2017.
- [CZY⁺21] Yuxin Chen, Ziqi Zhang, Chunfeng Yuan, Bing Li, Ying Deng, and Weiming Hu. Channel-wise topology refinement graph convolution for skeleton-based action recognition. In *Proceedings of the IEEE/CVF international conference on computer vision*, pages 13359--13368, 2021.
- [DAGiNV22] Amanda Duarte, Samuel Albanie, Xavier Giró-i Nieto, and Gül Varol. Sign language video retrieval with free-form textual queries. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 14094--14104, 2022.
- [Dau65] Maurice Daumas. Les machines à traduire de georges artsrouni. *Revue d'histoire des sciences et de leurs applications*, 18(3) :283--302, 1965.
- [DBK⁺20] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, et al. An image is worth 16x16 words : Transformers for image recognition at scale. In *International Conference on Learning Representations*, 2020.
- [DCK20] Raj Dabre, Chenhui Chu, and Anoop Kunchukuttan. A survey of multilingual neural machine translation. *ACM Computing Surveys (CSUR)*, 53(5) :1--38, 2020.
- [DCLT19] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. Bert : Pre-training of deep bidirectional transformers for language understanding. In *North American Chapter of the Association for Computational Linguistics*, 2019.
- [DD13] Patrice Dalle and Juliette Dalle. Langues des signes, enseignement et nouvelles technologies. *La nouvelle revue de l'adaptation et de la scolarisation*, 64(4) :189--202, 2013.
- [DDMH⁺24] Aashaka Desai, Maartje De Meulder, Julie A. Hochgesang, Anne-marie Kocab, and Alex X. Lu. Systemic biases in sign language AI research : A deaf-led call to reevaluate research agendas. In Eleni Efthimiou, Stavroula-Evita Fotinea, Thomas Hanke, Julie A. Hochgesang, Johanna Mesch, and Marc Schulder, editors, *Proceedings of the LREC-COLING 2024 11th Workshop on the Representation and Processing of Sign Languages : Evaluation of Sign Language Resources*, pages 366--377, Torino, Italy, May 2024. ELRA Language Resources Association (ELRA) and the International Committee on Computational Linguistics (ICCL).
- [DDS⁺09] Jia Deng, Wei Dong, Richard Socher, Li-Jia Li, Kai Li, and Li Fei-Fei. Imagenet : A large-scale hierarchical image database. In *2009 IEEE conference on computer vision and pattern recognition*, pages 248--255. Ieee, 2009.
- [DFW15] Yong Du, Yun Fu, and Liang Wang. Skeleton based action recognition with convolutional neural network. In *2015 3rd IAPR Asian*

- conference on pattern recognition (ACPR)*, pages 579--583. IEEE, 2015.
- [DH09] Daphne Ducharme and Lisa Hurst. Être sourd et apprendre à lire. *Revue du Nouvel-Ontario*, (34) :145--173, 2009.
- [dL76] Abbé Charles-Michel de L'Épée. *Institution des sourds et muets par la voie des signes méthodiques*. Nyon l'Aîné, Paris, 1776.
- [DPV⁺21] Amanda Duarte, Shruti Palaskar, Lucas Ventura, Deepti Ghadiyaram, Kenneth DeHaan, Florian Metze, Jordi Torres, and Xavier Giro-i Nieto. How2Sign : A Large-scale Multimodal Dataset for Continuous American Sign Language. In *Conference on Computer Vision and Pattern Recognition (CVPR)*, 2021.
- [DRD⁺07] Philippe Dreuw, David Rybach, Thomas Deselaers, Morteza Zahedi, and Hermann Ney. Speech recognition techniques for a sign language recognition system. In *Interspeech*, pages 2513--2516, Antwerp, Belgium, August 2007. ISCA best student paper award Interspeech 2007.
- [DZC⁺22] Haodong Duan, Yue Zhao, Kai Chen, Dahua Lin, and Bo Dai. Revisiting skeleton-based action recognition. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pages 2969--2978, 2022.
- [eBBB16] M. e. Benchiheub, B. Berret, and A. Braffort. Collecting and analysing a motion-capture corpus of french sign language. In *7th International Conference on Language Resources and Evaluation - Workshop on the Representation and Processing of Sign Languages (LREC-WRPSL 2016)*, pages 7--12, 2016.
- [EGJK04] Ralph Elliott, John Glauert, Vince Jennings, and Richard Kennaway. An overview of the sigml notation and sigmlsigning software system. *sign-lang@ LREC 2004*, pages 98--104, 2004.
- [Enc13] Florence Encrevé. *Les sourds dans la société française au XIXe siècle*. Creaphis éditions, Paris, 2013.
- [EOAG18] Sergey Edunov, Myle Ott, Michael Auli, and David Grangier. Understanding back-translation at scale. In Ellen Riloff, David Chiang, Julia Hockenmaier, and Jun'ichi Tsujii, editors, *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing*, pages 489--500, Brussels, Belgium, October-November 2018. Association for Computational Linguistics.
- [ETV20] Moussa Kamal Eddine, Antoine J-P Tixier, and Michalis Vazirgiannis. Barthez : a skilled pretrained french sequence-to-sequence model. *arXiv preprint arXiv :2010.12321*, 2020.
- [FFMC21] Jérôme Fink, Benoît Frénay, Laurence Meurant, and Anthony Cleve. Lsfb-cont and lsfb-isol : Two new datasets for vision-based sign language recognition. In *2021 International Joint Conference on Neural Networks (IJCNN)*, pages 1--8, 2021.

- [FHC14] Michael Filhol, Mohamed Nassime Hadjadj, and Annick Choisier. Non-manual features : The right to indifference. In Onno Crasborn, Eleni Efthimiou, Stavroula-Evita Fotinea, Thomas Hanke, Jette Kristoffersen, and Johanna Mesch, editors, *Proceedings of the LREC2014 6th Workshop on the Representation and Processing of Sign Languages : Beyond the Manual Channel*, pages 49--54, Reykjavik, Iceland, May 2014. European Language Resources Association (ELRA).
- [FT14] M. Filhol and X. Tannier. Construction of a french-lsf corpus. In *Building and Using Comparable Corpora, Language resource and evaluation conference (LREC)*, Iceland, 2014.
- [FXM⁺21] Haoqi Fan, Bo Xiong, Karttikeya Mangalam, Yanghao Li, Zhicheng Yan, Jitendra Malik, and Christoph Feichtenhofer. Multiscale vision transformers. In *Proceedings of the IEEE/CVF international conference on computer vision*, pages 6824--6835, 2021.
- [GA18] Ankush Garg and Mayank Agarwal. Machine translation : A literature review. *ArXiv*, abs/1901.01122, 2018.
- [GDSL24] Shester Gueuwou, Xiaodan Du, Greg Shakhnarovich, and Karen Livescu. Signmusketeers : An efficient multi-stream approach for sign language translation at scale. *arXiv preprint arXiv :2406.06907*, 2024.
- [GFGS06] Alex Graves, Santiago Fernández, Faustino Gomez, and Jürgen Schmidhuber. Connectionist temporal classification : labelling unsegmented sequence data with recurrent neural networks. In *Proceedings of the 23rd international conference on Machine learning*, pages 369--376, 2006.
- [Gui06] Pierre Guitteny. *Le passif en langue des signes*. Theses, Université Michel de Montaigne - Bordeaux III, December 2006.
- [GWM⁺24] Mo Guan, Yan Wang, Guangkun Ma, Jiarui Liu, and Mingzu Sun. Multi-stream keypoint attention network for sign language recognition and translation. *arXiv e-prints*, pages arXiv--2405, 2024.
- [HBT⁺21] Wei-Ning Hsu, Benjamin Bolte, Yao-Hung Hubert Tsai, Kushal Lakhotia, Ruslan Salakhutdinov, and Abdelrahman Mohamed. Hubert : Self-supervised speech representation learning by masked prediction of hidden units. *IEEE/ACM transactions on audio, speech, and language processing*, 29 :3451--3460, 2021.
- [HFO⁺24] Julie Halbout, Diandra Fabre, Yanis Ouakrim, Julie Lascar, Annelies Braffort, Michèle Gouiffès, and Denis Beautemps. Matignon-LSF : a Large Corpus of Interpreted French Sign Language. In ELRA Language Resources Association (ELRA) and the International Committee on Computational Linguistics (ICCL), editors, *LREC-COLING 2024 11th Workshop on the Representation and Processing of Sign Languages : Evaluation of Sign Language Resources*, pages 202--208, Turin, Italy, May 2024.
- [HKHC18] Cong Duy Vu Hoang, Philipp Koehn, Gholamreza Haffari, and Trevor Cohn. Iterative back-translation for neural machine transla-

- tion. In *2nd Workshop on Neural Machine Translation and Generation*, pages 18--24. Association for Computational Linguistics, 2018.
- [HL00] John Hutchins and Evgenii Lovtskii. Petr petrovich troyanskii (1894–1950) : A forgotten pioneer of mechanical translation. *Machine translation*, 15(3) :187--221, 2000.
- [HZgZ⁺21] Hezhen Hu, Weichao Zhao, Wen gang Zhou, Yuechen Wang, and Houqiang Li. Signbert : Pre-training of hand-model-aware representation for sign language recognition. *2021 IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 11067--11076, 2021.
- [HZL21] Hezhen Hu, Wengang Zhou, and Houqiang Li. Hand-model-aware sign language recognition. pages 1558--1566, 2021.
- [HZZL23] Hezhen Hu, Weichao Zhao, Wengang Zhou, and Houqiang Li. Signbert+ : Hand-model-aware self-supervised pre-training for sign language understanding. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, pages 1--20, 2023.
- [JB16] Trevor Johnston and L. De Beuzeville. *Auslan Corpus Annotation Guidelines*. Centre for Language Sciences, Department of Linguistics, Macquarie University, 2016.
- [KAB⁺23] Tom Kocmi, Eleftherios Avramidis, Rachel Bawden, Ondřej Bojar, Anton Dvorkovich, Christian Federmann, Mark Fishel, Markus Freitag, Thamme Gowda, Roman Grundkiewicz, Barry Haddow, Philipp Koehn, Benjamin Marie, Christof Monz, Makoto Morishita, Kenton Murray, Makoto Nagata, Toshiaki Nakazawa, Martin Popel, Maja Popović, and Mariya Shmatova. Findings of the 2023 conference on machine translation (WMT23) : LLMs are here but not quite there yet. In Philipp Koehn, Barry Haddow, Tom Kocmi, and Christof Monz, editors, *Proceedings of the Eighth Conference on Machine Translation*, pages 1--42, Singapore, December 2023. Association for Computational Linguistics.
- [KB14] Diederik P Kingma and Jimmy Ba. Adam : A method for stochastic optimization. *arXiv preprint arXiv :1412.6980*, 2014.
- [KBA⁺17] QiuHong Ke, Mohammed Bennamoun, Senjian An, Ferdous Sohel, and Farid Boussaid. A new representation of skeleton sequences for 3d action recognition. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 3288--3297, 2017.
- [KCS⁺17] Will Kay, João Carreira, Karen Simonyan, Brian Zhang, Chloe Hillier, Sudheendra Vijayanarasimhan, Fabio Viola, Tim Green, Trevor Back, Apostol Natsev, Mustafa Suleyman, and Andrew Zisserman. The kinetics human action video dataset. *ArXiv*, abs/1705.06950, 2017.
- [Ker11] Loïc Kervajan. *Contribution à la traduction automatique Français/Langue des Signes Française (LSF) au moyen de personnages virtuels*. PhD thesis, Université de Provence-Aix-Marseille I, 2011.
- [KFN15] Oscar Koller, Jens Forster, and Hermann Ney. Continuous sign language recognition : Towards large vocabulary statistical recognition

- systems handling multiple signers. *Computer Vision and Image Understanding*, 141 :108--125, December 2015.
- [KHL⁺20] Reiner Konrad, Thomas Hanke, Gabriele Langer, Dolly Blanck, Julian Bleicken, Ilona Hofmann, Olga Jeziorski, Lutz König, Susanne König, Rie Nishio, Anja Regen, Uta Salden, Sven Wagner, Satu Worseck, Oliver Böse, Elena Jahn, and Marc Schulder. Meine dgs -- annotiert. öffentliches korpus der deutschen gebärdensprache, 3. release / my dgs -- annotated. public corpus of german sign language, 3rd release, 2020.
- [KK14] Rupinder Kaur and Parteek Kumar. Hamnosys generation system for sign language. In *2014 International Conference on Advances in Computing, Communications and Informatics (ICACCI)*, pages 2727--2734. IEEE, 2014.
- [KKJC19] Sang-Ki Ko, Chang Jo Kim, Hyedong Jung, and Choongsang Cho. Neural sign language translation based on human keypoint estimation. *Applied Sciences*, 9 :2683, 07 2019.
- [KMB21] Jyotsana Khatri, Rudra Murthy, and Pushpak Bhattacharyya. Language model pretraining and transfer learning for very low resource languages. In Loic Barrault, Ondrej Bojar, Fethi Bougares, Rajen Chatterjee, Marta R. Costa-jussa, Christian Federmann, Mark Fishel, Alexander Fraser, Markus Freitag, Yvette Graham, Roman Grundkiewicz, Paco Guzman, Barry Haddow, Matthias Huck, Antonio Jimeno Yepes, Philipp Koehn, Tom Kocmi, Andre Martins, Makoto Morishita, and Christof Monz, editors, *Proceedings of the Sixth Conference on Machine Translation*, pages 995--998, Online, November 2021. Association for Computational Linguistics.
- [KR18] Taku Kudo and John Richardson. Sentencepiece : A simple and language independent subword tokenizer and detokenizer for neural text processing. *arXiv preprint arXiv :1808.06226*, 2018.
- [KSH12] Alex Krizhevsky, Ilya Sutskever, and Geoffrey E Hinton. Imagenet classification with deep convolutional neural networks. In F. Pereira, C.J. Burges, L. Bottou, and K.Q. Weinberger, editors, *Advances in Neural Information Processing Systems*, volume 25. Curran Associates, Inc., 2012.
- [KTW⁺20] Prannay Khosla, Piotr Teterwak, Chen Wang, Aaron Sarna, Yonglong Tian, Phillip Isola, Aaron Maschinot, Ce Liu, and Dilip Krishnan. Supervised contrastive learning. *Advances in neural information processing systems*, 33 :18661--18673, 2020.
- [KW16] Thomas N Kipf and Max Welling. Semi-supervised classification with graph convolutional networks. *arXiv preprint arXiv :1609.02907*, 2016.
- [KWSS18] Sujay S Kumar, Tenzin Wangyal, Varun Saboo, and Ramamoorthy Srinath. Time series neural networks for real time sign language translation. In *2018 17th IEEE International Conference on Machine Learning and Applications (ICMLA)*, pages 243--248. IEEE, 2018.

- [LGBD24a] Julie Lascar, Michèle Gouiffès, Annelies Braffort, and Claire Danet. Annotation of lsf subtitled videos without a pre-existing dictionary. In *LREC-COLING 2024 11th Workshop on the Representation and Processing of Sign Languages : Evaluation of Sign Language Resources*, pages 100--108, 2024.
- [LGBD24b] Julie Lascar, Michèle Gouiffès, Annelies Braffort, and Claire Danet. Annotation of LSF subtitled videos without a pre-existing dictionary. In Eleni Efthimiou, Stavroula-Evita Fotinea, Thomas Hanke, Julie A. Hochgesang, Johanna Mesch, and Marc Schulder, editors, *Proceedings of the LREC-COLING 2024 11th Workshop on the Representation and Processing of Sign Languages : Evaluation of Sign Language Resources*, pages 204--212, Torino, Italia, May 2024. ELRA and ICCL.
- [LGG⁺20] Yinhan Liu, Jiatao Gu, Naman Goyal, Xian Li, Sergey Edunov, Marjan Ghazvininejad, Mike Lewis, and Luke Zettlemoyer. Multilingual denoising pre-training for neural machine translation. *Transactions of the Association for Computational Linguistics*, 8 :726--742, 2020.
- [LGL⁺19] Ana C. Lorena, Luís P. F. Garcia, Jens Lehmann, Marcilio C. P. Souto, and Tin Kam Ho. How complex is your classification problem? a survey on measuring classification complexity. *ACM Comput. Surv.*, 52(5), sep 2019.
- [LH14] Pengfei Lu and Matt Huenerfauth. Collecting and evaluating the cuny asl corpus for research on american sign language animation. *Comput. Speech Lang.*, 28(3) :812--831, May 2014.
- [LIRK03] Lucian Vlad Lita, Abraham Ittycheriah, Salim Roukos, and Nanda Kambhatla. truecasing. In *Annual Meeting of the Association for Computational Linguistics*, 2003.
- [Liu18] Li Liu. *Modeling for Continuous Cued Speech Recognition in French using Advanced Machine Learning Methods*. Theses, Université Grenoble Alpes, September 2018.
- [LJD⁺18] Lisha Li, Kevin Jamieson, Giulia DeSalvo, Afshin Rostamizadeh, and Ameet Talwalkar. Hyperband : A novel bandit-based approach to hyperparameter optimization. *Journal of Machine Learning Research*, 18(185) :1--52, 2018.
- [LLC⁺21] Ze Liu, Yutong Lin, Yue Cao, Han Hu, Yixuan Wei, Zheng Zhang, Stephen Lin, and Baining Guo. Swin transformer : Hierarchical vision transformer using shifted windows. In *Proceedings of the IEEE/CVF international conference on computer vision*, pages 10012--10022, 2021.
- [LLLL23] Jungho Lee, Minhyeok Lee, Dogyoon Lee, and Sangyoun Lee. Hierarchically decomposed graph convolutional networks for skeleton-based action recognition. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 10444--10453, 2023.
- [LNC⁺22] Ze Liu, Jia Ning, Yue Cao, Yixuan Wei, Zheng Zhang, Stephen Lin, and Han Hu. Video swin transformer. In *Proceedings of the*

- IEEE/CVF conference on computer vision and pattern recognition*, pages 3202--3211, 2022.
- [Low76] Bruce Lowerre. *The Harpy Speech Recognition System*. Ph.d. thesis, Carnegie Mellon University, Pittsburgh, PA, USA, 1976.
- [LROYL19] Dongxu Li, Cristian Rodriguez-Opazo, Xin Yu, and Hongdong Li. Word-level deep sign language recognition from video : A new large-scale dataset and methods comparison. *2020 IEEE Winter Conference on Applications of Computer Vision (WACV)*, pages 1448--1458, 2019.
- [LRYL20] Dongxu Li, Cristian Rodriguez, Xin Yu, and Hongdong Li. Transferring cross-domain knowledge for video sign language recognition. pages 6205--6214, 2020.
- [LWH⁺23] Kunchang Li, Yali Wang, Yinan He, Yizhuo Li, Yi Wang, Limin Wang, and Yu Qiao. Uniformerv2 : Unlocking the potential of image vits for video understanding. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 1632--1643, 2023.
- [LZXP18] Chao Li, Qiaoyong Zhong, Di Xie, and Shiliang Pu. Co-occurrence feature learning from skeleton data for action recognition and detection with hierarchical aggregation. In *Proceedings of the 27th International Joint Conference on Artificial Intelligence*, pages 786--792, 2018.
- [MBP⁺22] Liliane Momeni, Hannah Bull, KR Prajwal, Samuel Albanie, Gül Varol, and Andrew Zisserman. Automatic dense annotation of large-vocabulary sign language videos. In *European Conference on Computer Vision*, pages 671--690. Springer, 2022.
- [MGC16] Laurence Meurant, Maxime Gobert, and Anthony Cleve. Modelling a parallel corpus of french and french belgian sign language (lsfb). 05 2016.
- [MGI⁺21] Mizuki Maruyama, Shuvojit Ghose, Katsufumi Inoue, Partha Pratim Roy, Masakazu Iwamura, and Michifumi Yoshioka. Word-level sign language recognition with multi-stream neural networks focusing on local regions. *arXiv preprint arXiv :2106.15989*, 2021.
- [Mil21] Agnès Millet. *Grammaire descriptive de la langue des signes française : dynamiques iconiques et linguistique générale*. UGA éditions, 2021.
- [MJM⁺23] Amit Moryossef, Zifan Jiang, Mathias Müller, Sarah Ebling, and Yoav Goldberg. Linguistically motivated sign language segmentation. *arXiv preprint arXiv :2310.13960*, 2023.
- [MKMB24] Fredrik Malmberg, Anna Klezovich, Johanna Mesch, and Jonas Beskow. Exploring latent sign language representations with isolated signs, sentences and in-the-wild data. In Eleni Efthimiou, Stavroula-Evita Fotinea, Thomas Hanke, Julie A. Hochgesang, Johanna Mesch, and Marc Schulder, editors, *Proceedings of the LREC-COLING 2024 11th Workshop on the Representation and Processing of Sign Languages : Evaluation of Sign Language Resources*, pages 219--224, Torino, Italia, May 2024. ELRA and ICCL.

- [MMOS⁺20] Louis Martin, Benjamin Muller, Pedro Javier Ortiz Suárez, Yoann Dupont, Laurent Romary, Éric Villemonte de la Clergerie, Djamé Seddah, and Benoît Sagot. Camembert : a tasty french language model. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, 2020.
- [Nae20] Lucie Naert. *Capture, annotation and synthesis of motions for the data-driven animation of sign language avatars*. PhD thesis, Université de Bretagne Sud, 2020.
- [Nyl01] Edo Nyland. *Linguistic Archaeology : An Introduction*. Trafford Publishing, 2001.
- [OBG⁺24] Yanis Ouakrim, Hannah Bull, Michèle Gouiffès, Denis Beautemps, Thomas Hueber, and Annelies Braffort. Mediapi-RGB : Enabling Technological Breakthroughs in French Sign Language (LSF) Research through an Extensive Video-Text Corpus. In *VISAPP 2024 - 19th International Joint Conference on Computer Vision, Imaging and Computer Graphics Theory and Applications*, volume 2, Rome, Italy, February 2024.
- [OC12] Ellen Ormel and Onno Crasborn. Prosodic correlates of sentences in signed languages : A literature review and suggestions for new types of studies. *Sign Language Studies*, 12(2) :279--315, 2012.
- [PBM⁺22] K R Prajwal, Hannah Bull, Liliane Momeni, Samuel Albanie, Gül Varol, and Andrew Zisserman. Weakly-supervised fingerspelling recognition in british sign language videos. In *British Machine Vision Conference*, 2022.
- [PGL20] Justin M Power, Guido W Grimm, and Johann-Mattis List. Evolutionary dynamics in the dispersal of sign languages. *Royal Society Open Science*, 7(1) :191100, 2020.
- [Pos18] Matt Post. A call for clarity in reporting BLEU scores. In Ondřej Bojar, Rajen Chatterjee, Christian Federmann, Mark Fishel, Yvette Graham, Barry Haddow, Matthias Huck, Antonio Jimeno Yepes, Philipp Koehn, Christof Monz, Matteo Negri, Aurélie Névél, Mariana Neves, Matt Post, Lucia Specia, Marco Turchi, and Karin Verspoor, editors, *Proceedings of the Third Conference on Machine Translation : Research Papers*, pages 186--191, Brussels, Belgium, October 2018. Association for Computational Linguistics.
- [PRWZ02] Kishore Papineni, Salim Roukos, Todd Ward, and Wei-Jing Zhu. Bleu : a method for automatic evaluation of machine translation. In *Proceedings of the 40th annual meeting of the Association for Computational Linguistics*, pages 311--318, 2002.
- [QYM17] Zhaofan Qiu, Ting Yao, and Tao Mei. Learning spatio-temporal representation with pseudo-3d residual networks. In *proceedings of the IEEE International Conference on Computer Vision*, pages 5533--5541, 2017.

- [RNS⁺18] Alec Radford, Karthik Narasimhan, Tim Salimans, Ilya Sutskever, et al. Improving language understanding by generative pre-training. 2018.
- [RSR⁺20] Colin Raffel, Noam Shazeer, Adam Roberts, Katherine Lee, Sharan Narang, Michael Matena, Yanqi Zhou, Wei Li, and Peter J Liu. Exploring the limits of transfer learning with a unified text-to-text transformer. *Journal of machine learning research*, 21(140) :1--67, 2020.
- [RSW⁺24] Phillip Rust, Bowen Shi, Skyler Wang, Necati Cihan Camgöz, and Jean Maillard. Towards privacy-aware sign language translation at scale. *arXiv preprint arXiv :2402.09611*, 2024.
- [RTM⁺23] S M Rayeed, Sidratul Tamzida Tuba, Hasan Mahmud, Mumtahir Habib Ullah Mazumder, Saddam Hossain Mukta, and Kamrul Hasan. Bdsl47 : A complete depth-based bangla sign alphabet and digit dataset. *Data in Brief*, 51 :109799, 2023.
- [Ré05] République Française. LOI n° 2005-102 du 11 février 2005 pour l'égalité des droits et des chances, la participation et la citoyenneté des personnes handicapées, 2005. Published in the Journal Officiel de la République Française.
- [San10] Wendy Sandler. Prosody and syntax in sign languages. *Transactions of the philological society*, 108(3) :298--328, 2010.
- [SBC⁺02] Marie-Anne Sallandre, Dominique Boutet, Christian Cuxac, Caroline Dubois, Patrice Dalle, LS-Colin, Annelies Braffort, Rachid Gherbi, Fanch Lejeune, Christophe Collet, Guillemette Jausions, Boris Lenseigne, Annick Choisier, Ivani Fusellier-Souza, Stéphane Mangaud, Institut national des jeunes sourds, Nasredine Chab, Anthony Guyon, and Laurent Valo. Corpus ls-colin sur plusieurs genres discursifs, 2002.
- [SBH22] Sanjana Sankar, Denis Beautemps, and Thomas Hueber. Multistream neural architectures for cued speech recognition using a pre-trained visual feature extractor and constrained ctc decoding. In *ICASSP 2022 - 2022 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, pages 8477--8481, 2022.
- [SBSL22] Bowen Shi, Diane Brentari, Greg Shakhnarovich, and Karen Livescu. Open-domain sign language translation learned from online video. In *EMNLP*, 2022.
- [SCB20a] Ben Saunders, Necati Cihan Camgoz, and Richard Bowden. Everybody sign now : Translating spoken language to photo realistic sign language video. *arXiv preprint arXiv :2011.09846*, 2020.
- [SCB20b] Ben Saunders, Necati Cihan Camgoz, and Richard Bowden. Progressive transformers for end-to-end sign language production. In *Computer Vision--ECCV 2020 : 16th European Conference, Glasgow, UK, August 23--28, 2020, Proceedings, Part XI 16*, pages 687--705. Springer, 2020.

- [SCB21] Ben Saunders, Necati Cihan Camgoz, and Richard Bowden. Continuous 3d multi-channel sign language production via progressive transformers and mixture density networks. *International journal of computer vision*, 129(7) :2113--2135, 2021.
- [SCB22] Ben Saunders, Necati Cihan Camgoz, and Richard Bowden. Signing at scale : Learning to co-articulate signs for large-scale photo-realistic sign language production. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 5141--5151, 2022.
- [SCHB20] Stephanie Stoll, Necati Cihan Camgoz, Simon Hadfield, and Richard Bowden. Text2sign : towards sign language production using neural machine translation and generative adversarial networks. *International Journal of Computer Vision*, 128(4) :891--908, 2020.
- [SD19] BH Shekar and Guesh Dagnew. Grid search-based hyperparameter tuning and classification of microarray cancer data. In *2019 second international conference on advanced computational and communication paradigms (ICACCP)*, pages 1--8. IEEE, 2019.
- [SDP20] Thibault Sellam, Dipanjan Das, and Ankur Parikh. Bleurt : Learning robust metrics for text generation. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 7881--7892, 2020.
- [Seg09] Jérémie Segouat. A study of sign language coarticulation. *ACM SIGACCESS Accessibility and Computing*, (93) :31--38, 2009.
- [SFR⁺13] Adam Schembri, Jordan Fenlon, Ramas Rentelis, Sally Reynolds, and Kearsy Cormier. Building the british sign language corpus. *Language Documentation & Conservation*, 7 :136--154, 2013.
- [SHB16] Rico Sennrich, Barry Haddow, and Alexandra Birch. Improving neural machine translation models with monolingual data. In Katrin Erk and Noah A. Smith, editors, *Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (Volume 1 : Long Papers)*, pages 86--96, Berlin, Germany, August 2016. Association for Computational Linguistics.
- [Sit12] Audrey Sitbon. *Baromètre santé sourds et malentendants 2011/2012*. INPES éditions, www.inpes.sante.fr, 2012.
- [SLJ⁺15] Christian Szegedy, Wei Liu, Yangqing Jia, Pierre Sermanet, Scott Reed, Dragomir Anguelov, Dumitru Erhan, Vincent Vanhoucke, and Andrew Rabinovich. Going deeper with convolutions. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 1--9, 2015.
- [SLNW16] Amir Shahroudy, Jun Liu, Tian-Tsong Ng, and Gang Wang. Ntu rgb+ d : A large scale dataset for 3d human activity analysis. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 1010--1019, 2016.

- [SMV⁺19] Chen Sun, Austin Myers, Carl Vondrick, Kevin Murphy, and Cordelia Schmid. Videobert : A joint model for video and language representation learning. In *Proceedings of the IEEE/CVF international conference on computer vision*, pages 7464--7473, 2019.
- [SRP19] Yann Soullard, Cyprien Ruffino, and Thierry Paquet. Ctcmodel : a keras model for connectionist temporal classification. *arXiv preprint arXiv :1901.07957*, 2019.
- [Sto01] William C. Stokoe. *Language in Hand : Why Sign Came Before Speech*. Gallaudet University Press, 2001.
- [Sut10] Valerie Sutton. The signwriting alphabet. *Read and Write any Sign Language in the World. ISWA Manual*, 2010.
- [SVL14] Ilya Sutskever, Oriol Vinyals, and Quoc V Le. Sequence to sequence learning with neural networks. *Advances in neural information processing systems*, 27, 2014.
- [SZSW20] Yi-Fan Song, Zhang Zhang, Caifeng Shan, and Liang Wang. Stronger, faster and more explainable : A graph convolutional baseline for skeleton-based action recognition. In *Proceedings of the 28th ACM International Conference on Multimedia*, MM '20, page 1625--1633, New York, NY, USA, 2020. Association for Computing Machinery.
- [SZW19] Yi-Fan Song, Zhang Zhang, and Liang Wang. Richly activated graph convolutional network for action recognition with incomplete skeletons. In *2019 IEEE International Conference on Image Processing (ICIP)*, pages 1--5, 2019.
- [SZY24] Xiaolong Shen, Zhedong Zheng, and Yi Yang. Stepnet : Spatial-temporal part-aware network for isolated sign language recognition. *ACM Transactions on Multimedia Computing, Communications and Applications*, 20(7) :1--19, 2024.
- [TBF⁺15] Du Tran, Lubomir Bourdev, Rob Fergus, Lorenzo Torresani, and Manohar Paluri. Learning spatiotemporal features with 3d convolutional networks. In *Proceedings of the IEEE international conference on computer vision*, pages 4489--4497, 2015.
- [TCD⁺21] Hugo Touvron, Matthieu Cord, Matthijs Douze, Francisco Massa, Alexandre Sablayrolles, and Hervé Jégou. Training data-efficient image transformers & distillation through attention. In *International conference on machine learning*, pages 10347--10357. PMLR, 2021.
- [TGD⁺23] Laia Tarrés, Gerard I Gállego, Amanda Duarte, Jordi Torres, and Xavier Giró-i Nieto. Sign language translation from instructional videos. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 5625--5635, 2023.
- [TH15] Abdel Aziz Taha and Allan Hanbury. Metrics for evaluating 3d medical image segmentation : analysis, selection, and tool. *BMC medical imaging*, 15 :1--28, 2015.
- [TK23] Sho Takase and Shun Kiyono. Lessons on parameter sharing across layers in transformers. In *Proceedings of The Fourth Workshop on*

- Simple and Efficient Natural Language Processing (SustaiNLP)*, pages 78--90, 2023.
- [TNW20] Anirudh Tunga, Sai Vidhyaranya Nuthalapati, and Juan Wachs. Pose-based sign language recognition using GCN and BERT. In *WACV Workshop*, pages 31--40, 2020.
- [TSWW22] Zhan Tong, Yibing Song, Jue Wang, and Limin Wang. Videomae : Masked autoencoders are data-efficient learners for self-supervised video pre-training. *Advances in neural information processing systems*, 35 :10078--10093, 2022.
- [UTG23] David Uthus, Garrett Tanzer, and Manfred Georg. Youtube-asl : A large-scale, open-domain american sign language-english parallel corpus, 2023.
- [vAK07] Ulrich von Agris and Karl-Friedrich Kraiss. Towards a video corpus for signer-independent continuous sign language recognition. *Gesture in Human-Computer Interaction and Simulation*, 2007.
- [VDiN20] Lucas Ventura, Amanda Duarte, and Xavier Giró i Nieto. Can everybody sign now? exploring sign language video generation from 2d poses. In *ECCV 2020 Workshop on Sign Language recognition, Production and Translation (SLRTP)*, 08/2020 2020.
- [VGLar] L. Verlaine, P. Guitteny, and P. Legouis. *La langue des signes*. Centre d'information sur la surdité d'Aquitaine, year. Manuel du Centre d'information sur la surdité d'Aquitaine. Voir aussi CIS <http://www.cis.gouv.fr>.
- [VMA⁺21] G. Varol, L. Momeni, S. Albanie, T. Afouras, and A. Zisserman. Read and attend : Temporal localisation in sign language videos. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 16857--16866, 2021.
- [VPK⁺21] Andreas Voskou, Konstantinos P Panousis, Dimitrios Kosmopoulos, Dimitris N Metaxas, and Sotirios Chatzis. Stochastic transformer networks with linear competing units : Application to end-to-end sl translation. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 11946--11955, 2021.
- [VSP⁺17] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. In I. Guyon, U. Von Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan, and R. Garnett, editors, *Advances in Neural Information Processing Systems*, volume 30. Curran Associates, Inc., 2017.
- [WBZ⁺21] Jason Wei, Maarten Bosma, Vincent Y Zhao, Kelvin Guu, Adams Wei Yu, Brian Lester, Nan Du, Andrew M Dai, and Quoc V Le. Finetuned language models are zero-shot learners. *arXiv preprint arXiv :2109.01652*, 2021.
- [WCW⁺22] Rui Wang, Dongdong Chen, Zuxuan Wu, Yinpeng Chen, Xiyang Dai, Mengchen Liu, Yu-Gang Jiang, Luwei Zhou, and Lu Yuan.

- Bevt : Bert pretraining of video transformers. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pages 14733--14743, 2022.
- [WGGH18] Xiaolong Wang, Ross Girshick, Abhinav Gupta, and Kaiming He. Non-local neural networks. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 7794--7803, 2018.
- [WLL⁺22] Yi Wang, Kunchang Li, Yizhuo Li, Yinan He, Bingkun Huang, Zhiyu Zhao, Hongjie Zhang, Jilan Xu, Yi Liu, Zun Wang, et al. Internvideo : General video foundation models via generative and discriminative learning. *arXiv preprint arXiv :2212.03191*, 2022.
- [WLL⁺24] Yi Wang, Kunchang Li, Xinhao Li, Jiashuo Yu, Yinan He, Guo Chen, Baoqi Pei, Rongkun Zheng, Jilan Xu, Zun Wang, et al. Internvideo2 : Scaling video foundation models for multimodal video understanding. *CoRR*, 2024.
- [Wol19] T Wolf. Huggingface's transformers : State-of-the-art natural language processing. *arXiv preprint arXiv :1910.03771*, 2019.
- [WQB⁺22] Matthew Watson, Chen Qian, Jonathan Bischof, François Chollet, et al. Kerasnlp. <https://github.com/keras-team/keras-nlp>, 2022.
- [WZA22] Quanyu Wang, Kaixiang Zhang, and Manjotho Ali Asghar. Skeleton-based st-gcn for human action recognition with extended skeleton graph and partitioning strategy. *IEEE Access*, 10 :41403--41410, 2022.
- [YR20] Kayo Yin and Jesse Read. Better sign language translation with stmc-transformer. In *International Conference on Computational Linguistics*, 2020.
- [YXL18] Sijie Yan, Yuanjun Xiong, and Dahua Lin. Spatial temporal graph convolutional networks for skeleton-based action recognition. pages 7444--7452, 2018.
- [YZ17] Su Yang and Qing Zhu. Video-based chinese sign language recognition using convolutional neural network. In *2017 IEEE 9th International Conference on Communication Software and Networks (ICCSN)*, pages 929--934, 2017.
- [ZCC⁺23] Benjia Zhou, Zhigang Chen, Albert Clapés, Jun Wan, Yanyan Liang, Sergio Escalera, Zhen Lei, and Du Zhang. Gloss-free sign language translation : Improving from visual-language pretraining. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 20871--20881, 2023.
- [ZKW⁺] Tianyi Zhang, Varsha Kishore, Felix Wu, Kilian Q Weinberger, and Yoav Artzi. Bertscore : Evaluating text generation with bert. In *International Conference on Learning Representations*.
- [ZZZL20] Hao Zhou, Wengang Zhou, Yun Zhou, and Houqiang Li. Spatial-temporal multi-cue network for continuous sign language recognition. In *Proceedings of the AAAI conference on artificial intelligence*, volume 34, pages 13009--13016, 2020.